Cryptanalyse des schémas de recherche sur données chiffrées

Matthieu Giraud

Gilles ZÉMOR

Université de Bordeaux
Master Cryptologie
et Sécurité Informatique

université de BORDEAUX

Alexandre ANZALA-YAMAJAKO
Olivier BERNARD

Thales Communications & Security
Laboratoire Chiffre

THALES

15 septembre 2016

Contexte

Aujourd'hui une entité est capable de maîtriser un **périmètre de sécurité interne**.

Contexte

Cependant le volume des données gérées tend à croître, obligeant un grand nombre d'entités à **externaliser leur stockage**.

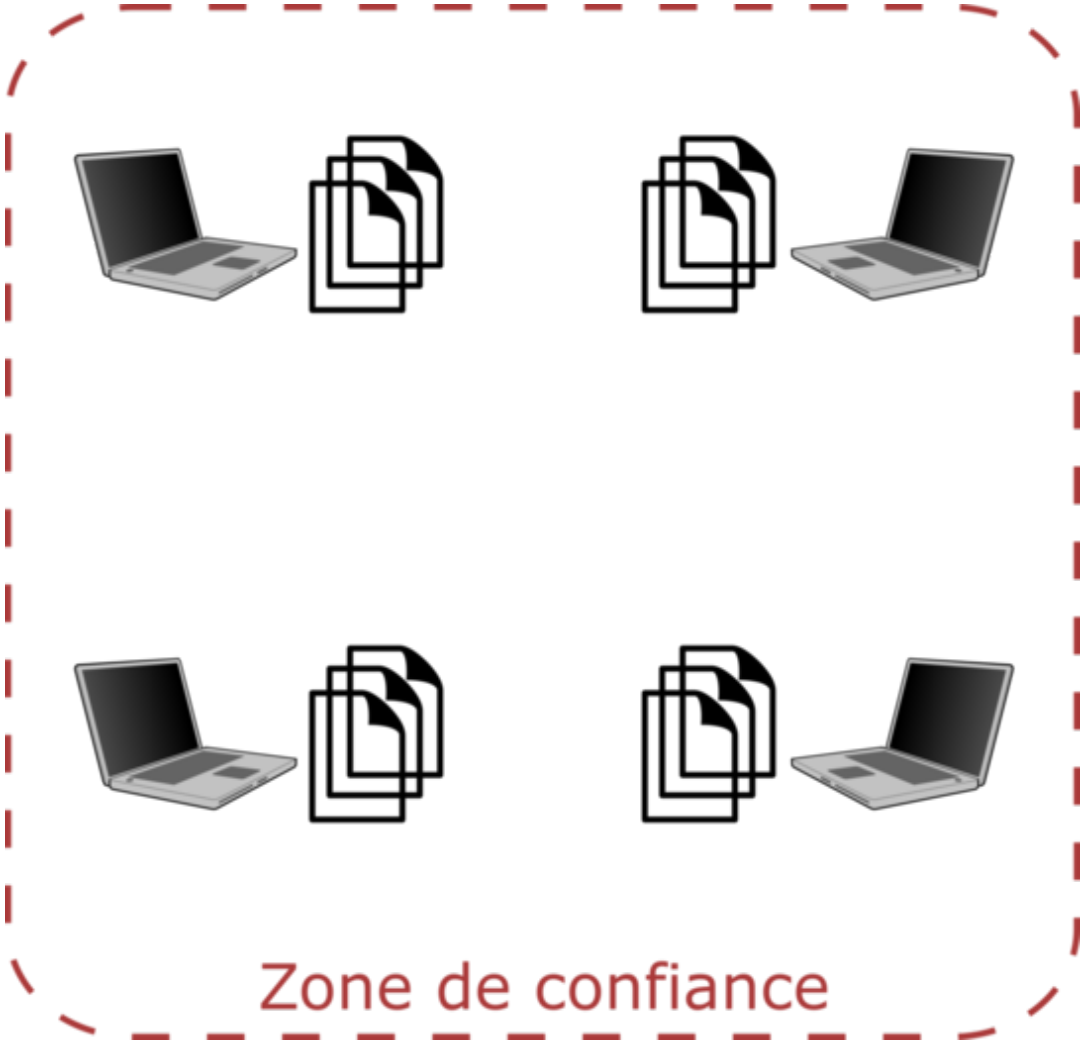

Contexte

Les **opérateurs de Cloud** sont prêts à accueillir ces données.

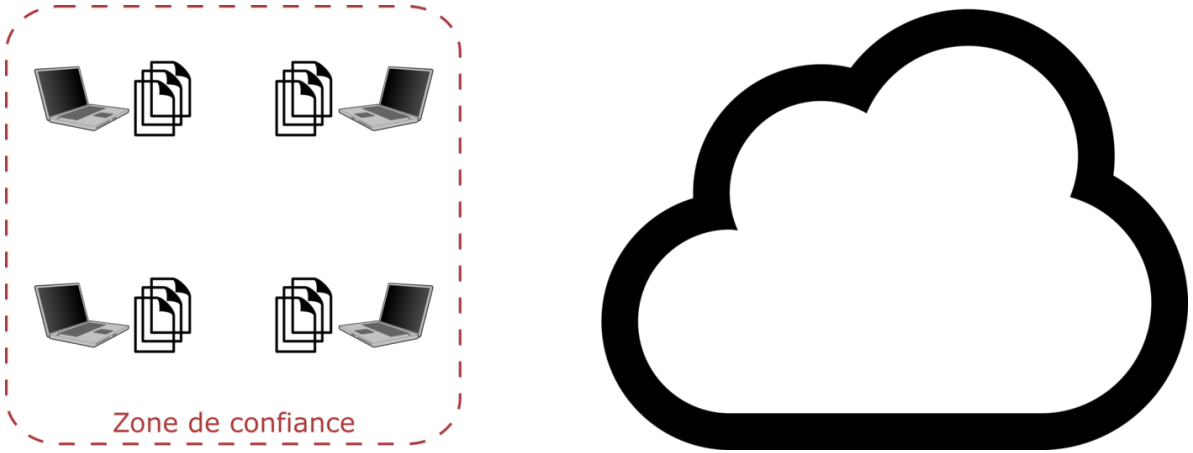

Contexte

Certains de ces opérateurs offrent des **fonctionnalités sans sécurité**.

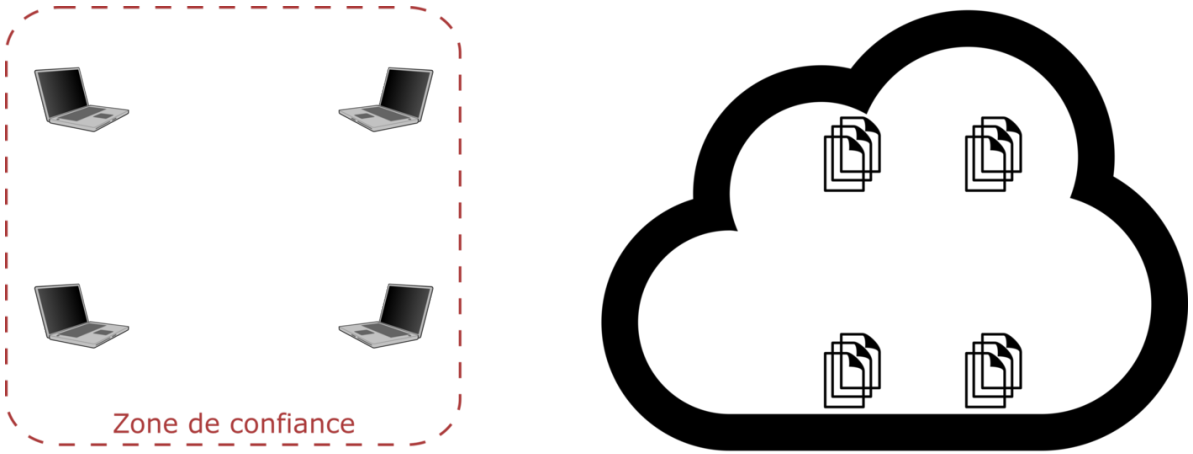

+ Fonctionnalité

- Sécurité

Contexte

D'autres opérateurs de Cloud proposent de fortes garanties de **sécurité sans fonctionnalité**.

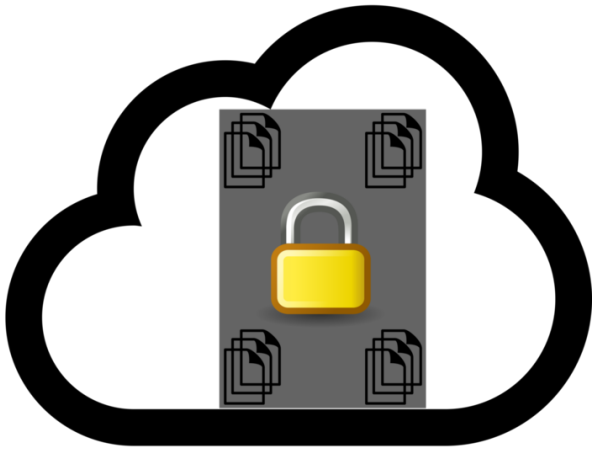

+ Sécurité

- Fonctionnalité

Compromis : *Symmetric Searchable Encryption*

Symmetric Searchable Encryption (**SSE**) :

- Externaliser un ensemble de **données chiffrées**.
- Réaliser des **recherches par mot-clef unique**.

Objectifs du stage

Théorie

- État de l'art des attaques existantes.
- **Clarifier** la hiérarchie des fuites d'information définies par Cash *et al.* [CGPR16].
- Déterminer de **nouvelles attaques**.

Objectifs du stage

Théorie

- État de l'art des attaques existantes.
- **Clarifier** la hiérarchie des fuites d'information définies par Cash *et al.* [CGPR16].
- Déterminer de **nouvelles attaques**.

Pratique

- Évaluer **l'efficacité des nouvelles attaques** sur des ensembles documentaires de la vie réelle.

Sommaire

Schémas SSE
- Formalisation
- Modèle de sécurité

Classification des fuites d'information

Exploitation des fuites d'information
- Notre modèle d'attaque
- Cryptanalyses

Conclusion

Sommaire

Schémas SSE
- Formalisation
- Modèle de sécurité

Classification des fuites d'information

Exploitation des fuites d'information
- Notre modèle d'attaque
- Cryptanalyses

Conclusion

SSE : *Symmetric Searchable Encryption*

La formalisation d'un schéma SSE implique un client et un serveur.

SSE : *Symmetric Searchable Encryption*

La formalisation d'un schéma SSE implique un client et un serveur.

Initialisation

Setup prend en entrée un ensemble documentaire D et renvoie une clef secrète K, un ensemble de documents chiffrés D^* ainsi qu'une structure EDB :

$$(K, \mathsf{D}^*, \mathsf{EDB}) \leftarrow \mathsf{Setup}(\mathsf{D})$$

SSE : *Symmetric Searchable Encryption*

La formalisation d'un schéma SSE implique un client et un serveur.

Initialisation

Setup prend en entrée un ensemble documentaire D et renvoie une clef secrète K, un ensemble de documents chiffrés D^* ainsi qu'une structure EDB :

$$(K, \mathsf{D}^*, \mathsf{EDB}) \leftarrow \mathsf{Setup}(\mathsf{D})$$

Recherche

Search prend en entrée la clef K, une recherche par le mot-clef w et EDB. Il retourne $\mathsf{D}^*(w)$:

$$\mathsf{D}^*(w) \leftarrow \mathsf{Search}(K, w, \mathsf{EDB})$$

Modèle *semi-honnête*

Le serveur suit le modèle **semi-honnête** de Goldreich [Gol98] :

- **Honnête** : il respecte les protocoles.
- **Curieux** : il essaie d'apprendre le maximum d'information.

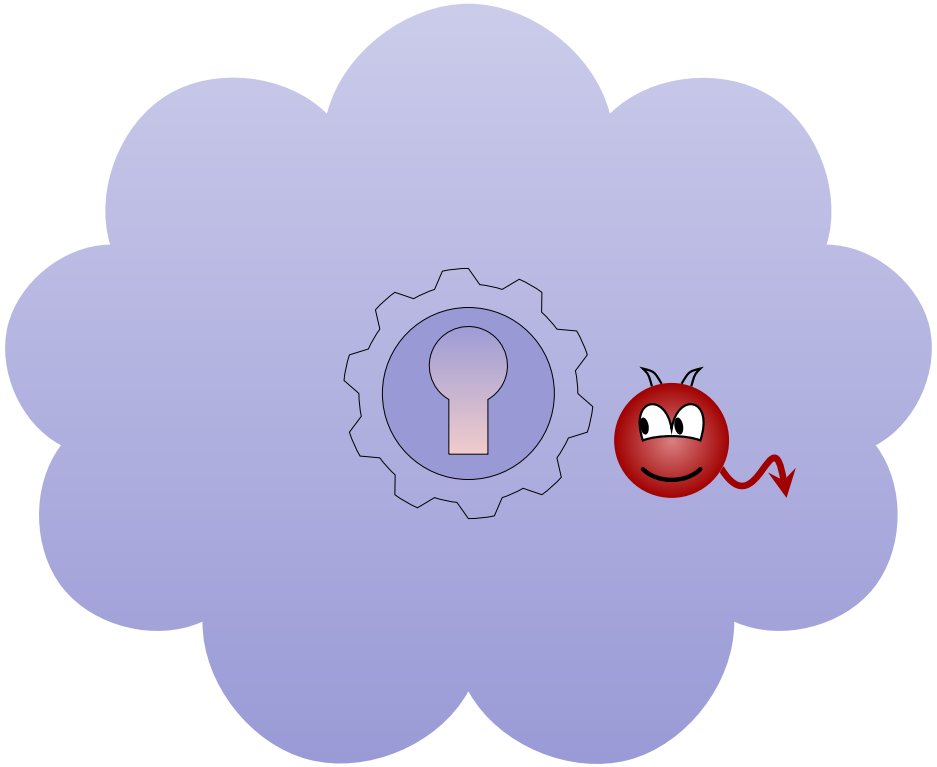

Modèle de sécurité

Comment évaluer la sécurité d'un schéma SSE dans ce modèle ?

Fonction de fuite $\mathcal{L}$

Elle désigne une liste d'informations **accessibles à l'attaquant**.

Modèle de sécurité

Comment évaluer la sécurité d'un schéma SSE dans ce modèle ?

Fonction de fuite $\mathcal{L}$

Elle désigne une liste d'informations **accessibles à l'attaquant**.

Preuve de sécurité

L'attaquant cherche à **distinguer** :

- un monde où l'exécution des protocoles est **normale** ;
- un monde où l'exécution est **simulée** à partir de $\mathcal{L}$.

Modèle de sécurité

Comment évaluer la sécurité d'un schéma SSE dans ce modèle ?

Fonction de fuite $\mathcal{L}$

Elle désigne une liste d'informations **accessibles à l'attaquant**.

Preuve de sécurité

L'attaquant cherche à **distinguer** :

- un monde où l'exécution des protocoles est **normale** ;
- un monde où l'exécution est **simulée** à partir de $\mathcal{L}$.

Conclusion

Si l'attaquant **n'arrive pas à distinguer** ces deux exécutions :

$\Rightarrow$ la fonction de fuite est **exhaustive**.

Quel est l'impact pratique de la fonction de fuite ?

Sommaire

Schémas SSE
- Formalisation
- Modèle de sécurité

Classification des fuites d'information

Exploitation des fuites d'information
- Notre modèle d'attaque
- Cryptanalyses

Conclusion

Profil de fuite L4

Informations révélées

- **Mots-clefs partagés** entre les documents.
- **Ordre** des mots-clefs dans les documents.
- **Nombre total** de mots-clefs dans les documents.
- **Nombre d'apparitions** des mots-clefs dans les documents.

Profil de fuite L4

Informations révélées

- **Mots-clefs partagés** entre les documents.
- **Ordre** des mots-clefs dans les documents.
- **Nombre total** de mots-clefs dans les documents.
- **Nombre d'apparitions** des mots-clefs dans les documents.

D		EDB				D*
$d_1 = (w_1, w_3, w_2)$	$\Rightarrow$	$[w_1], [w_3], [w_2]$	$\rightarrow$	1	$\rightarrow$	d_1^*
$d_2 = (w_3, w_3)$		$[w_3], [w_3]$	$\rightarrow$	2	$\rightarrow$	d_2^*

où $[w] = F_K(w)$ avec F une PRF.

Exemples réels

Solutions commerciales : *CipherCloud* [Cip], *Skyhigh Networks* [Net].

Profil de fuite L3

Informations révélées

- **Mots-clefs partagés** entre les documents.
- **Ordre** des mots-clefs dans les documents.
- **Nombre** de mots-clefs **distincts** dans les documents.
- ~~**Nombre d'apparitions** des mots-clefs dans les documents.~~

Profil de fuite L3

Informations révélées

- **Mots-clefs partagés** entre les documents.
- **Ordre** des mots-clefs dans les documents.
- **Nombre** de mots-clefs **distincts** dans les documents.
- ~~**Nombre d'apparitions** des mots-clefs dans les documents.~~

D		EDB				D*
$d_1 = (w_1, w_3, w_2)$	$\Rightarrow$	$[w_1], [w_3], [w_2]$	$\rightarrow$	1	$\rightarrow$	d_1^*
$d_2 = (w_3, w_3)$		$[w_3], \cancel{[w_3]}$	$\rightarrow$	2	$\rightarrow$	d_2^*

où $[w] = F_K(w)$ avec F une PRF.

Exemples réels

Solution commerciale : *Bitglass* [Bit].

Profil de fuite L2

Informations révélées

- **Mots-clefs partagés** entre les documents.
- **Nombre** de mots-clefs **distincts** dans les documents.
- ~~**Ordre** des mots-clefs dans les documents~~

Profil de fuite L2

Informations révélées

- **Mots-clefs partagés** entre les documents.
- **Nombre** de mots-clefs **distincts** dans les documents.
- ~~**Ordre** des mots-clefs dans les documents~~

D		EDB				D*
$d_1 = (w_1, w_3, w_2)$	$\Rightarrow$	$\{[w_1], [w_2], [w_3]\}$	$\rightarrow$	1	$\rightarrow$	d_1^*
$d_2 = (w_3, w_3)$		$\{[w_3]\}$	$\rightarrow$	2	$\rightarrow$	d_2^*

où $[w] = F_K(w)$ avec F une PRF.

Profils de fuite L1/L0

Profil L1 : informations révélées

- Nombre de documents partageant un mot-clef.
- Documents partageant un mot-clef **quand celui-ci a été recherché**.

Exemple : [CJJ+13].

Profils de fuite L1/L0

Profil L1 : informations révélées

- Nombre de documents partageant un mot-clef.
- Documents partageant un mot-clef **quand celui-ci a été recherché**.

Exemple : [CJJ+13].

Profil L0 : informations révélées

- Nombre de couples document/mot-clef.
- Documents partageant un mot-clef **quand celui-ci a été recherché**.

Exemple : [KPR12].

Sommaire

Schémas SSE
- Formalisation
- Modèle de sécurité

Classification des fuites d'information

Exploitation des fuites d'information
- Notre modèle d'attaque
- Cryptanalyses

Conclusion

Modèle d'attaque

Type d'attaque

- **Attaque passive**, nous consultons la base de données chiffrée.

Hypothèses

- **Connaissance** d'un échantillon $\mathcal{I}$ de documents clairs.

Objectif

- **Reconstruction** du contenu des documents chiffrés.

Ensembles documentaires utilisés

Collections	*Commons*	*Enron*	*Gutenberg*	*Lucene*	*Wikipedia*
Contenu	mailing list	emails	livres	mailing list	encyclopédie
#D	28 997	490 369	21 602	58 884	3 607 727
#W	230 893	643 818	2 853 955	394 481	12 816 686

Déroulement d'une attaque

Première étape

- **Associer** les documents clairs connus de l'échantillon $\mathcal{I}$ aux documents chiffrés correspondant.

Déroulement d'une attaque

Première étape

- **Associer** les documents clairs connus de l'échantillon $\mathcal{I}$ aux documents chiffrés correspondant.

Deuxième étape

- **Associer** les mots-clefs clairs à leur version protégée pour chaque association entre document clair et document chiffré.

Déroulement d'une attaque

Première étape

- **Associer** les documents clairs connus de l'échantillon $\mathcal{I}$ aux documents chiffrés correspondant.

Deuxième étape

- **Associer** les mots-clefs clairs à leur version protégée pour chaque association entre document clair et document chiffré.

Troisième étape

- **Évaluer** l'efficacité avec le taux de mots-clefs recouverts dans $\mathcal{I}$ et le nombre de documents recouverts partiellement.

Déroulement d'une attaque

Association des documents clairs/chiffrés

Comment ?

- Nous cherchons une **mesure discrimante** sur les documents en utilisant les informations révélées par le profil de fuite considéré.

Déroulement d'une attaque

Association des documents clairs/chiffrés

Comment ?

- Nous cherchons une **mesure discrimante** sur les documents en utilisant les informations révélées par le profil de fuite considéré.

Association des mots-clefs clairs/protégés

Comment ?

- Se fait naturellement si **l'ordre des mots-clefs** est conservé.

Déroulement d'une attaque

Association des documents clairs/chiffrés

Comment ?

- Nous cherchons une **mesure discrimante** sur les documents en utilisant les informations révélées par le profil de fuite considéré.

Association des mots-clefs clairs/protégés

Comment ?

- Se fait naturellement si **l'ordre des mots-clefs** est conservé.

Taux de mots-clefs recouverts

Comment ?

- **Nous parcourons la base de données chiffrée**.

Cryptanalyse de schémas de profil L4

- Nous avons toutes les informations sur la structure des documents.
- Seul le sens des mots-clefs est perdu.

Calque d'un document

$$\mathsf{calque}_{\mathsf{L4}}(d) = (k : d[j] = w_k)_{1 \leqslant j \leqslant |d|}$$

Cryptanalyse de schémas de profil L4

Exemple

Nous supposons connaître trois documents :

- $d_1 = (w_1, w_3, w_2)$
- $d_2 = (w_4, w_4)$
- $d_3 = (w_5, w_6)$

EDB

$$\begin{array}{lll} [w_1], [w_3], [w_2] & \to 1 & \to \mathsf{calque}_{\mathsf{L4}}(d_1^*) = (1, 3, 2) \\ [w_4], [w_4] & \to 2 & \to \mathsf{calque}_{\mathsf{L4}}(d_2^*) = (4, 4) \\ [w_5], [w_6] & \to 3 & \to \mathsf{calque}_{\mathsf{L4}}(d_3^*) = (5, 6) \end{array}$$

Cryptanalyse de schémas de profil L4

Exemple

Nous supposons connaître trois documents :

- $d_1 = (w_1, w_3, w_2)$
- $d_2 = (w_4, w_4)$
- $d_3 = (w_5, w_6)$

EDB		
$[w_1], [w_3], [w_2]$	$\rightarrow 1$	$\rightarrow \mathsf{calque}_{\mathsf{L4}}(d_1^*) = (1, 3, 2)$
$[w_4], [w_4]$	$\rightarrow 2$	$\rightarrow \mathsf{calque}_{\mathsf{L4}}(d_2^*) = (4, 4)$
$[w_5], [w_6]$	$\rightarrow 3$	$\rightarrow \mathsf{calque}_{\mathsf{L4}}(d_3^*) = (5, 6)$

$$\mathsf{calque}_{\mathsf{L4}}(d_1) = (1, 3, 2) \Rightarrow d_1 \leftrightarrow d_1^*$$
$$\mathsf{calque}_{\mathsf{L4}}(d_2) = (4, 4) \Rightarrow d_2 \leftrightarrow d_2^*$$
$$\mathsf{calque}_{\mathsf{L4}}(d_3) = (5, 6) \Rightarrow d_3 \leftrightarrow d_3^*$$

Cryptanalyse de schémas de profil L4

Exemple

Nous supposons connaître trois documents :

- $d_1 = (w_1, w_3, w_2)$
- $d_2 = (w_4, w_4)$
- $d_3 = (w_5, w_6)$

EDB

$$\begin{array}{lll} [w_1], [w_3], [w_2] & \to 1 & \to \mathsf{calque}_{\mathsf{L4}}(d_1^*) = (1, 3, 2) \\ [w_4], [w_4] & \to 2 & \to \mathsf{calque}_{\mathsf{L4}}(d_2^*) = (4, 4) \\ [w_5], [w_6] & \to 3 & \to \mathsf{calque}_{\mathsf{L4}}(d_3^*) = (5, 6) \end{array}$$

$$\mathsf{calque}_{\mathsf{L4}}(d_1) = (1, 3, 2) \Rightarrow d_1 \leftrightarrow d_1^*$$
$$\mathsf{calque}_{\mathsf{L4}}(d_2) = (4, 4) \Rightarrow d_2 \leftrightarrow d_2^*$$
$$\mathsf{calque}_{\mathsf{L4}}(d_3) = (5, 6) \Rightarrow d_3 \leftrightarrow d_3^*$$

Cryptanalyse de schémas de profil L4

Exemple

Nous supposons connaître trois documents :

- $d_1 = (w_1, w_3, w_2)$
- $d_2 = (w_4, w_4)$
- $d_3 = (w_5, w_6)$

EDB

$$\begin{array}{lll} [w_1], [w_3], [w_2] & \to 1 & \to \mathsf{calque}_{\mathsf{L4}}(d_1^*) = (1, 3, 2) \\ [w_4], [w_4] & \to 2 & \to \mathsf{calque}_{\mathsf{L4}}(d_2^*) = (4, 4) \\ [w_5], [w_6] & \to 3 & \to \mathsf{calque}_{\mathsf{L4}}(d_3^*) = (5, 6) \end{array}$$

$$\mathsf{calque}_{\mathsf{L4}}(d_1) = (1, 3, 2) \Rightarrow d_1 \leftrightarrow d_1^*$$
$$\mathsf{calque}_{\mathsf{L4}}(d_2) = (4, 4) \Rightarrow d_2 \leftrightarrow d_2^*$$
$$\mathsf{calque}_{\mathsf{L4}}(d_3) = (5, 6) \Rightarrow d_3 \leftrightarrow d_3^*$$

Cryptanalyse de schémas de profil L4

Étape 3 : *Reconstruction du contenu des documents chiffrés*

Résultats sur Commons

#D	#Calque L4 unique
28 997	27 979 (96.4%)

%	#50%	#70%	#90%
1	28 837	27 136	7 631
2	28 899	27 931	11 503
3	28 918	28 224	14 182

1% de documents clairs connus ⇒ 27 136 (94%) des documents chiffrés reconstruits à au moins 70%.

Cryptanalyse de schémas de profil L4

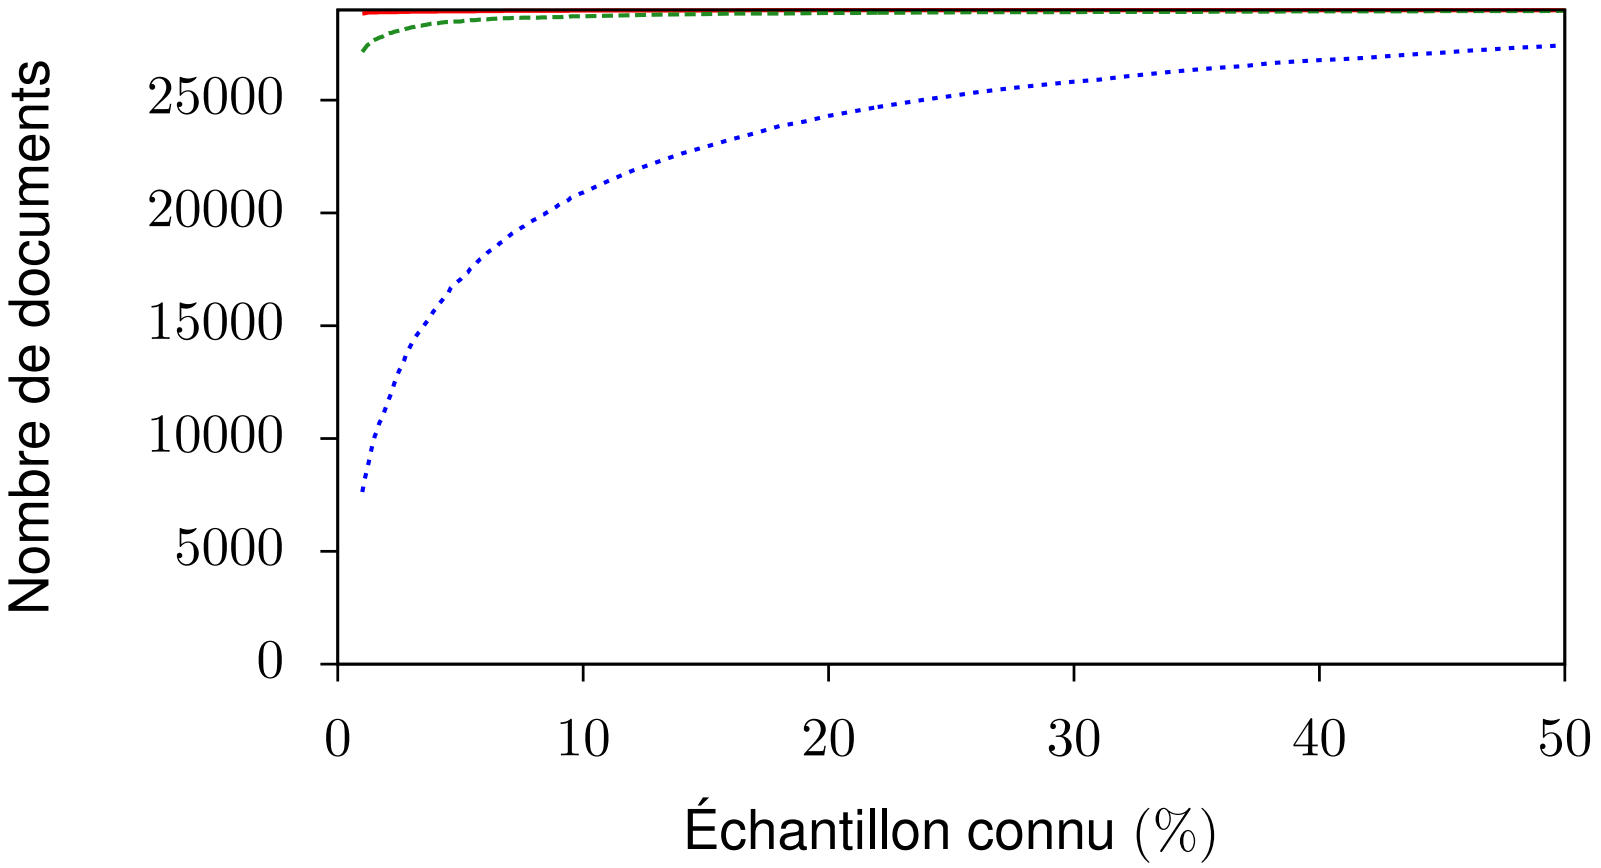

Documents recouverts au moins à 50%
Documents recouverts au moins à 70%
Documents recouverts au moins à 90%

Cryptanalyse de schémas de profil L3

- Nous n'avons plus l'information sur les répétitions des mots-clefs

  $\Rightarrow$ le *calque* ne fonctionne plus pour le profil L3.

Cryptanalyse de schémas de profil L3

- Nous n'avons plus l'information sur les répétitions des mots-clefs

  $\Rightarrow$ le *calque* ne fonctionne plus pour le profil L3.

- Similarité entre deux documents.

Cryptanalyse de schémas de profil L3

- Nous n'avons plus l'information sur les répétitions des mots-clefs

  $\Rightarrow$ le *calque* ne fonctionne plus pour le profil L3.

- Similarité entre deux documents.
- Nous souhaitons utiliser l'information sur l'**ordre des mots-clefs**

  $\Rightarrow$ *calque de l'intersection*.

Cryptanalyse de schémas de profil L3

Exemple

Soit $d_1 = (w_1, w_3, w_2, w_5)$ et $d_2 = (w_2, w_1, w_4)$.

Cryptanalyse de schémas de profil L3

Exemple

Soit $d_1 = (w_1, w_3, w_2, w_5)$ et $d_2 = (w_2, w_1, w_4)$.

$$\mathsf{W}_0 = \mathsf{W}_1 \cap \mathsf{W}_2 = \{w_1, w_2\}$$

Cryptanalyse de schémas de profil L3

Exemple

Soit $d_1 = (w_1, w_3, w_2, w_5)$ et $d_2 = (w_2, w_1, w_4)$.

$$\mathsf{W}_0 = \mathsf{W}_1 \cap \mathsf{W}_2 = \{w_1, w_2\}$$

$$d_1 \to (1, 0, 1, 0) \text{ et } d_2 \to (1, 1, 0)$$

Cryptanalyse de schémas de profil L3

Exemple

Soit $d_1 = (w_1, w_3, w_2, w_5)$ et $d_2 = (w_2, w_1, w_4)$.

$$\mathsf{W}_0 = \mathsf{W}_1 \cap \mathsf{W}_2 = \{w_1, w_2\}$$

$$d_1 \to (1, 0, 1, 0) \text{ et } d_2 \to (1, 1, 0)$$

$$\mathsf{sim}_{\mathsf{L3}}(d_1, d_2) = ((1, 0, 1, 0), (1, 1, 0))$$

Cryptanalyse de schémas de profil L3

Exemple

Soit $d_1 = (w_1, w_3, w_2, w_5)$ et $d_2 = (w_2, w_1, w_4)$.

$$\mathsf{W}_0 = \mathsf{W}_1 \cap \mathsf{W}_2 = \{w_1, w_2\}$$

$$d_1 \to (1, 0, 1, 0) \text{ et } d_2 \to (1, 1, 0)$$

$$\mathsf{sim}_{\mathsf{L3}}(d_1, d_2) = ((1, 0, 1, 0), (1, 1, 0))$$

Formalisation

$$\mathsf{sim}_{\mathsf{L3}}(d_1, d_2) = \left(\mathsf{bin}\left(\sum_{w \in \mathsf{W}_0} 2^{\mathsf{ord}(w, d_1)} \right), \mathsf{bin}\left(\sum_{w \in \mathsf{W}_0} 2^{\mathsf{ord}(w, d_2)} \right) \right)$$

avec :

- $\mathsf{W}_0 = \mathsf{W}_1 \cap \mathsf{W}_2$
- $\mathsf{bin}(v)$ l'écriture binaire de v
- $\mathsf{ord}(w, d)$ l'ordre d'apparition de w dans d

Cryptanalyse de schémas de profil L3

Étape 3 : *Reconstruction du contenu des documents chiffrés*

Résultats sur Commons

%	#50%	#70%	#90%
1	28 780	26 680	7 428
2	28 881	27 745	11 299
3	28 911	28 166	13 946

1% de documents clairs connus $\Rightarrow$ $26\ 680\ (92\%)$ des documents chiffrés reconstruits à au moins 70%.

Cryptanalyse de schémas de profil L3

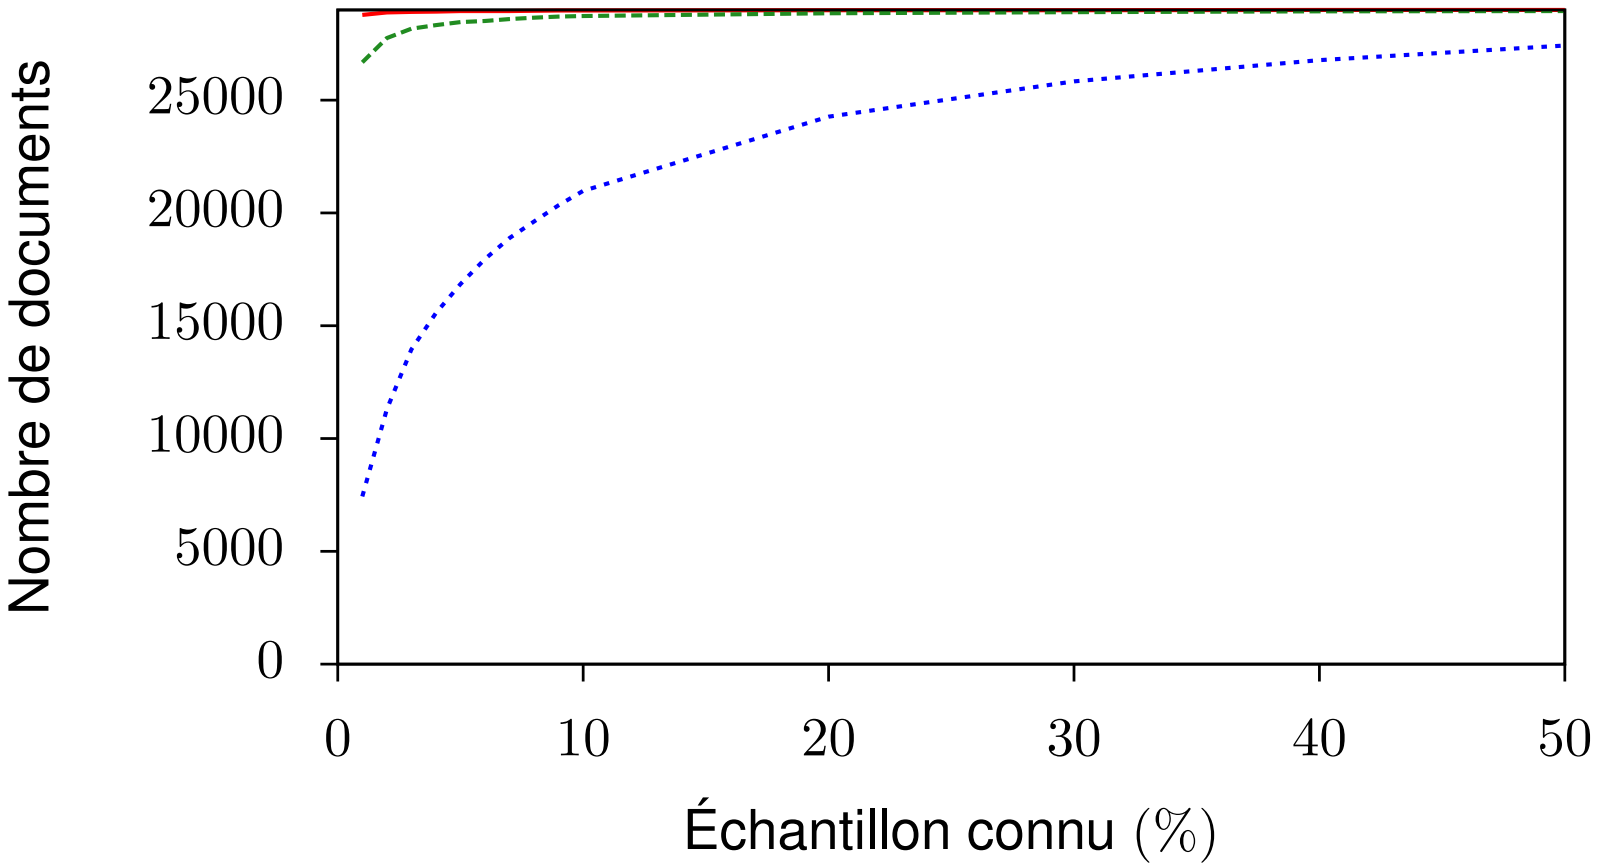

Documents recouverts au moins à 50%
Documents recouverts au moins à 70%
Documents recouverts au moins à 90%

Cryptanalyse de schémas de profil L2

Étape 1 : *Association des documents*

Que reste-t-il comme information ?

Mots-clefs partagés entre les documents.

Cryptanalyse de schémas de profil L2

Étape 1 : *Association des documents*

Que reste-t-il comme information ?

Mots-clefs partagés entre les documents.

Approche

- $m_0 := \mathsf{match}_{\mathsf{L2}}(d_0, d_1) = \#\left(\mathsf{W}_0 \cap \mathsf{W}_1\right)$
- Problème : $\mathsf{candidats}(d_0, d_1) \gg 1$

Cryptanalyse de schémas de profil L2

Étape 1 : *Association des documents*

Que reste-t-il comme information ?

Mots-clefs partagés entre les documents.

Approche

- $m_0 := \mathsf{match}_{\mathsf{L2}}(d_0, d_1) = \#\left(\mathsf{W}_0 \cap \mathsf{W}_1\right)$
- Problème : $\mathsf{candidats}(d_0, d_1) \gg 1$

Remarque

- Avec trois documents d_0, d_1 et d_2 :

$$\#(\mathsf{W}_1 \cap \mathsf{W}_2), \#(\mathsf{W}_1 \cap \mathsf{W}_3), \#(\mathsf{W}_2 \cap \mathsf{W}_3), \#(\mathsf{W}_1 \cap \mathsf{W}_2 \cap \mathsf{W}_3)$$

Cryptanalyse de schémas de profil L2

Étape 1 : *Association des documents*

Que reste-t-il comme information ?

Mots-clefs partagés entre les documents.

Approche

- $m_0 := \mathsf{match}_{\mathsf{L2}}(d_0, d_1) = \#\left(\mathsf{W}_0 \cap \mathsf{W}_1\right)$
- Problème : $\mathsf{candidats}(d_0, d_1) \gg 1$

Remarque

- Avec trois documents d_0, d_1 et d_2 :

$$\#(\mathsf{W}_1 \cap \mathsf{W}_2), \#(\mathsf{W}_1 \cap \mathsf{W}_3), \#(\mathsf{W}_2 \cap \mathsf{W}_3), \#(\mathsf{W}_1 \cap \mathsf{W}_2 \cap \mathsf{W}_3)$$

Idée

- Regarder les intersections de toutes les parties de $\mathcal{I}$.

Cryptanalyse de schémas de profil L2

Étape 1 : *Association des documents*

Utiliser les informations fournies par $\mathcal{I}$

- Trier les documents de $\mathcal{I}$ en fonction du nombre de candidats :
$$\#\mathsf{candidats}(d_1) \leqslant \#\mathsf{candidats}(d_2) \leqslant \dots$$
- Nous considérons le cardinal de la première intersection :
$$\#(\mathsf{W}_1 \cap \mathsf{W}_2)$$
- Nous agrégeons au fur et à mesure les documents de $\mathcal{I}$ en intégrant les nouvelles informations apportées par les différentes intersections.

Cryptanalyse de schémas de profil L2

Étape 1 : *Association des documents*

En pratique

Nous avons rapidement un match unique :

- *Commons* : **trois** documents pour un match unique.
- *Enron* : **quatre** documents pour un match unique.

Cryptanalyse de schémas de profil L2

Étape 2 : *Association des mots-clefs*

L'**ordre des mots-clefs** n'est plus conservé avec un profil L2

Cryptanalyse de schémas de profil L2

Étape 2 : *Association des mots-clefs*

L'**ordre des mots-clefs** n'est plus conservé avec un profil L2

Processus

- Soit $\mathcal{I}_0 \subseteq \mathcal{I}$, tel que $\forall d \in \mathcal{I}_0$, nous connaissons $d \leftrightarrow d^*$.
- Nous créons l'**index inversé** associé à $\mathcal{I}_0$, noté $\mathsf{inv}(\mathcal{I}_0)$.

Cryptanalyse de schémas de profil L2

Étape 2 : *Association des mots-clefs*

L'**ordre des mots-clefs** n'est plus conservé avec un profil L2

Processus

- Soit $\mathcal{I}_0 \subseteq \mathcal{I}$, tel que $\forall d \in \mathcal{I}_0$, nous connaissons $d \leftrightarrow d^*$.
- Nous créons l'**index inversé** associé à $\mathcal{I}_0$, noté $\mathsf{inv}(\mathcal{I}_0)$.

Exemple

Soit $\mathcal{I}_0 = \{d_1, d_2\}$ avec $d_1 = (w_2, w_1, w_2)$ et $d_2 = (w_2, w_3)$.
Nous avons alors

$\mathsf{inv}(\mathcal{I}_0)$	
w_1	d_1
w_2	d_1, d_2
w_3	d_2

Cryptanalyse de schémas de profil L2

Étape 2 : *Association des mots-clefs*

Processus

- Nous **ordonnons** $\mathsf{inv}(\mathcal{I}_0)$ en fonction du nombre de documents par ligne pour obtenir $\mathsf{inv}_{\mathsf{ord}}(\mathcal{I}_0)$.

Cryptanalyse de schémas de profil L2

Étape 2 : *Association des mots-clefs*

Processus

- Nous **ordonnons** $\mathsf{inv}(\mathcal{I}_0)$ en fonction du nombre de documents par ligne pour obtenir $\mathsf{inv}_{\mathsf{ord}}(\mathcal{I}_0)$.

Exemple

$\mathsf{inv}(\mathcal{I}_0)$	
w_1	d_1
w_2	d_1, d_2
w_3	d_2

$\Rightarrow$

$\mathsf{inv}_{\mathsf{ord}}(\mathcal{I}_0)$	
w_2	d_1, d_2
w_1	d_1
w_3	d_2

Cryptanalyse de schémas de profil L2

Étape 2 : *Association des mots-clefs*

Processus

- Nous considérons **les intersections des ensembles de mots-clefs protégés** dans l'ordre de $\mathsf{inv}_{\mathsf{ord}}(\mathcal{I}_0)$.

Cryptanalyse de schémas de profil L2

Étape 2 : *Association des mots-clefs*

Processus

- Nous considérons **les intersections des ensembles de mots-clefs protégés** dans l'ordre de $\mathsf{inv}_{\mathsf{ord}}(\mathcal{I}_0)$.

Exemple

EDB $+$

$\mathsf{inv}_{\mathsf{ord}}(\mathcal{I}_0)$	
w_2	d_1, d_2
w_1	d_1
w_3	d_2

Cryptanalyse de schémas de profil L2

Étape 2 : *Association des mots-clefs*

Processus

- Nous considérons **les intersections des ensembles de mots-clefs protégés** dans l'ordre de $\mathsf{inv}_{\mathsf{ord}}(\mathcal{I}_0)$.

Exemple

$$\mathsf{EDB} \quad + \quad \begin{array}{cc} \multicolumn{2}{c}{\mathsf{inv}_{\mathsf{ord}}(\mathcal{I}_0)} \\ \hline w_2 & d_1, d_2 \\ w_1 & d_1 \\ w_3 & d_2 \end{array} \qquad \mathsf{W}_1^* \cap \mathsf{W}_2^* = \{[w_2]\}$$

Cryptanalyse de schémas de profil L2

Étape 2 : *Association des mots-clefs*

Processus

- Nous considérons **les intersections des ensembles de mots-clefs protégés** dans l'ordre de $\mathsf{inv}_{\mathsf{ord}}(\mathcal{I}_0)$.

Exemple

EDB $+$

$\mathsf{inv}_{\mathsf{ord}}(\mathcal{I}_0)$	
w_2	d_1, d_2
w_1	d_1
w_3	d_2

$$\mathsf{W}_1^* \cap \mathsf{W}_2^* = \{[w_2]\} \Rightarrow w_2 \leftrightarrow [w_2]$$

Cryptanalyse de schémas de profil L2

Étape 2 : *Association des mots-clefs*

Processus

- Nous considérons **les intersections des ensembles de mots-clefs protégés** dans l'ordre de $\mathsf{inv}_{\mathsf{ord}}(\mathcal{I}_0)$.

Exemple

		$\mathsf{inv}_{\mathsf{ord}}(\mathcal{I}_0)$	
		w_2	d_1, d_2
EDB	$+$	w_1	d_1
		w_3	d_2

$\mathsf{W}_1^* \cap \mathsf{W}_2^* = \{[w_2]\} \Rightarrow w_2 \leftrightarrow [w_2]$

$\mathsf{W}_1^* = \{[w_1], [w_2]\}$

Cryptanalyse de schémas de profil L2

Étape 2 : *Association des mots-clefs*

Processus

- Nous considérons **les intersections des ensembles de mots-clefs protégés** dans l'ordre de $\mathsf{inv}_{\mathsf{ord}}(\mathcal{I}_0)$.

Exemple

		$\mathsf{inv}_{\mathsf{ord}}(\mathcal{I}_0)$	
		w_2	d_1, d_2
EDB	$+$	w_1	d_1
		w_3	d_2

$$\mathsf{W}_1^* \cap \mathsf{W}_2^* = \{[w_2]\} \Rightarrow w_2 \leftrightarrow [w_2]$$
$$\mathsf{W}_1^* = \{[w_1], [w_2]\} \Rightarrow w_1 \leftrightarrow [w_1]$$

Cryptanalyse de schémas de profil L2

Étape 2 : *Association des mots-clefs*

Processus

- Nous considérons **les intersections des ensembles de mots-clefs protégés** dans l'ordre de $\mathsf{inv}_{\mathsf{ord}}(\mathcal{I}_0)$.

Exemple

		$\mathsf{inv}_{\mathsf{ord}}(\mathcal{I}_0)$		
		w_2	d_1, d_2	$\mathsf{W}_1^* \cap \mathsf{W}_2^* = \{[w_2]\} \Rightarrow w_2 \leftrightarrow [w_2]$
EDB	$+$	w_1	d_1	$\mathsf{W}_1^* = \{[w_1], [w_2]\} \Rightarrow w_1 \leftrightarrow [w_1]$
		w_3	d_2	$\mathsf{W}_2^* = \{[w_2], [w_3]\}$

Cryptanalyse de schémas de profil L2

Étape 2 : *Association des mots-clefs*

Processus

- Nous considérons **les intersections des ensembles de mots-clefs protégés** dans l'ordre de $\mathsf{inv}_{\mathsf{ord}}(\mathcal{I}_0)$.

Exemple

		$\mathsf{inv}_{\mathsf{ord}}(\mathcal{I}_0)$		
		w_2	d_1, d_2	$\mathsf{W}_1^* \cap \mathsf{W}_2^* = \{[w_2]\} \Rightarrow w_2 \leftrightarrow [w_2]$
EDB	$+$	w_1	d_1	$\mathsf{W}_1^* = \{[w_1], [w_2]\} \Rightarrow w_1 \leftrightarrow [w_1]$
		w_3	d_2	$\mathsf{W}_2^* = \{[w_2], [w_3]\} \Rightarrow w_3 \leftrightarrow [w_3]$

Cryptanalyse de schémas de profil L2

Étape 3 : *Reconstruction du contenu des documents chiffrés*

Résultats sur Commons

%	W($\mathcal{I}_0$)	#50%	#70%	#90%
1	0.23	28 255	21 664	909
2	0.22	28 619	25 287	4 800
3	0.21	28 739	26 340	6 690

1% des documents clairs connus $\Rightarrow$ 21 664 (75%) des documents chiffrés reconstruits à au moins 70%.

Cryptanalyse de schémas de profil L2

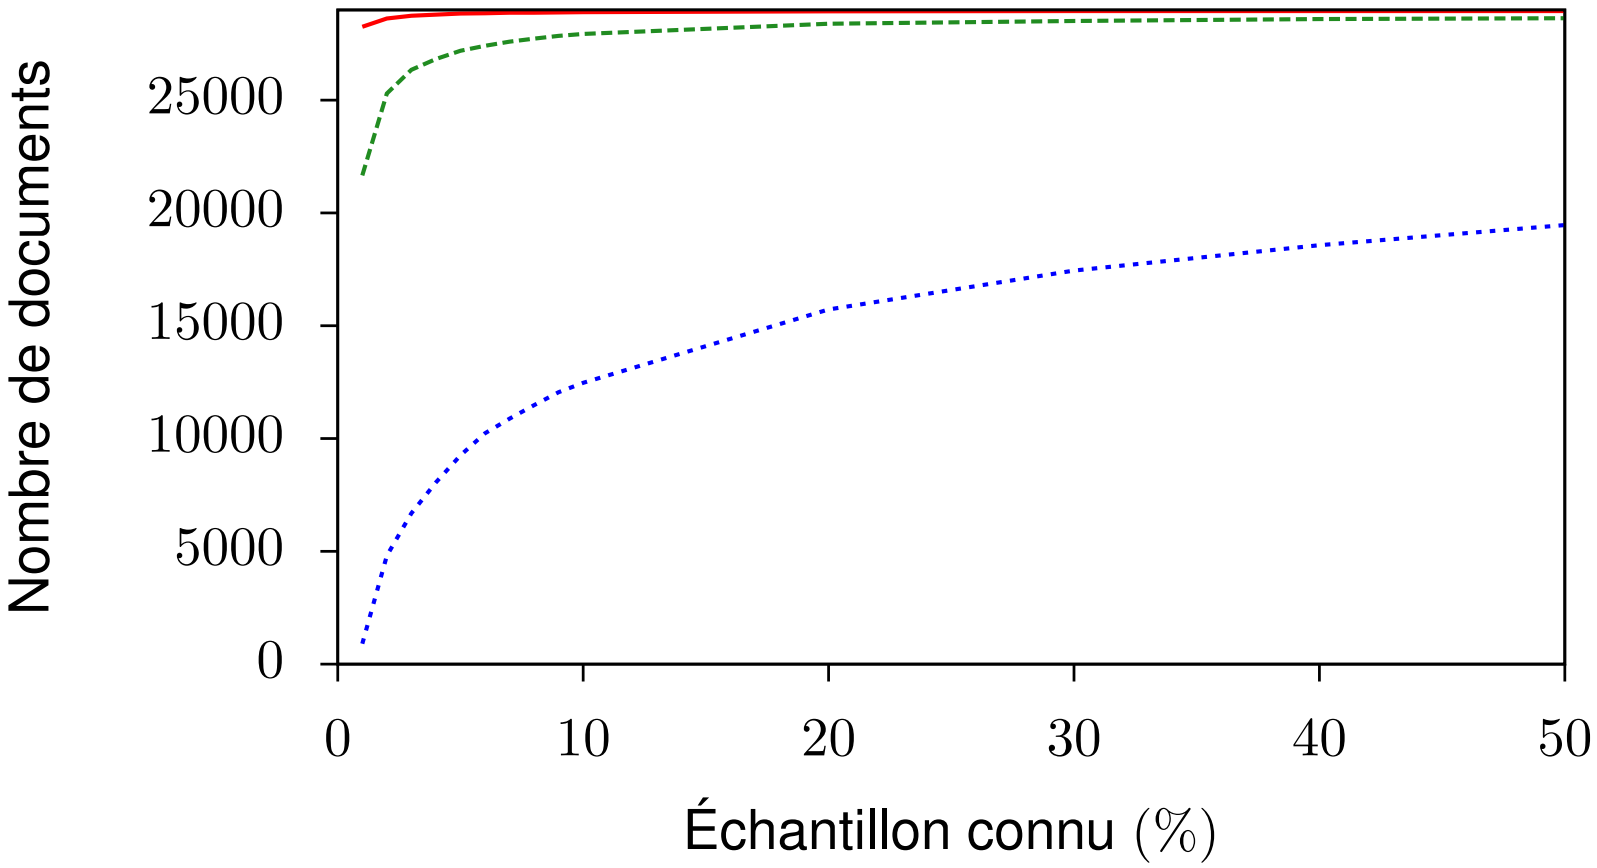

Documents recouverts au moins à 50%
Documents recouverts au moins à 70%
Documents recouverts au moins à 90%

Sommaire

Schémas SSE
- Formalisation
- Modèle de sécurité

Classification des fuites d'information

Exploitation des fuites d'information
- Notre modèle d'attaque
- Cryptanalyses

Conclusion

Conclusion

Nous avons **conçu et réalisé** des nouvelles attaques :

Application ✓

- Sur des ensembles documentaires réels (sauf *Wikipedia*).

Efficacité ✓

- Permettant de reconstruire efficacement le contenu des documents chiffrés sur les profils L4, L3 et L2.

Perspectives

Implémentation

- Passer le code à l'échelle (e.g. *Wikipedia*)

Amélioration des attaques

- Profils L4/L3 : améliorer l'association des mots-clefs à la marge.
- Profil L2 : deux idées pour améliorer l'association des mots-clefs.

Publier !

Merci

Questions ?

Bibliographie

- Bitglass, Security, compliance, and encryption, http://www.bitglass.com/solutions/salesforce-encryption.
- David Cash, Paul Grubbs, Jason Perry, and Thomas Ristenpart, Leakage-abuse attacks against searchable encryption, http://eprint.iacr.org/2016/718.
- CipherCloud, Cloud data encryption, http://www.ciphercloud.com/technologies/encryption/.
- David Cash, Stanislaw Jarecki, Charanjit S. Jutla, Hugo Krawczyk, Marcel-Catalin Rosu, and Michael Steiner, Highly-scalable searchable symmetric encryption with support for boolean queries, CRYPTO, 2013, pp. 353–373.
- Oded Goldreich, Secure multi-party computation, manuscript, preliminary version, 1998.
- Seny Kamara, Charalampos Papamanthou, and Tom Roeder, Dynamic searchable symmetric encryption, ACM Conference on Computer and Communications Security, 2012, pp. 965–976.
- Skyhigh Networks, Skyhigh for salesforce, https://www.skyhightnetworks.com/product/salesforce-encryption/.

Profil de fuite L1

D
$d_1 = (w_1, w_3, w_2)$
$d_2 = (w_3, w_3)$

$\Rightarrow$

inv(D)	
w_1	d_1
w_2	d_1
w_3	d_1, d_2

EDB				D*
$[w_1 \| 0]$	$\rightarrow$	$\mathsf{Enc}_{[w_1 \| 1]}(1)$	$\rightarrow$	d_1^*
$[w_2 \| 0]$	$\rightarrow$	$\mathsf{Enc}_{[w_2 \| 1]}(1)$	$\rightarrow$	d_1^*
$[w_3 \| 0]$	$\rightarrow$	$\mathsf{Enc}_{[w_3 \| 1]}(1), \mathsf{Enc}_{[w_3 \| 1]}(2)$	$\rightarrow$	d_1^*, d_2^*

Profil de fuite L1

Exemple

EDB	
$[w_1 \| 0]$	$\mathsf{Enc}_{[w_1 \| 1]}(1)$
$[w_2 \| 0]$	$\mathsf{Enc}_{[w_2 \| 1]}(1)$
$[w_3 \| 0]$	$\mathsf{Enc}_{[w_3 \| 1]}(1), \mathsf{Enc}_{[w_3 \| 1]}(2)$

- Le client réalise une recherche par le mot-clef w_1

Profil de fuite L1

Exemple

EDB	
$[w_1 \| 0]$	$\mathsf{Enc}_{[w_1 \| 1]}(1)$
$[w_2 \| 0]$	$\mathsf{Enc}_{[w_2 \| 1]}(1)$
$[w_3 \| 0]$	$\mathsf{Enc}_{[w_3 \| 1]}(1), \mathsf{Enc}_{[w_3 \| 1]}(2)$

- Le client réalise une recherche par le mot-clef w_1
- Le protocole envoie $[w_1 \| 0]$ et $[w_1 \| 1]$ au serveur.

Profil de fuite L1

Exemple

EDB	
$[w_1 \| 0]$	$\mathsf{Enc}_{[w_1 \| 1]}(1)$
$[w_2 \| 0]$	$\mathsf{Enc}_{[w_2 \| 1]}(1)$
$[w_3 \| 0]$	$\mathsf{Enc}_{[w_3 \| 1]}(1), \mathsf{Enc}_{[w_3 \| 1]}(2)$

- Le client réalise une recherche par le mot-clef w_1
- Le protocole envoie $[w_1 \| 0]$ et $[w_1 \| 1]$ au serveur.

Profil de fuite L1

Exemple

EDB	
$[w_1 \| 0]$	1
$[w_2 \| 0]$	$\mathsf{Enc}_{[w_2 \| 1]}(1)$
$[w_3 \| 0]$	$\mathsf{Enc}_{[w_3 \| 1]}(1), \mathsf{Enc}_{[w_3 \| 1]}(2)$

- Le client réalise une recherche par le mot-clef w_1
- Le protocole envoie $[w_1 \| 0]$ et $[w_1 \| 1]$ au serveur.

Profil de fuite L1

Exemple

EDB	
$[w_1 \| 0]$	1
$[w_2 \| 0]$	$\mathsf{Enc}_{[w_2 \| 1]}(1)$
$[w_3 \| 0]$	$\mathsf{Enc}_{[w_3 \| 1]}(1), \mathsf{Enc}_{[w_3 \| 1]}(2)$

- Le client réalise une recherche par le mot-clef w_1
- Le protocole envoie $[w_1 \| 0]$ et $[w_1 \| 1]$ au serveur.

Profil de fuite L1

Exemple

EDB	
$[w_1 \| 0]$	1
$[w_2 \| 0]$	$\mathsf{Enc}_{[w_2 \| 1]}(1)$
$[w_3 \| 0]$	$\mathsf{Enc}_{[w_3 \| 1]}(1), \mathsf{Enc}_{[w_3 \| 1]}(2)$

- Le client réalise une recherche par le mot-clef w_1
- Le protocole envoie $[w_1 \| 0]$ et $[w_1 \| 1]$ au serveur.
- Le client réalise une seconde recherche par le mot-clef w_2

Profil de fuite L1

Exemple

EDB	
$[w_1 \| 0]$	1
$[w_2 \| 0]$	1
$[w_3 \| 0]$	$\mathsf{Enc}_{[w_3 \| 1]}(1), \mathsf{Enc}_{[w_3 \| 1]}(2)$

- Le client réalise une recherche par le mot-clef w_1
- Le protocole envoie $[w_1 \| 0]$ et $[w_1 \| 1]$ au serveur.
- Le client réalise une seconde recherche par le mot-clef w_2

Profil de fuite L0

D
$d_1 = (w_1, w_3, w_2)$
$d_2 = (w_3, w_3)$

$\Rightarrow$

inv(D)	
w_1	d_1
w_2	d_1
w_3	d_1, d_2

EDB				D*
$[w_1 \| 0 \| c = 0]$	$\rightarrow$	$\mathsf{Enc}_{[w_1 \| 1 \| c=0]}(1)$	$\rightarrow$	d_1^*
$[w_2 \| 0 \| c = 0]$	$\rightarrow$	$\mathsf{Enc}_{[w_2 \| 1 \| c=0]}(1)$	$\rightarrow$	d_1^*
$[w_3 \| 0 \| c = 0]$	$\rightarrow$	$\mathsf{Enc}_{[w_3 \| 1 \| c=0]}(1)$	$\rightarrow$	d_1^*
$[w_3 \| 0 \| c = 1]$	$\rightarrow$	$\mathsf{Enc}_{[w_3 \| 1 \| c=1]}(2)$	$\rightarrow$	d_2^*