Mémoire de Master

Cryptanalyse des schémas de recherche sur données chiffrées

Matthieu Giraud

encadré par
Alexandre Anzala-Yamajako &
Olivier Bernard

sous la responsabilité pédagogique de
Gilles Zémor

Université de Bordeaux
Master Cryptologie et
Sécurité Informatique

Thales
Communications & Security
Laboratoire Chiffre

2 septembre 2016

Remerciements

Je tiens à remercier tout d'abord mes tuteurs Alexandre Anzala-Yamajako et Olivier Bernard pour l'encadrement exceptionnel qu'ils m'ont offert. Leur disponibilité, leur pédagogie ainsi que leur bonne humeur m'ont permis de faire de ces six mois de stage, une première expérience professionnelle inoubliable. Cela a été un vrai plaisir d'apprendre et de réfléchir à leurs côtés.

Mes remerciements s'adressent également à Éric Garrido pour m'avoir accueilli au sein de sa fabuleuse équipe. Alexandre, Ange, Aurélien, David, Émeline, Éric, Julia, Mickaël, Olivier B., Olivier O., Philippe, Renaud, Sylvain, Thomas P., Thomas R., Sonia, cela a été une joie de partager mon quotidien avec vous. Merci en particulier à Alexandre et David Lefranc pour la grande aide qu'ils m'ont apportée lors de mes recherches pour une thèse en cryptologie.

Je remercie également Christine Bachoc, Guilhem Castagnos, Emmanuel Fleury ainsi que Gilles Zémor pour l'enseignement de qualité qu'ils m'ont donné durant ces deux années de master passées à l'Université de Bordeaux. Je peux grâce à eux vivre pleinement ma passion.

Merci aussi à Assia, Benjamin, Laurent et Mélissa, stagiaires en même temps que moi à *Thales Communications & Security* pour les bons moments partagés avec eux. Et merci à Gérane Le Quentrec-Creven et à Pauline B.-S. pour la relecture de ce mémoire.

Enfin, je remercie de tout cœur mes parents, *Les Chevreuils* et Pauline pour le précieux soutien qu'ils m'ont apporté.

Introduction

À l'heure du tout numérique, le volume de nos données ne cesse de croître au fil des jours, nous conduisant parfois à les externaliser et à les confier à des opérateurs *Cloud*. Certaines de ces données, comme les documents juridiques, bancaires et médicaux, les brevets industriels ou plus simplement nos e-mails, peuvent être de nature sensible ou bien confidentielle nous obligeant à faire confiance à l'opérateur *Cloud*.

Afin de s'affranchir de la confiance accordée à l'opérateur *Cloud*, il est alors important de chiffrer ces données. La solution idéale à cette problématique repose sur le chiffrement dit homomorphe permettant d'effectuer tout type d'opérations sur des données chiffrées [Gen]. Malheureusement, elle reste actuellement de l'ordre de la recherche académique.

Une solution possible serait de chiffrer préalablement les données à externaliser. Par définition, elles seront inintelligibles par l'opérateur *Cloud* et donc inexploitables. Paradoxalement, si ces données chiffrées sont inintelligibles par l'opérateur *Cloud*, elles le sont aussi pour nous. Nous serons alors dans l'impossibilité de manipuler nos propres données. Bien sûr, nous pourrions penser qu'il nous suffirait de télécharger toutes ces données chiffrées puis de les déchiffrer localement. Nous pourrions ainsi réaliser les opérations voulues mais cela va à l'encontre des avantages attendus d'un opérateur *Cloud*. En effet, un des points forts d'un opérateur *Cloud* est de nous permettre de stocker une grande quantité de données en ligne et donc accessible de n'importe quel endroit. Cette solution est alors loin d'être efficace et même parfois impraticable si le volume de données sauvegardées est très important.

La solution actuelle est de déposer ces données en clair sur l'opérateur *Cloud*. Cela nous permet de les exploiter sans aucune contrainte. Il est alors légitime de s'inquiéter sur la confidentialité et la sécurité de ces données transmises. En effet, nous ne possédons aucun contrôle sur l'opérateur *Cloud*, ce dernier peut à tout moment consulter les données stockées, les dupliquer ou encore les transmettre à des tiers. De plus, nous n'avons aucune garantie que l'infrastructure de l'opérateur soit suffisamment sécurisée et qu'elle puisse ainsi empêcher toute intrusion malicieuse.

Une autre possibilité intéressante est de se restreindre à la fonctionnalité de recherche sur données chiffrées. En effet, une telle solution nous permet d'avoir nos données en sécurité sur l'opérateur *Cloud* tout en ayant la possiblité de récupérer les données chiffrées que nous cherchons spécifiquement. Cette solution est réalisable grâce aux schémas de recherches sur données chiffrées, dits SSE pour *Searchable Symmetric Encryption*. En effet, ces schémas, même s'ils ne permettent pas toutes les opérations que peut offrir le chiffrement homomorphe, sont d'une grande utilité pour les besoins actuels des données hébergées dans le *Cloud*.

Nous nous intéressons dans ce mémoire à la sécurité de ces schémas SSE. Nous commencerons par présenter leur fonctionnement puis étudierons leur sécurité en définissant différents modèles. En nous appuyant sur l'article de Cash *et al.* [CGPR16], nous définirons un ensemble de profils de fuite permettant de classifier les schémas SSE selon la quantité d'information qu'ils révèlent. Nous présenterons par la suite différentes attaques réalisées en fonction de ces profils de fuite et en donnerons les résultats.

Table des matières

1 Schémas de recherche sur données chiffrées **1**
1.1 Notations . . . 1
1.1.1 Mots-clefs et documents . . . 1
1.1.2 Recherches sur données chiffrées et historique . . . 2
1.1.3 Bases de données chiffrées . . . 2
1.2 Schémas de recherche statiques et dynamiques . . . 3
1.2.1 Schémas de recherche statiques . . . 3
1.2.2 Schémas de recherche dynamiques . . . 4

2 Sécurité des schémas de recherche **7**
2.1 Propriétés de sécurité d'un schéma de recherche . . . 7
2.1.1 Modèle de l'attaquant . . . 7
2.1.2 Les pouvoirs de l'attaquant . . . 7
2.1.3 Notions de sécurité d'un schéma de recherche . . . 8
2.2 Sécurité dans le modèle *Chosen-Query Attack* . . . 8
2.2.1 Propriété de sécurité $\mathsf{IND-CQA}$ . . . 8
2.2.2 Propriété de sécurité $\mathcal{L}-\mathsf{CQA}$ . . . 9
2.2.3 Lien entre les propriétés de sécurité $\mathsf{IND-CQA}$ et $\mathcal{L}-\mathsf{CQA}$ . . . 10
2.3 Sécurité dans le modèle *Adaptive Chosen-Query Attack* . . . 10
2.3.1 Propriété de sécurité $\mathsf{IND-CQA2}$ . . . 10
2.3.2 Propriété de sécurité $\mathcal{L}-\mathsf{CQA2}$ . . . 11
2.3.3 Lien entre les propriétés de sécurité $\mathsf{IND-CQA2}$ et $\mathcal{L}-\mathsf{CQA2}$ . . . 11

3 Classification des fuites d'information des schémas de recherche **13**
3.1 Profil de fuite $\mathsf{L4}$ . . . 13
3.1.1 Fonction de fuite associée . . . 13
3.1.2 Exemple d'un schéma de profil de fuite $\mathsf{L4}$ . . . 14
3.2 Profil de fuite $\mathsf{L3}$ . . . 15
3.2.1 Fonction de fuite associée . . . 15
3.2.2 Exemple d'un schéma de profil de fuite $\mathsf{L3}$ . . . 16
3.3 Profil de fuite $\mathsf{L2}$ . . . 18
3.3.1 Fonction de fuite associée . . . 18
3.3.2 Exemple d'un schéma de profil de fuite $\mathsf{L2}$ reposant sur un index . . . 18
3.3.3 Exemple d'un schéma de profil de fuite $\mathsf{L2}$ reposant sur un index inversé . . . 20
3.4 Profil de fuite $\mathsf{L1}$ . . . 21
3.4.1 Fonction de fuite associée . . . 21
3.4.2 Exemple d'un schéma de profil de fuite $\mathsf{L1}$ . . . 22
3.5 Profil de fuite $\mathsf{L0}$ . . . 23

3.5.1 Fonction de fuite associée 23
3.5.2 Exemple d'un schéma de profil de fuite L0 24

4 Exploitation des fuites pour la cryptanalyse des schémas de recherche 27
4.1 Modèles d'attaques 27
4.1.1 Attaque passive 27
4.1.2 Attaque active 27
4.1.3 Connaissances préalables du serveur 28
4.1.4 Objectifs des attaques 28
4.2 Mise en œuvre des attaques 29
4.2.1 Ensembles documentaires utilisés 29
4.2.2 Implémentation 29
4.2.3 Objectif et moyen des attaques réalisées 29
4.3 Cryptanalyse des schémas de recherche de profil L4 30
4.3.1 Approche par la longueur L4 des documents 30
4.3.2 Approche par le ratio L4 des documents 31
4.3.3 Approche par le calque L4 des documents 32
4.3.4 Résultats sur la cryptanalyse des schémas de profil L4 34
4.4 Cryptanalyse sur les schémas de recherche de profil L3 35
4.4.1 Approche par la longueur L3 d'un document 35
4.4.2 Similarité de deux documents 36
4.4.3 Similarité de deux documents en considérant l'ordre des mots-clefs 37
4.4.4 Algorithme de l'attaque sur le profil de fuite L3 38
4.4.5 Résultats sur la cryptanalyse des schémas de profil L3 38
4.5 Cryptanalyse sur les schémas de recherche de profil L2 40
4.5.1 Association entre documents clairs et documents chiffrés 40
4.5.2 Associer les mots-clefs avec un index inversé ordonné 42
4.5.3 Algorithme de l'attaque L2 44
4.5.4 Résultats sur la cryptanalyse des schémas le profil L2 44

A Résultats des attaques réalisées 49
A.1 Lecture des résultats 49
A.1.1 Les graphes 49
A.1.2 Les tableaux 49
A.2 Résultats sur la cryptanalyse des schémas de profil L4 50
A.2.1 Résultats sur l'ensemble documentaire *Lucene* 50
A.2.2 Résultats sur l'ensemble documentaire *Enron* 51
A.3 Résultats sur la cryptanalyse des schémas de profil L3 52
A.3.1 Résultats sur l'ensemble documentaire *Lucene* 52
A.3.2 Résultats sur l'ensemble documentaire *Gutenberg* 53
A.4 Résultats sur la cryptanalyse des schémas de profil L3 54
A.4.1 Résultats sur l'ensemble documentaire *Lucene* 54

Bibliographie 55

Chapitre 1
Schémas de recherche sur données chiffrées

Apparus dans les années 2000 avec les premières applications liées au *Cloud*, les schémas de recherche sur données chiffrées, ou plus simplement SSE pour *Searchable Symmetric Encryption*, permettent à un client de stocker et de rechercher de façon confidentielle et sécurisée ses données en externe. Nous présentons dans ce premier chapitre le fonctionnement de ces schémas.

§ 1.1 Notations

Nous noterons Pr la probabilité d'un événement, $|v|$ la longueur d'un vecteur v et $\#E$ le cardinal d'un ensemble E. Nous rappelons qu'une fonction $\mu : \mathbb{N} \to \mathbb{R}$ est dite *négligeable* en λ si pour tout polynôme p il existe $k \in \mathbb{N}$ tel que $\mu(\lambda) \leqslant 1/|p(\lambda)|$ pour $\lambda > k$.

1.1.1 Mots-clefs et documents

Soit $\mathsf{W} = \{w_1, \ldots, w_m\}$ un ensemble composé de m mots-clefs. Nous noterons $\mathsf{D} = \{d_1, \ldots, d_n\}$ un ensemble de n documents où chaque document d_i sera considéré comme une liste ordonnée de ℓ_i mots-clefs appartenant à W, c'est-à-dire $d_i = (w_1, \ldots, w_{\ell_i}) \in \mathsf{W}^{\ell_i}$. Nous définissons, pour un ensemble documentaire D, la valeur N correspondant au nombre total de couples où un couple est composé d'un document et d'un mot-clef qu'il contient. En d'autres termes, $N = \#\{(d, w) : d \in \mathsf{D}, w \in d\}$. Nous associons également à chaque document d_i l'ensemble noté W_i correspondant à l'ensemble des mots-clefs distincts qui le composent.

Nous représentons par $\mathsf{D}^* = \{d_1^*, \ldots, d_n^*\}$, l'ensemble des documents chiffrés où d_i^* est le chiffré du document d_i. De la même manière, nous notons par $\mathsf{W}^* = \{w_1^*, \ldots, w_m^*\}$, l'ensemble des mots-clefs de W transformés par une fonction à sens-unique où w_i^* est le transformé du mot-clef w_i.

Enfin, un document chiffré d_i^* sera représenté de façon unique par son identifiant i, il peut s'agir par exemple de son emplacement mémoire.

Remarque 1.1. *Pour simplifier les idées, nous considérons les documents comme des "documents textes". Il est toutefois important de garder à l'esprit que tout ce qui suit fonctionne avec des documents arbitraires (e.g. des fichiers images ou vidéos) tant qu'ils sont indexables.*

1.1.2 Recherches sur données chiffrées et historique

Soit D un ensemble de documents définis sur l'ensemble de mots-clefs W et $w \in \mathsf{W}$. Une recherche par le mot-clef w sur les documents chiffrés (les éléments de D^*) consiste à retrouver ceux dont les clairs contiennent w.

Définition 1.1 (Recherche sur un mot-clef)**.** *Soit* W *un ensemble de mots-clefs et* $w \in \mathsf{W}$*,* D *un ensemble de documents définis sur* W*. Nous définissons* $\mathsf{D}^*(w)$ *comme l'ensemble des identifiants des documents chiffrés de* D^* *dont les clairs contiennent le mot-clef* w*. C'est-à-dire*

$$\mathsf{D}^*(w) = \{i : w \in \mathsf{W}_i\}$$

Plus généralement, nous pouvons définir une recherche booléenne.

Définition 1.2 (Recherche booléenne)**.** *Soit* D *un ensemble de documents définis sur l'ensemble de mots-clefs* W*. Soit* $\bar{w} \subseteq \mathsf{W}$ *un sous-ensemble de mots-clefs et* ϕ *une formule booléenne sur* $\bar{w}$*. Nous définissons* $\mathsf{D}^*(\phi(\bar{w}))$ *comme l'ensemble des identifiants des documents chiffrés dont les clairs vérifient la formule booléenne* $\phi(\bar{w})$*. C'est-à-dire*

$$\mathsf{D}^*(\phi(\bar{w})) = \{i : \phi(\bar{w}) = \mathsf{True} \text{ pour } \mathsf{W}_i\}$$

Exemple 1.1. *Soit* $\mathsf{D} = \{d_1, d_2\}$ *un ensemble de deux documents définis sur* $\mathsf{W} = \{w_1, w_2, w_3\}$*, où* $d_1 = (w_1, w_2, w_3, w_1)$ *et* $d_2 = (w_1, w_2, w_2)$*. La recherche booléenne sur* $\bar{w} = (w_1, w_3)$ *définie par* $\phi(\cdot) = (\cdot \wedge \cdot)$ *nous donne alors* $\mathsf{D}^*(\phi(\bar{w})) = 1$*.*

Remarque 1.2. *Il est à noter que certains schémas* SSE *n'autorisent que les recherches par mot-clef unique. Dans ce cas, nous aurons simplement* $\bar{w} = \{w\}$ *et* $\phi(\bar{w}) = w$*. Afin de simplifier les notations et sauf mention du contraire, nous parlerons dans la suite de ce mémoire de recherche par mot-clef unique. Il est néanmoins important de se souvenir que certains schémas* SSE *autorisent des recherches booléennes tel le schéma de Cash et al. présenté dans* [*CJJ+13*]*.*

Nous définissons maintenant un historique comme la donnée d'un ensemble de documents et d'une liste de recherches appliquées à cet ensemble documentaire.

Définition 1.3 (Historique)**.** *Soit* $\mathsf{D} = \{d_1, \ldots, d_n\}$ *un ensemble de* n *documents définis sur* W*. Un historique de* q *recherches est un couple* $H = (\mathsf{D}, Q)$ *où* $Q = (w_1, \ldots, w_q)$ *avec* $w_i \in \mathsf{W}$ *pour* $1 \leqslant i \leqslant q$*.*

Exemple 1.2. *Soit* $\mathsf{D} = \{d_1, d_2\}$ *un ensemble de deux documents définis sur* $\mathsf{W} = \{w_1, w_2, w_3\}$*, où* $d_1 = (w_2, w_1, w_1)$ *et* $d_2 = (w_3, w_1)$*. Un historique de deux recherches peut être donc* $H = (\mathsf{D}, (w_1, w_3))$*.*

1.1.3 Bases de données chiffrées

Soit $\mathsf{D} = (d_1, \ldots, d_n)$ un ensemble de n documents définis sur W. Nous considérons la base de données chiffrée EDB associée à D comme une table liant l'ensemble des mots-clefs transformés et les identifiants des documents chiffrés. Deux représentations possibles pour une base de données sont présentées ci-dessous.

La première représentation repose sur un index. Nous faisons correspondre alors à l'entrée i de la table une liste de mots-clefs protégés (par exemple par une fonction pseudo-aléatoire) référençant d_i^*.

Exemple 1.3. *Soit deux documents* $d_1 = (w_1, w_3, w_2)$ *et* $d_2 = (w_2)$. *En utilisant la représentation de la base de données chiffrée qui repose sur un index, nous avons*

EDB
$1 \leftarrow (w_1^*, w_3^*, w_2^*)$
$2 \leftarrow (w_2^*)$

La seconde représentation repose sur un index inversé. Celle-ci, inversement à la représentation via un index, associe un mot-clef transformé w^* à un ensemble d'identifiants de documents chiffrés dont les clairs contiennent le mot-clef w, c'est-à-dire $\mathsf{D}^*(w)$.

Exemple 1.4. *Soit deux documents* $d_1 = (w_1, w_3, w_2)$ *et* $d_2 = (w_2)$. *En utilisant la représentation de la base de données chiffrée qui repose sur un index inversé, nous avons*

EDB
$w_1^* \rightarrow \{1\}$
$w_2^* \rightarrow \{1, 2\}$
$w_3^* \rightarrow \{1\}$

Remarque 1.3. *Dans la suite, quand cela ne sera pas précisé, nous parlerons indifféremment d'une base de données chiffrée reposant sur un index et d'une base de données chiffrée reposant sur un index inversé.*

§ 1.2 Schémas de recherche statiques et dynamiques

Nous rappelons qu'un schéma SSE fait intervenir un client et un serveur. Le client possède un ensemble de documents sensibles qu'il souhaite chiffrer puis exporter sur un serveur, de telle sorte que le serveur devra être capable d'effectuer des recherches sur ces données chiffrées et retourner les identifiants des documents chiffrés correspondant à la recherche initialement donnée par le client. Un schéma SSE peut être statique ou bien dynamique. Un schéma dynamique permet en plus d'initialiser une base de données chiffrée sur le serveur, de la mettre à jour en ajoutant et/ou en enlevant certains documents de manière consistante avec la fonction de recherche.

1.2.1 Schémas de recherche statiques

La première grande famille des schémas SSE est composée des schémas SSE dits statiques. Ceux-là sont très utiles pour archiver un ensemble de documents qui n'est pas appelé à être modifié par la suite.

Définition 1.4 (Schéma statique)**.** *Un schéma* SSE *statique* Π *de paramètre de sécurité* λ *est déterminé par un algorithme* $\Pi.\mathsf{Setup}$ *et un protocole* $\Pi.\mathsf{Search}$ *où*

- *L'algorithme* $\Pi.\mathsf{Setup}$ *prend en entrée le paramètre de sécurité* λ *et un ensemble de documents* D *définis sur* W. *Il génère une clef secrète* K_λ *destinée au client conduisant à la construction de la base de données chiffrée* EDB *et à l'ensemble de documents chiffrés* D^* *à destination du serveur.*

$$(K_\lambda, \mathsf{EDB}, \mathsf{D}^*) \leftarrow \Pi.\mathsf{Setup}(\lambda, \mathsf{D})$$

– *Le protocole* $\Pi.\mathsf{Search}$ *prend en entrée la clef secrète* K_λ*, un mot-clef* $w \in \mathsf{W}$ *et la base de données chiffrée* EDB*. La recherche par le mot-clef* w *sera protégée à l'aide de la clef* K_λ *puis envoyée au serveur hébergeant la base de données chiffrée. Le protocole se termine en retournant* $\mathsf{D}^*(w)$ *au client.*

$$\mathsf{D}^*(w) \leftarrow \Pi.\mathsf{Search}(K_\lambda, w, \mathsf{EDB})$$

Intuitivement, nous disons qu'un schéma SSE statique Π est correct si son protocole de recherche $\Pi.\mathsf{Search}$ retourne l'ensemble $\mathsf{D}^*(w)$ pour une recherche par le mot-clef w. Nous formalisons cette notion par la définition ci-dessous.

Définition 1.5 (Schéma de recherche statique correct)**.** *Soit* $\mathcal{A}$ *un algorithme polynomial et probabiliste, et* Π *un schéma* SSE *statique de paramètre de sécurité* λ*. Nous considérons l'expérience* $\mathsf{CorSta}^{\Pi}_{\mathcal{A}}(\lambda)$ *présentée dans la figure 1.1.*
Nous dirons que Π *est correct si pour tout algorithme polynomial et probabiliste* $\mathcal{A}$

$$\Pr\left[\mathsf{CorSta}^{\Pi}_{\mathcal{A}}(\lambda) = 1\right] \leqslant \mu(\lambda)$$

où μ *est une fonction négligeable en* λ*.*

$H \leftarrow \mathcal{A}(1^\lambda)$, $H = (\mathsf{D}, Q)$;
$(K_\lambda, \mathsf{EDB}, \mathsf{D}^*) \leftarrow \Pi.\mathsf{Setup}(\lambda, \mathsf{D})$;

pour $1 \leqslant i \leqslant q$ **faire**
  $\mathrm{v}[i] \leftarrow \Pi.\mathsf{Search}(K_\lambda, Q[i], \mathsf{EDB})$;

si $\mathrm{v} \neq (\mathsf{D}^*(Q[1]), \ldots, \mathsf{D}^*(Q[q]))$ **alors**
  retourner 1 ;
sinon
  retourner 0;

FIGURE 1.1 – Expérience $\mathsf{CorSta}^{\Pi}_{\mathcal{A}}(\lambda)$.

1.2.2 Schémas de recherche dynamiques

Contrairement aux schémas SSE statiques où le client ne peut qu'effectuer des recherches sur des données chiffrées, les schémas SSE dynamiques permettent également au serveur d'ajouter et de supprimer des documents à la base de données chiffrée et ainsi de la mettre à jour de manière consistante avec le protocole de recherche.

Définition 1.6 (Schéma de recherche dynamique)**.** *Un schéma* SSE *dynamique* Π *est défini de la même façon qu'un schéma* SSE *statique mais possède en plus un protocole* $\Pi.\mathsf{Update}$ *où*

Le protocole $\Pi.\mathsf{Update}$ *prend en entrée la base de données chiffrée* EDB*, la clef secrète du client* K_λ*, une opération de mise à jour* $\mathsf{op} \in \{\mathsf{add}, \mathsf{del}, \mathsf{edit}^+, \mathsf{edit}^-\}$*, un document* d *ainsi qu'un ensemble de mots-clefs* W_0*. L'opération de mise à jour, le document* d *et l'ensemble de mots-clefs* W_0 *seront protégés à l'aide de la clef secrète du client et envoyés au serveur. Le protocole met alors à jour la base de données chiffrée et retourne* EDB' *au serveur.*

$$\mathsf{EDB}' \leftarrow \mathsf{Update}(\mathsf{EDB}, K_\lambda, \mathsf{op}, d, \mathsf{W}_0)$$

Précisons l'effet des opérations.

- L'opération add associée au document d et à un ensemble de mots-clefs W_0 permet au serveur d'ajouter d^* à D^* et de le référencer aux mots-clefs protégés de W_0 dans la base de données chiffrée.
- De la même manière, l'opération del permet au serveur de supprimer d^* mais également de ne plus le référencer aux mots-clefs protégés W_0^* dans la base de données chiffrée.
- Les opérations edit^+ et edit^- permettent au serveur de modifier le référencement de d^* en lui associant les mots-clefs protégés de W_0 via l'opération edit^+ ou en les enlevant avec l'opération edit^-.

Remarque 1.4. *Si la définition d'un schéma dynamique correct est conceptuellement simple, sa formalisation est plus délicate puisqu'il faut s'assurer que dans le jeu de sécurité que tout se passe bien quelque soit l'enchaînement des recherches et des opération de mise à jour.*

Chapitre 2
Sécurité des schémas de recherche

Nous définissons dans ce chapitre la sécurité des schémas SSE. Nous y présentons également l'attaquant ainsi que ses différents pouvoirs d'attaque.

§ 2.1 Propriétés de sécurité d'un schéma de recherche

2.1.1 Modèle de l'attaquant

Nous nous plaçons dans le modèle défini pour la première fois par Goh dans [Goh03]. Dans ce modèle le serveur est supposé *honnête mais curieux*, c'est-à-dire que celui-ci respectera les protocoles mais essaiera d'apprendre le maximum d'information sur les documents qu'il héberge et sur les requêtes qu'il reçoit du client. Dans ce modèle, le serveur aura donc le rôle de l'attaquant.

Ce modèle est le meilleur pour définir la sécurité des schémas SSE. En effet, un attaquant extérieur ne peut qu'observer les requêtes du client envoyées au serveur et les réponses du serveur retournées au client. Au contraire, un serveur honnête mais curieux, en plus de recevoir les requêtes du client et de lui envoyer les réponses associées, peut également observer la base de données chiffrée qu'il héberge et les accès sur celle-ci.

Afin d'expliciter les informations accessibles au serveur, nous associons à chaque schéma SSE une fonction de fuite. Son rôle est de représenter de façon exhaustive les informations que le schéma révèle au serveur.

2.1.2 Les pouvoirs de l'attaquant

Mise à part l'observation de la base de données chiffrée qu'il héberge, le serveur peut interagir avec celle-ci en envoyant lui-même des requêtes. Elles seront alors soit fausses et non traitées, n'apportant aucune information, soit correctes et alors le serveur pourra déduire des informations sur les documents qu'il héberge et sur les requêtes qu'il reçoit du client.

Il est important ici de remarquer que le serveur peut ou non considérer les résultats de ses précédentes requêtes avant d'en générer une nouvelle. Si tel est le cas, nous dirons que l'attaquant est adaptatif. Si au contraire, les résultats des requêtes précédentes n'est pas pris en compte pour en générer une nouvelle, nous dirons que l'attaquant est non-adaptatif.

La distinction entre un attaquant adaptatif et un attaquant non-adaptatif est importante puisqu'elle engendre des garanties de sécurité différentes. Bien entendu, si un

schéma SSE est sûr contre un attaquant adaptatif, il l'est également contre un attaquant non-adaptatif. Qui peut le plus, peut le moins...

Dans le modèle de sécurité dit CQA, pour *Chosen-Query Attack*, l'attaquant est non-adaptatif. Il consulte donc les résultats de ses requêtes uniquement à la fin de son attaque. Dans le modèle de sécurité dit CQA2, pour *Adaptive Chosen-Query Attack*, l'attaquant est adaptatif. Il est donc autorisé à consulter les résultats de ses requêtes précédentes avant d'en générer une nouvelle. Nous pouvons remarquer que le modèle de sécurité CQA2 est le mieux adapté aux capacités réelles d'un attaquant puisque ce dernier peut choisir chaque requête après avoir obtenu le résultat de la précédente.

2.1.3 Notions de sécurité d'un schéma de recherche

Intuitivement, nous pouvons dire qu'un schéma SSE est sûr selon deux critères. Tout d'abord, un schéma SSE est sûr si celui-ci génère une base de données chiffrée révélant un minimum d'information au serveur sur l'ensemble des documents. Deuxièmement, un schéma SSE est sûr si les requêtes effectuées par le client n'indiquent au serveur que les identifiants concernés par celles-ci. Il est en effet impossible de cacher cette information puisqu'elle correspond à la nature même d'un schéma SSE. Nous formalisons ce minimum d'information révélé au serveur par le schéma SSE avec la notion de trace d'un historique.

Définition 2.1 (Trace d'un historique)**.** *Soit* $\mathsf{D} = (d_1, \ldots, d_n)$ *une collection de* n *documents définis sur l'ensemble de mots-clefs* W*. Soit* $H = (\mathsf{D}, Q)$ *un historique de* q *requêtes. La trace induite par l'historique* H *est l'ensemble* $\mathrm{Tr}(H) = (N, \mathsf{D}^*(w_1), \ldots, \mathsf{D}^*(w_q))$*.*

La première notion de sécurité que nous présentons pour les schémas SSE est la sécurité au sens de l'indistinguabilité selon le point de vue de l'attaquant, notée IND. Pour cela, nous supposons que l'attaquant choisit deux historiques de même trace, $H_1(\mathsf{D}_1, Q_1)$ et $H_2 = (\mathsf{D}_2, Q_2)$. Nous choisissons alors un de ces historiques au hasard et en générons la base de données chiffrée. Nous réalisons ensuite sur celle-ci les recherches associées à l'historique choisit. Nous la base de données chiffrée et les résultats des recherches à l'attaquant. La sécurité IND d'un schéma SSE signifie que l'attaquant ne peut pas déterminer l'historique choisit malgré le comportement de celles-ci face aux requêtes réalisées.

La seconde notion de sécurité que nous présentons a été définie par Curtmola *et al.* dans [CGKO06] et par Kamara *et al.* dans [KPR12], elle introduit une fonction de fuite $\mathcal{L}$ propre au schéma SSE. Cette fonction formalise de façon exhaustive les informations révélées par le schéma. La notion de sécurité présentée ici est la sécurité $\mathcal{L}$-sémantique, notée simplement $\mathcal{L}$. La sécurité $\mathcal{L}$ d'un schéma SSE signifie qu'aucune autre information que ce qui est formalisé par la fonction de fuite du schéma n'est accessible à l'attaquant. Il ne peut donc pas différencier l'exécution réelle des protocoles à celle simulée à partir de la fonction de fuite associée au schéma. Nous cherchons donc avec cette notion de sécurité à quantifier précisément les fuites associées à un schéma.

§ 2.2 Sécurité dans le modèle *Chosen-Query Attack*

2.2.1 Propriété de sécurité IND − CQA

Nous présentons ici la propriété de sécurité IND-CQA d'un schéma SSE statique. Basée sur des requêtes non-adaptatives, cette propriété de sécurité suppose que l'adversaire génère l'ensemble de ses requêtes avant le début de l'attaque.

$(H_0, H_1) \leftarrow \mathcal{A}_1(1^\lambda)$ tels que $\mathrm{Tr}(H_0) = \mathrm{Tr}(H_1)$;
$b \leftarrow \$\{0,1\}$;
$(K_\lambda, \mathsf{EDB}, \mathsf{D}^*) \leftarrow \mathsf{Setup}(\lambda, \mathsf{D}_b)$;
pour $1 \leqslant i \leqslant |Q_b|$ **faire**
  $\mathrm{v}[i] \leftarrow \mathsf{Search}(K_\lambda, Q_b[i], \mathsf{EDB})$;
$b' \leftarrow \mathcal{A}_2(\mathsf{EDB}, \mathrm{v})$;
si $b' = b$ **alors**
  retourner 1 ;
sinon
  retourner 0 ;

FIGURE 2.1 – Jeu de sécurité $\mathsf{Ind}^{\Pi}_{\mathcal{A}}(\lambda)$.

Définition 2.2 (Schéma statique $\mathsf{IND-CQA}$ sûr)**.** *Soit* $\Pi = (\mathsf{Setup}, \mathsf{Search})$ *un schéma* SSE *statique de paramètre de sécurité* λ*. Nous représentons l'adversaire par un algorithme polynomial et probabiliste* $\mathcal{A} = (\mathcal{A}_1, \mathcal{A}_2)$*. Nous considérons le jeu de sécurité* $\mathsf{Ind}^{\Pi}_{\mathcal{A}}(\lambda)$ *présentée dans 2.1.*
Nous dirons que le schéma Π *est* $\mathsf{IND-CQA}$ *sûr si pour tout adversaire polynomial et probabiliste* $\mathcal{A} = (\mathcal{A}_1, \mathcal{A}_2)$

$$\Pr\left[\mathsf{Ind}^{\Pi}_{\mathcal{A}}(\lambda) = 1\right] - 1/2 \leqslant \mu(\lambda)$$

où μ *est une fonction négligeable en* λ*.*

Remarque 2.1. *La propriété de sécurité* $\mathsf{IND-CQA}$ *est analogue pour un schéma* SSE *dynamique. La différence réside dans le fait que les vecteurs de requêtes* Q_0 *et* Q_1 *peuvent également contenir des requêtes de mise à jour.*

2.2.2 Propriété de sécurité $\mathcal{L}-\mathsf{CQA}$

La propriété de sécurité $\mathcal{L}$-sémantique compare l'exécution réelle des protocoles à celle simulée par la fonction de fuite $\mathcal{L}$ du schéma SSE considéré. L'exécution réelle sera représentée par le jeu de sécurité $\mathsf{Real}^{\Pi}_{\mathcal{A}}(\lambda)$ alors que l'exécution simulée sera représentée par le jeu de sécurité $\mathsf{Ideal}^{\Pi}_{\mathcal{A},\mathcal{S}}(\lambda)$.

$H = (\mathsf{D}, Q) \leftarrow \mathcal{A}_1(1^\lambda)$;
$(K_\lambda, \mathsf{EDB}, \mathsf{D}^*) \leftarrow \mathsf{Setup}(\lambda, \mathsf{D})$;
pour $1 \leqslant i \leqslant \#Q$ **faire**
  $\mathrm{v}[i] \leftarrow \mathsf{Search}(K_\lambda, Q[i], \mathsf{EDB})$;
$b' \leftarrow \mathcal{A}_2(\mathsf{EDB}, \mathrm{v})$;
retourner b'

FIGURE 2.2 – Jeu de sécurité $\mathsf{Real}^{\Pi}_{\mathcal{A}}(\lambda)$.

$H = (\mathsf{D}, Q) \leftarrow \mathcal{A}_1(1^\lambda)$;
$\mathsf{EDB} \leftarrow \mathcal{S}(\mathcal{L}(\mathsf{D}))$;
pour $1 \leqslant i \leqslant \#Q$ **faire**
  $\mathrm{v}[i] \leftarrow \mathcal{S}(\mathcal{L}(\mathsf{D}, Q[i]))$;
$b' \leftarrow \mathcal{A}_2(\mathsf{EDB}, \mathrm{v})$;
retourner b' ;

FIGURE 2.3 – Jeu de sécurité $\mathsf{Sim}^{\Pi}_{\mathcal{A}}(\lambda)$.

Définition 2.3 (Schéma statique $\mathcal{L}-\mathsf{CQA}$ sûr)**.** *Soit* $\Pi = (\mathsf{Setup}, \mathsf{Search})$ *un schéma* SSE *statique de paramètre de sécurité* λ *et soit* $\mathcal{L}$ *sa fonction de fuite associée. Soit un adversaire polynomial et probabiliste* $\mathcal{A} = (\mathcal{A}_1, \mathcal{A}_2)$ *et un simulateur probabiliste et polynomial*

$\mathcal{S}$. Nous considérons le jeu de sécurité $\mathsf{Real}^{\Pi}_{\mathcal{A}}(\lambda)$ présent dans la figure 2.2 et le jeu de sécurité $\mathsf{Sim}^{\Pi}_{\mathcal{A},\mathcal{S}}(\lambda)$ présent dans la figure 2.3.
Nous dirons que le schéma Π est $\mathcal{L}-\mathsf{CQA}$ sûr si pour tout adversaire polynomial et probabiliste $\mathcal{A}$, il existe un algorithme $\mathcal{S}$ tel que

$$\Pr\left[\mathsf{Real}^{\Pi}_{\mathcal{A}}(\lambda) \neq \mathsf{Sim}^{\Pi}_{\mathcal{A},\mathcal{S}}(\lambda)\right] \leqslant \mu(\lambda)$$

où μ est une fonction négligeable en λ.

Remarque 2.2. *La propriété de sécurité $\mathcal{L}-\mathsf{CQA}$ est analogue pour un schéma* SSE *dynamique. La différence réside dans le fait que le vecteur de requêtes Q peut également contenir des requêtes de mise à jour.*

2.2.3 Lien entre les propriétés de sécurité $\mathsf{IND}-\mathsf{CQA}$ et $\mathcal{L}-\mathsf{CQA}$

Bien que ces propriétés soient différentes, il peut arriver parfois qu'elles soient équivalentes. Précisons bien que ceci n'est pas vrai en général.

Considérons par exemple le schéma de Curtmola *et al.* présenté dans [CGKO06] et que nous notons ici Π_{Curt}. Nous avons alors le théorème suivant.

Théorème 2.1 (Théorème sur le schéma Π_{Curt})**.** *Le schéma* SSE *Π_{Curt} associé à la fonction de fuite $\mathcal{L}_{Curt}$ est $\mathsf{IND}-\mathsf{CQA}$ sûr si, et seulement si, il est $\mathcal{L}_{Curt}-\mathsf{CQA}$ sûr.*

Démonstration. Nous invitons le lecteur à consulter la preuve de ce théorème présente dans l'article de Curtmola *et al.* [CGKO06]. □

§ 2.3 Sécurité dans le modèle *Adaptive Chosen-Query Attack*

2.3.1 Propriété de sécurité $\mathsf{IND}-\mathsf{CQA2}$

Nous présentons ici la propriété de sécurité $\mathsf{IND}-\mathsf{CQA2}$ d'un schéma SSE statique. Basée sur des requêtes adaptatives, cette sécurité suppose que l'adversaire génère ses requêtes en fonction des résultats obtenus précédemment.

$(\mathsf{D}_0, \mathsf{D}_1) \leftarrow \mathcal{A}_0(1^\lambda)$ tels que $|d_{0_i}| = |d_{1_i}|$;
$b \leftarrow \$\{0,1\}$;
$(K_\lambda, \mathsf{EDB}_b, \mathsf{D}^*_b) \leftarrow \mathsf{Setup}(\lambda, \mathsf{D}_b)$;
$(w_{0,1}, w_{1,1}) \leftarrow \mathcal{A}_1(\mathsf{EDB}_b)$ tels que $\#\mathsf{D}^*_0(w_{0,1}) = \#\mathsf{D}^*_1(w_{1,1})$;
$\mathrm{v}[1] \leftarrow \mathsf{Search}(K_\lambda, w_{b,1}, \mathsf{EDB}_b)$;
pour $2 \leqslant i \leqslant q$ **faire**
  $\mathrm{v}[i] \leftarrow \mathsf{Search}(K_\lambda, w_{b,i}, \mathsf{EDB}_b)$ avec $(w_{0,i}, w_{1,i}) \leftarrow \mathcal{A}_i(\mathsf{EDB}_b, w_{b,1}, \ldots, w_{b,i-1})$ tels que $\#\mathsf{D}^*_0(w_{0,i}) = \#\mathsf{D}^*_1(w_{1,i})$;
$b' \leftarrow \mathcal{A}_{q+1}(\mathsf{EDB}_b, \mathrm{v})$;
si $b' = b$ **alors**
  retourner 1 ;
sinon
  retourner 0 ;

FIGURE 2.4 – Jeu de sécurité $\mathsf{Ind}^{\Pi}_{\mathcal{A}}(\lambda)$.

Définition 2.4 (Schéma statique $\mathsf{IND}-\mathsf{CQA2}$ sûr)**.** *Soit* $\Pi = (\mathsf{Setup}, \mathsf{Search})$ *un schéma* SSE *statique de paramètre de sécurité* λ*. Nous représentons l'adversaire par un algorithme polynomial et probabiliste* $\mathcal{A} = (\mathcal{A}_0, \ldots, \mathcal{A}_{q+1})$ *tel que* $q \in \mathbb{N}$ *et nous considérons le jeu de sécurité présenté dans la figure 2.4.*
Nous dirons que le schéma Π *est* $\mathsf{IND}-\mathsf{CQA2}$ *sûr si pour tout adversaire polynomial et probabiliste* $\mathcal{A}$*, on a*

$$\Pr\left[\mathsf{Ind}^{\Pi}_{\mathcal{A}}(\lambda) = 1\right] - 1/2 \leqslant \mu(\lambda)$$

où μ *est une fonction négligeable en* λ*.*

Remarque 2.3. *La sécurité* $\mathsf{IND}-\mathsf{CQA2}$ *est analogue pour un schéma* SSE *dynamique. La différence réside dans le fait que les requêtes peuvent être des requêtes de mise à jour.*

2.3.2 Propriété de sécurité $\mathcal{L}-\mathsf{CQA2}$

Nous présentons ici la propriété de sécurité $\mathcal{L}-\mathsf{CQA2}$ d'un schéma SSE statique. Basée sur des requêtes adaptatives, cette sécurité suppose que l'adversaire génère ses requêtes en fonction des résultats obtenus précédemment.

$\mathsf{D} \leftarrow \mathcal{A}_0(1^\lambda)$;
$(K_\lambda, \mathsf{EDB}, \mathsf{D}^*) \leftarrow \mathsf{Setup}(\lambda, \mathsf{D})$;
$w_1 \leftarrow \mathcal{A}_1(\mathsf{EDB})$;
$\mathrm{v}[1] \leftarrow \mathsf{Search}(K_\lambda, w_1, \mathsf{EDB})$;
pour $2 \leqslant i \leqslant q$ **faire**
  $w_i \leftarrow \mathcal{A}_i(\mathsf{EDB}, \mathrm{v}[1], \ldots, \mathrm{v}[i-1])$;
  $\mathrm{v}[i] \leftarrow \mathsf{Search}(K_\lambda, w_i, \mathsf{EDB})$;
$b' \leftarrow \mathcal{A}_{q+1}(\mathsf{EDB}, \mathrm{v})$;

FIGURE 2.5 – Jeu de sécurité $\mathsf{Real}^{\Pi}_{\mathcal{A}}(\lambda)$.

$\mathsf{D} \leftarrow \mathcal{A}_0(1^\lambda)$;
$\mathsf{EDB} \leftarrow \mathcal{S}_0(\mathcal{L}(\mathsf{D}))$;
$w_1 \leftarrow \mathcal{A}_1(\mathsf{EDB})$;
$\mathrm{v}[1] \leftarrow \mathcal{S}_1(\mathcal{L}(\mathsf{D}, w_1))$;
pour $2 \leqslant i \leqslant q$ **faire**
  $w_i \leftarrow \mathcal{A}_i(\mathsf{EDB}, \mathrm{v}[1], \ldots, \mathrm{v}[i-1])$,
  $\mathrm{v}[i] \leftarrow \mathcal{S}_i(\mathcal{L}(\mathsf{D}, w_1, \ldots, w_i))$;
$b' \leftarrow \mathcal{A}_{q+1}(\mathsf{EDB}, \mathrm{v})$;

FIGURE 2.6 – Jeu de sécurité $\mathsf{Sim}^{\Pi}_{\mathcal{A}}(\lambda)$.

Définition 2.5 (Schéma statique $\mathcal{L}-\mathsf{CQA2}$ sûr)**.** *Soit* $\Pi = (\mathsf{Setup}, \mathsf{Search})$ *un schéma* SSE *statique de paramètre de sécurité* λ *et soit* $\mathcal{L}$ *sa fonction de fuite associée. Soit un adversaire représenté par l'algorithme polynomial et probabiliste* $\mathcal{A} = (\mathcal{A}_0, \ldots, \mathcal{A}_{q+1})$ *tel que* $q \in \mathbb{N}$ *et un simulateur représenté par l'algorithme probabiliste et polynomial* $\mathcal{S} = (\mathcal{S}_0, \ldots, \mathcal{S}_q)$*. Nous considérons le jeu de sécurité* $\mathsf{Real}^{\Pi}_{\mathcal{A}}(\lambda)$ *présenté dans la figure 2.5 ainsi que le jeu de sécurité* $\mathsf{Sim}^{\Pi}_{\mathcal{A},\mathcal{S}}(\lambda)$ *présénté dans la figure 2.6.*
Nous dirons que le schéma Π *est* $\mathcal{L}-\mathsf{CQA2}$ *sûr si pour tout adversaire polynomial et probabiliste* $\mathcal{A}$*, il existe un algorithme* $\mathcal{S}$ *tel que*

$$\Pr\left[\mathsf{Real}^{\Pi}_{\mathcal{A}}(\lambda) \neq \mathsf{Sim}^{\Pi}_{\mathcal{A},\mathcal{S}}(\lambda)\right] \leqslant \mu(\lambda)$$

où μ *est une fonction négligeable en* λ*.*

Remarque 2.4. *La sécurité* $\mathcal{L}-\mathsf{CQA2}$ *est analogue pour un schéma* SSE *dynamique. La différence réside dans le fait que les requêtes peuvent être des requêtes de mise à jour.*

2.3.3 Lien entre les propriétés de sécurité $\mathsf{IND}-\mathsf{CQA2}$ et $\mathcal{L}-\mathsf{CQA2}$

Nous reprenons l'exemple du schéma de Curtmola *et al.* présenté dans [CGKO06] et que nous notons ici Π_{Curt}. Nous avons alors le théorème suivant.

Théorème 2.2 (Théorème sur le schéma Π_{Curt})**.** *Si un schéma* SSE Π_{Curt} *de fonction de fuite* $\mathcal{L}_{Curt}$ *est* $\mathcal{L}_{Curt}-\mathsf{CQA2}$ *sûr, alors il est également* $\mathsf{IND}-\mathsf{CQA2}$ *sûr.*

Démonstration. Nous invitons le lecteur à consulter la preuve de ce théorème présente dans l'article de Curtmola *et al.* [CGKO06]. □

Nous nous intéressons dans la suite de ce mémoire à la notion de sécurité $\mathcal{L}$ qui quantifie de manière exacte les informations révélées par un schéma SSE.

Chapitre 3
Classification des fuites d'information des schémas de recherche

Nous présentons dans ce chapitre la classification des schémas SSE introduite par Cash *et al.* dans [CGPR16] où différents schémas SSE conduisent à différents profils de fuite. Nous l'abordons ici différemment en commençant par identifier les informations des documents qui peuvent être révélées par une base de données chiffrée générée par un schéma. Nous donnons ensuite des exemples d'implémentation pour chacune des classes. Nous débutons par le profil de fuite $\mathsf{L4}$ regroupant les schémas dont les bases de données chiffrées qu'ils génèrent révèlent le maximum d'information sur les documents. Nous continuons avec les profils de fuite intermédiaires $\mathsf{L3}$, $\mathsf{L2}$, $\mathsf{L1}$ et terminons avec la définition d'un nouveau profil de fuite $\mathsf{L0}$ regroupant les schémas dont les bases de données chiffrées qu'ils génèrent révèlent le minimum d'information.

§ 3.1 Profil de fuite $\mathsf{L4}$

3.1.1 Fonction de fuite associée

Sans prendre en considération le sens des mots-clefs qui le composent, commençons par nous interroger sur les informations que nous pouvons avoir d'un document.

Un document est tout d'abord caractérisé par le nombre total de mots-clefs qui le compose, l'ordre et le nombre d'apparition de ses mots-clefs. D'autre part, il est également décrit par les mots-clefs qu'il partage avec les autres documents. Ainsi, nous ne perdons aucune information sur un document clair si le référencement de son chiffré dans la base de données chiffré nous donne toutes ces informations. Seul le sens du document est perdu. Nous définissons cet ensemble d'information pour une telle base de données chiffrée comme le profil $\mathsf{L4}$ d'un document chiffré.

Définition 3.1 (Profil $\mathsf{L4}$ d'un document chiffré)**.** *Soit $d \in \mathsf{D}$ un document défini sur W et EDB une base de données chiffrée associée à D. Nous définissons le profil $\mathsf{L4}$ de d^* par rapport à EDB comme*

$$\mathsf{profil}^{\mathsf{L4}}_{\mathsf{EDB}}(d^*)[j] = k \text{ si } d[j] = w_k \text{ pour } 1 \leqslant j \leqslant \ell$$

Cette définition nous permet de formaliser la première classe des schémas SSE, le profil de fuite $\mathsf{L4}$. Cette classe correspond à l'ensemble des schémas SSE dont les bases de données chiffrées qu'ils génèrent révèlent le profil $\mathsf{L4}$ des documents chiffrés référencés.

Définition 3.2 (Profil de fuite $\mathsf{L4}$)**.** *Soit Π un schéma* SSE *et $\mathcal{L}$ sa fonction de fuite associée. Soit EDB la base de données chiffrée générée à partir de l'ensemble documentaire*

D *par le schéma* Π. *Nous dirons que le schéma* Π *a un profil de fuite* $\mathsf{L4}$ *si*

$$\mathcal{L}(\mathsf{EDB}) = \{\mathsf{profil}^{\mathsf{L4}}_{\mathsf{EDB}}(d_i^*)\}_{1 \leqslant i \leqslant \#\mathsf{D}}$$

Remarque 3.1. *Les schémas* SSE *de profil de fuite* $\mathsf{L4}$ *laissent fuire beaucoup d'information. Malgré cela, la simplicité de leur implémentation et leur compatibilité avec les divers services Cloud ont permis leur déploiement à grande échelle. Des compagnies internationales telles que Skyhigh Networks et CipherCloud utilisent par exemple de tels schémas* SSE.

3.1.2 Exemple d'un schéma de profil de fuite $\mathsf{L4}$

Soit Π_{L4} un schéma SSE statique utilisant un schéma de chiffrement par substitution $\mathcal{E} = (\mathsf{Gen}, \mathsf{Enc}, \mathsf{Dec})$ de paramètre de sécurité λ. Soit D un ensemble documentaire. Nous présentons l'algorithme $\Pi_{\mathsf{L4}}.\mathsf{Setup}$ dans la figure 3.1.

Algorithme : $\Pi_{\mathsf{L4}}.\mathsf{Setup}$

Entrées : λ et D
Sortie : K_λ, EDB et D^*

$K_\lambda \leftarrow \mathsf{Gen}(1^\lambda)$;
$\mathsf{EDB} \leftarrow \emptyset$;
$\mathsf{D}^* \leftarrow \emptyset$;
pour $1 \leqslant i \leqslant \#\mathsf{D}$ **faire**
  $d_i^* = (\mathsf{Enc}_{K_\lambda}(d_i[j]))_{1 \leqslant j \leqslant \ell_i}$;
  $\mathsf{D}^* \leftarrow \mathsf{D}^* \cup \{d_i^*\}$;
  $\mathsf{EDB}[i] \leftarrow d_i^*$;
retourner K_λ, EDB et D^* ;

FIGURE 3.1 – Algortihme $\Pi_{\mathsf{L4}}.\mathsf{Setup}$.

Cet algorithme génère alors une base de données chiffrée reposant sur un index où chaque identifiant des documents chiffrés est associé à la liste des mots-clefs protégés par $\mathcal{E}$. Cette liste conserve les informations sur l'ordre et la répétition des mots-clefs dans le document clair correspondant. Nous remarquons également qu'un même mot-clef sera protégé de la même façon quel que soit le document qui le contient. Le serveur connaît donc l'ensemble des documents contenant un même mot-clef.

Exemple 3.1. *Soit* $\mathsf{D} = (d_1, d_2)$ *un ensemble de deux documents avec* $d_1 = (w_3, w_2, w_3)$ *et* $d_1 = (w_1, w_2, w_1, w_3)$. *Nous obtenons par l'algorithme* $\Pi_{\mathsf{L4}}.\mathsf{Setup}$ *la base de données chiffrée suivante*

EDB
$1 \leftarrow (\mathsf{Enc}_{K_\lambda}(w_3), \mathsf{Enc}_{K_\lambda}(w_2), \mathsf{Enc}_{K_\lambda}(w_3))$
$2 \leftarrow (\mathsf{Enc}_{K_\lambda}(w_1), \mathsf{Enc}_{K_\lambda}(w_2), \mathsf{Enc}_{K_\lambda}(w_1), \mathsf{Enc}_{K_\lambda}(w_3))$

Nous remarquons dans cet exemple que le serveur sait qu'il héberge deux documents. Il connaît de plus pour ces deux documents, le nombre de mots-clefs qui le compose, leur ordre ainsi que leur nombre d'appartition. Nous remarquons également que le serveur sait que d_1 *et* d_2 *partagent deux mots-clefs identiques puisque* d_1^* *et* d_2^* *possèdent les substitués* $\mathsf{Enc}_{K_\lambda}(w_2)$ *et* $\mathsf{Enc}_{K_\lambda}(w_3)$.

Nous nous intéressons maintenant à la fonctionnalité de recherche de ce schéma. Pour cela, nous présentons le protocole $\Pi_{\mathsf{L4}}.\mathsf{Search}$ dans la figure 3.2.

Algorithme : $\mathsf{Client}.\Pi_{\mathsf{L4}}.\mathsf{Search}$

Entrées : K_λ, w
Sortie : w^*

$w^* \leftarrow \mathsf{Enc}_{K_\lambda}(w)$ **retourner** w^* au serveur ;

Algorithme : $\mathsf{Serveur}.\Pi_{\mathsf{L4}}.\mathsf{Search}$

Entrées : w^*, EDB
Sortie : $\mathsf{D}^*(w)$

$D_w \leftarrow \emptyset$;
pour $1 \leqslant i \leqslant \#\mathsf{D}$ **faire**
  si $w^* \in \mathsf{EDB}[i]$ **alors**
    $D_w \leftarrow D_w \cup \{i\}$;
retourner $D_w = \mathsf{D}^*(w)$ au client ;

FIGURE 3.2 – Le protocole $\Pi_{\mathsf{L4}}.\mathsf{Search}$.

Le protocole protège le mot-clef recherché par le client à l'aide du schéma de chiffrement par substitution $\mathcal{E}$. Pour répondre à cette recherche, le serveur parcourt l'ensemble de la base de données. Il retourne au client les entrées de la table (correspondant aux identifiants des documents chiffrés) dont la liste de mots-clefs protégés associée contient le protégé du mot-clef recherché.

Exemple 3.2. *Nous considérons la base de données chiffrée présentée dans l'exemple précédent et nous supposons que le client fasse une recherche sur le mot-clef* w_1*. Pour effectuer cette recherche, le client utilise le protocole* $\Pi_{\mathsf{L4}}.\mathsf{Search}$ *prenant en entrée* K_λ *et* w_1*. Le protocole protège* w_1 *en calculant* $\mathsf{Enc}_{K_\lambda}(w_1)$*. Ce substitué est envoyé au serveur qui cherchera alors dans* EDB*, les chiffrés contenant* $\mathsf{Enc}_{K_\lambda}(w_1)$*. Le serveur renverra ensuite au client les identifiants correspondant, dans notre exemple ce sera l'identifiant* 2*.*

§ 3.2 Profil de fuite L3

3.2.1 Fonction de fuite associée

Le profil de fuite L4 révèle au serveur toutes les informations disponibles sur les documents, mise à part leur signification. La deuxième classe de schémas SSE proposée par Cash *et al.* dans [CJJ+13], est le profil de fuite L3. Celle-ci vise à classifier des schémas SSE révélant strictement moins d'information.

Afin d'effectuer des recherches par mot-clef sur des documents chiffrés, il est nécessaire de connaître les mots-clefs de chacun de ces documents. Néanmoins, ce processus n'a pas besoin de connaître le nombre d'apparition de ces mots-clefs dans les documents. Il lui suffit de savoir si tel ou tel mot-clef est présent dans tel ou tel document.

Ainsi, le référencement d'un document chiffré dans une base de données chiffrée ne donnant pas d'information sur le nombre d'apparition des différents mots-clefs du document clair défini le profil L3 d'un document chiffré.

Définition 3.3 (Profil $\mathsf{L3}$ d'un document chiffré)**.** *Soit $d \in \mathsf{D}$ un document défini sur W et EDB une base de données chiffrée associée à D. Nous définissons le profil $\mathsf{L3}$ de d^* par rapport à EDB comme*

$$\mathsf{profil}^{\mathsf{L3}}_{\mathsf{EDB}}(d^*) = (\mathsf{profil}^{\mathsf{L4}}_{\mathsf{EDB}}(d^*)[j] = k \text{ si } k \neq \mathsf{profil}^{\mathsf{L4}}_{\mathsf{EDB}}(d^*)[t] \text{ pour } 1 \leqslant t \leqslant j-1)_{1 \leqslant j \leqslant \ell}$$

La définition d'un profil $\mathsf{L3}$ d'un document nous permet de formaliser la deuxième classe de schéma SSE, le profil de fuite $\mathsf{L3}$. Cette nouvelle classe rassemble les schémas SSE dont les bases de données chiffrées qu'ils génèrent révèlent le profil $\mathsf{L3}$ des documents chiffrés référencés.

Définition 3.4 (Profil de fuite $\mathsf{L3}$)**.** *Soit Π un schéma* SSE *et $\mathcal{L}$ sa fonction de fuite associée. Soit EDB la base de données chiffrée générée à partir de l'ensemble documentaire D par le schéma Π. Nous dirons que le schéma Π a un profil de fuite $\mathsf{L3}$ si*

$$\mathcal{L}(\mathsf{EDB}) = \{\mathsf{profil}^{\mathsf{L3}}_{\mathsf{EDB}}(d_i^*)\}_{1 \leqslant i \leqslant \#\mathsf{D}}$$

Remarque 3.2. *Nous remarquons alors que le profil de fuite $\mathsf{L3}$ permet toujours au serveur de connaître le nombre total de documents hébergés ainsi que de savoir quels sont les documents partageant un même mot-clef.*

3.2.2 Exemple d'un schéma de profil de fuite $\mathsf{L3}$

Soit Π_{L3} un schéma SSE statique utilisant un schéma de chiffrement sémantiquement sûr $\mathcal{E} = (\mathsf{Gen}, \mathsf{Enc}, \mathsf{Dec})$ et soit $F.$ une fonction pseudo-aléatoire. Soit D un ensemble documentaire et λ un paramètre de sécurité. Nous présentons l'algorithme $\Pi_{\mathsf{L3}}.\mathsf{Setup}$ dans la figure 3.3.

Algorithme : $\Pi_{\mathsf{L3}}.\mathsf{Setup}$

Entrées : λ et D
Sortie : K_λ, EDB et D^*

$K_\lambda \leftarrow \mathsf{Gen}(1^\lambda)$;
$\mathsf{EDB} \leftarrow \emptyset$;
$\mathsf{D}^* \leftarrow \emptyset$;
pour $1 \leqslant i \leqslant \#\mathsf{D}$ **faire**
  $L = (F_{K_\lambda}(d_i[j]) : d_i[j] \neq d_i[t] \text{ pour } 1 \leqslant t \leqslant j-1)_{1 \leqslant j \leqslant \ell_i}$;
  $\mathsf{EDB}[i] \leftarrow L$;
  $d_i^* = \mathsf{Enc}_{K_\lambda}(d_i)$;
  $\mathsf{D}^* \leftarrow \mathsf{D}^* \cup \{d_i^*\}$;
retourner K_λ, EDB et D^* ;

FIGURE 3.3 – Algortihme $\Pi_{\mathsf{L3}}.\mathsf{Setup}$.

Cet algorithme génère une base de données qui repose sur un index. Chaque identifiant des documents chiffrés est associé à la liste des mots-clefs protégés par $F.$. Cette liste conserve l'information sur l'ordre des mots-clefs du documents clair correspondant. Nous remarquons alors qu'un même mot-clef sera protégé de la même façon quelque soit le document qui le contient. Le serveur connaît donc l'ensemble des documents contenant un même mot-clef.

Exemple 3.3. *Soit* $\mathsf{D} = (d_1, d_2)$ *un ensemble de deux documents avec* $d_1 = (w_3, w_2, w_3)$ *et* $d_1 = (w_1, w_2, w_1, w_3)$*. Nous obtenons par l'algorithme* $\Pi_{\mathsf{L3}}.\mathsf{Setup}$ *la base de données chiffrée suivante*

EDB
$1 \leftarrow (F_{K_\lambda}(w_3), F_{K_\lambda}(w_2))$
$2 \leftarrow (F_{K_\lambda}(w_1), F_{K_\lambda}(w_2), F_{K_\lambda}(w_3))$

Nous remarquons dans cet exemple que le serveur sait qu'il héberge deux documents. Il connaît de plus pour ces deux documents, le nombre de mots-clefs disctincts qui le compose ainsi que leur ordre d'apparition. Néanmoins, il ne connaît plus le nombre total de mots-clefs dans les documents ainsi que leur nombre d'apparition. Nous remarquons également que le serveur sait que d_1 *et* d_2 *partagent deux mots-clefs puisque* d_1^* *et* d_2^* *possède les valeurs pseudo-aléatoires* $F_{K_\lambda}(w_2)$ *et* $F_{K_\lambda}(w_3)$ *en commun.*

Nous nous intéressons maintenant à la fonctionnalité de recherche de ce schéma. Pour cela, nous présentons le protocole $\Pi_{\mathsf{L3}}.\mathsf{Search}$ dans la figure 3.4.

Algorithme : $\mathsf{Client}.\Pi_{\mathsf{L3}}.\mathsf{Search}$

Entrées : K_λ, w
Sortie : w^*

$w^* \leftarrow F_{K_\lambda}(w)$;
retourner w^* au serveur ;

Algorithme : $\mathsf{Serveur}.\Pi_{\mathsf{L3}}.\mathsf{Search}$

Entrées : w^*, EDB
Sortie : $\mathsf{D}^*(w)$

$D_w \leftarrow \emptyset$;
pour $1 \leqslant i \leqslant \#\mathsf{D}$ **faire**
  si $w^* \in \mathsf{EDB}[i]$ **alors**
    $D_w \leftarrow D_w \cup i$;
retourner $D_w = \mathsf{D}^*(w)$ au client ;

FIGURE 3.4 – Le protocole $\Pi_{\mathsf{L3}}.\mathsf{Search}$.

Le protocole protège le mot-clef recherché par le client à l'aide de la fonction pseudo-aléatoire. Pour répondre à cette recherche, le serveur parcourt l'ensemble de la base de données. Il retourne au client les entrées de la table (correspondant aux identifiants des documents chiffrés) dont la liste de mots-clefs protégés associée contient le protégé du mot-clef recherché.

Exemple 3.4. *Nous considérons la base de données chiffrée présentée dans l'exemple précédent et nous supposons que le client fasse une recherche sur le mot-clef* w_1*. Pour effectuer cette recherche, le client utilise le protocole* $\Pi_{\mathsf{L3}}.\mathsf{Search}$ *prenant en entrée* K_λ *et* w_1*. Le protocole protège* w_1 *en calculant* $F_{K_\lambda}(w_1)$*. Cette évaluation de* w_1 *par la fonction pseudo-aléatoire est envoyée au serveur qui cherchera alors dans* EDB*, les documents contenant* $F_{K_\lambda}(w_1)$*. Le serveur renverra ensuite au client les identifiants correspondant, dans notre exemple* 2*.*

§ 3.3 Profil de fuite L2

3.3.1 Fonction de fuite associée

Nous avons déjà signalé qu'une recherche par mot-clef sur documents chiffrés avait besoin, pour fonctionner, de connaître uniquement les mots-clefs présents dans chacun des documents. Toutefois, le profil L3 d'un document chiffré conserve l'information sur l'ordre d'apparition des mots-clefs du document clair associé.

Ainsi, le référencement d'un document chiffré dans une base de données chiffrée ne donnant pas d'information sur l'ordre d'appartition des mots-clefs du document clair définit le profil L2 d'un document chiffré.

Définition 3.5 (Profil L2 d'un document chiffré)**.** *Soit $d \in \mathsf{D}$ un document défini sur* W *et EDB une base de données chiffrée associée à* D*. Nous définissons le profil* L2 *de d^* par rapport à* EDB *comme*

$$\mathsf{profil}^{\mathsf{L2}}_{\mathsf{EDB}}(d^*) = \mathsf{lex}(\mathsf{profil}^{\mathsf{L3}}_{\mathsf{EDB}}(d^*)\,)$$

où lex *est une relation d'ordre intrinsèque.*

Cette définition nous permet de formaliser la troisième classe de schémas SSE, le profil de fuite L2. Cette troisième classe rassemble les schémas SSE dont les bases de données chiffrées qu'ils génèrent révèlent le profil L2 des documents chiffrés référencés.

Définition 3.6 (Profil de fuite L2)**.** *Soit* Π *un schéma* SSE *et $\mathcal{L}$ sa fonction de fuite associée. Soit* EDB *la base de données chiffrée générée à partir de l'ensemble documentaire* D *par le schéma* Π*. Nous dirons que le schéma* Π *a un profil de fuite* L2 *si*

$$\mathcal{L}(\mathsf{EDB}) = \{\mathsf{profil}^{\mathsf{L2}}_{\mathsf{EDB}}(d_i^*)\,\}_{1 \leqslant i \leqslant \#\mathsf{D}}$$

Remarque 3.3. *Comme pour les profils de fuite* L4 *et* L3*, nous remarquons alors que le profil de fuite* L2 *permet toujours au serveur de connaître le nombre total de documents hébergés ainsi que de savoir quels sont les documents partageant un même mot-clef.*

3.3.2 Exemple d'un schéma de profil de fuite L2 reposant sur un index

Soit Π_{L2} un schéma SSE statique utilisant un schéma de chiffrement sémantiquement sûr $\mathcal{E} = (\mathsf{Gen}, \mathsf{Enc}, \mathsf{Dec})$ de paramètre de sécurité λ, $F.$ une fonction pseudo-aléatoire et lex une fonction permettant d'ordonner une liste lexicographiquement. Soit D un ensemble documentaire. Nous présentons l'algorithme $\Pi_{\mathsf{L2}}.\mathsf{Setup}$ dans la figure 3.5.

Cet algorithme produit une base de données chiffrée reposant sur un index où chaque identifiant des documents chiffrés est associé à la liste des mots-clefs protégés par $F.$ à laquelle nous appliquons la fonction lex. Ainsi, ces listes permettent de savoir quels sont les documents partageant un même mot-clef mais n'indiquent pas où se trouve ce mot-clef dans les documents clairs.

Exemple 3.5. *Soit* $\mathsf{D} = (d_1, d_2)$ *un ensemble de deux documents avec* $d_1 = (w_3, w_2, w_3)$ *et* $d_1 = (w_1, w_2, w_1, w_3)$*. Nous obtenons par l'algorithme* $\Pi_{\mathsf{L2}}.\mathsf{Setup}$ *la base de données chiffrée suivante*

Algorithme : $\Pi_{\mathsf{L2}}.\mathsf{Setup}$

Entrées : λ et D
Sortie : K_λ, EDB et D^*

$K_\lambda \leftarrow \mathsf{Gen}(1^)$;
$\mathsf{EDB} \leftarrow \emptyset$;
$\mathsf{D}^* \leftarrow \emptyset$;
pour $1 \leqslant i \leqslant \#\mathsf{D}$ **faire**
  $L_0 = \mathsf{lex}((d_i[j] : d_i[j] \neq d_i[t] \text{ pour } 1 \leqslant t \leqslant j-1)_{1 \leqslant j \leqslant \ell_i})$;
  $L_1 = (F_{K_\lambda}(L_0[j]))_{1 \leqslant j \leqslant \ell_i}$;
  $\mathsf{EDB}[i] \leftarrow L_1$;
  $d_i^* = \mathsf{Enc}_{K_\lambda}(d_i)$;
  $\mathsf{D}^* \leftarrow \mathsf{D}^* \cup \{d_i^*\}$;
retourner K_λ, EDB et D^* ;

FIGURE 3.5 – Algortihme $\Pi_{\mathsf{L2}}.\mathsf{Setup}$.

EDB
$1 \leftarrow (F_{K_\lambda}(w_2), F_{K_\lambda}(w_3))$
$2 \leftarrow (F_{K_\lambda}(w_1), F_{K_\lambda}(w_2), F_{K_\lambda}(w_3))$

Nous remarquons dans cet exemple que le serveur sait qu'il héberge deux documents. Il connaît de plus pour ces deux documents, le nombre de mots-clefs disctincts qui les composent mais ne sait plus leur ordre d'apparition dans le document. Nous remarquons également que le serveur sait toujours que d_1 et d_2 partagent deux mots-clefs identiques puisque d_1^* et d_2^* possède les valeurs pseudo-aléatoires $F_{K_\lambda}(w_2)$ et $F_{K_\lambda}(w_3)$ en commun.

Nous nous intéressons maintenant à la fonctionnalité de recherche de ce schéma. Pour cela, nous présentons le protocole $\Pi_{\mathsf{L2}}.\mathsf{Search}$ dans la figure 3.6.

Algorithme : $\mathsf{Client}.\Pi_{\mathsf{L2}}.\mathsf{Search}$

Entrées : K_λ, w
Sortie : w^*

$w^* \leftarrow F_{K_\lambda}(w)$;
retourner w^* au serveur ;

Algorithme : $\mathsf{Serveur}.\Pi_{\mathsf{L2}}.\mathsf{Search}$

Entrées : w^*, EDB
Sortie : $\mathsf{D}^*(w)$

$D_w \leftarrow \emptyset$;
pour $1 \leqslant i \leqslant \#\mathsf{D}$ **faire**
  si $w^* \in \mathsf{EDB}[i]$ **alors**
    $D_w \leftarrow D_w \cup i$;
retourner $D_w = \mathsf{D}^*(w)$ au client ;

FIGURE 3.6 – Le protocole $\Pi_{\mathsf{L2}}.\mathsf{Search}$.

Ce protocole de recherche protège le mot-clef recherché par la fonction pseudo-alétoire F.. Pour répondre à une recherche, le serveur parcourt l'ensemble de la base de données et retourne au client les entrées de la table (correspondant aux identifiants des documents chiffrés) dont la liste des mots-clefs protégés asssociée contient le protégé mot-clef

recherché.

Exemple 3.6. *Nous considérons la base de données présentée dans l'exemple précédent et nous supposons que le client fasse une recherche sur le mot-clef w_1. Pour effectuer cette recherche, le client utilise le protocole $\Pi_{\mathsf{L2}}.\mathsf{Search}$ prenant en entrée K_λ et w_1. Le protocole protège w_1 en calculant $F_{K_\lambda}(w_1)$. Cette évaluation de w_1 par la fonction pseudo-aléatoire est envoyée au serveur qui cherchera alors dans* EDB *les documents contenant $F_{K_\lambda}(w_1)$. Le serveur renverra ensuite au client les identifiants correspondant, dans notre exemple* 2.

3.3.3 Exemple d'un schéma de profil de fuite L2 reposant sur un index inversé

Nous exposons maintenant une autre construction possible pour un schéma SSE de profil de fuite L2. Celle-ci repose sur un index inversé. Elle est donc plus efficace puisque pour répondre à une recherche, le serveur parcourt la liste des documents contenant le mot-clef recherché au lieu de parcourir l'ensemble de tous les documents.

Soit Π'_{L2} un schéma SSE statique utilisant un schéma de chiffrement sémantiquement sûr $\mathcal{E} = (\mathsf{Gen}, \mathsf{Enc}, \mathsf{Dec})$ et soit $F.$ une fonction pseudo-aléatoire. Soit D un ensemble documentaire et λ un paramètre de sécurité. Nous présentons l'algorithme $\Pi'_{\mathsf{L2}}.\mathsf{Setup}$ dans la figure 3.7.

Algorithme : $\Pi'_{\mathsf{L2}}.\mathsf{Setup}$

Entrées : λ et D
Sortie : K_λ, EDB et D^*

$K_\lambda \leftarrow \mathsf{Gen}(1^)$;
$\mathsf{EDB} \leftarrow \emptyset$;
$\mathsf{D}^* \leftarrow \emptyset$;
pour $w \in \mathsf{W}$ **faire**
  $\mathsf{EDB}[F_{K_\lambda}(w)] \leftarrow (i : w \in d_i)$;
pour $d \in \mathsf{D}$ **faire**
  $\mathsf{D}^* \leftarrow \mathsf{D}^* \cup \{\mathsf{Enc}_{K_\lambda}(d)\}$;
retourner K_λ, EDB et D^* ;

FIGURE 3.7 – Algortihme $\Pi'_{\mathsf{L2}}.\mathsf{Setup}$.

Cet algorithme produit une base de données chiffrée reposant sur un index inversé. Les entrées de la table correspondent aux mots-clefs de l'ensemble documentaire protégés par $F.$ aux quelles nous associons l'ensemble des identifiants des documents chiffrés dont les clairs contiennent le mot-clef correspondant. Ainsi, cette construction ne permet que de savoir quels sont les documents partageant un même mot-clef mais n'indiquent pas où se trouve ce mot-clef dans les documents clairs.

Exemple 3.7. *Soit $\mathsf{D} = (d_1, d_2)$ un ensemble de deux documents avec $d_1 = (w_3, w_2, w_3)$ et $d_2 = (w_1, w_2, w_1, w_3)$. Nous obtenons par l'algorithme $\Pi_{\mathsf{L2}}.\mathsf{Setup}$ la base de données chiffrée suivante*

EDB
$F_{K_\lambda}(w_1) \rightarrow \{2\}$
$F_{K_\lambda}(w_2) \rightarrow \{1,2\}$
$F_{K_\lambda}(w_3) \rightarrow \{1,2\}$

Comme pour l'exemple reposant sur un index, nous remarquons que le serveur sait qu'il héberge deux documents. Il connaît de plus pour ces deux documents, le nombre de mots-clefs disctincts qui le compose mais ne sait plus leur ordre d'apparition dans le document. Nous remarquons également que le serveur sait toujours que d_1 et d_2 partagent deux mots-clefs identiques puisque d_1^* et d_2^* possède les valeurs pseudo-aléatoires $F_{K_\lambda}(w_2)$ et $F_{K_\lambda}(w_3)$ en commun.

Nous nous intéressons maintenant à la fonctionnalité de recherche de ce schéma. Pour cela, nous présentons le protocole $\Pi'_{\mathsf{L2}}.\mathsf{Search}$ dans la figure 3.8.

Algorithme : $\mathsf{Client}.\Pi'_{\mathsf{L2}}.\mathsf{Search}$

Entrées : K_λ, w
Sortie : w^*

$w^* \leftarrow F_{K_\lambda}(w)$;
retourner w^* au serveur ;

Algorithme : $\mathsf{Serveur}.\Pi'_{\mathsf{L2}}.\mathsf{Search}$

Entrées : w^*, EDB
Sortie : $\mathsf{D}^*(w)$

retourner $\mathsf{EDB}[w^*]$ au client ;

FIGURE 3.8 – Le protocole $\Pi'_{\mathsf{L2}}.\mathsf{Search}$.

Ce protocole de recherche protège le mot-clef recherché par la fonction pseudo-alétoire $F_.$. Pour répondre à une recherche, le serveur retourne simplement l'ensemble des identifiants associés à l'entrée de valeur le protégé du mot-clef recherché.

Exemple 3.8. *Nous considérons la base de données chiffrée présentée dans l'exemple précédent et nous supposons que le client fasse une recherche sur le mot-clef w_1. Pour effectuer cette recherche, le client utilise le protocole $\Pi.\mathsf{Search}$ prenant en entrée K_λ et w_1. Le protocole protège w_1 en calculant $F_{K_\lambda}(w_1)$. Cette évaluation de w_1 par la fonction pseudo-aléatoire est envoyée au serveur qui lui permet de retourner au client les identifiants correspondant. Il suiffit de retourner la liste présente dans $\mathsf{EDB}[F_{K_\lambda}(w_1)]$, dans notre exemple 2.*

§ 3.4 Profil de fuite L1

3.4.1 Fonction de fuite associée

Les schémas SSE ayant un profil de fuite L4, L3 ou L2 révèlent au serveur tous les mots-clefs partagés entre les documents. Le profil de fuite L1 propose de limiter cette information aux mots-clefs qui ont uniquement été préalablement recherchés par le client.

Définition 3.7 (Profil de fuite L1)**.** *Soit Π un schéma* SSE *et $\mathcal{L}$ sa fonction de fuite associée. Soit* EDB *la base de données chiffrée générée par le schéma Π à partir de l'ensemble documentaire* D*. Nous dirons que le schéma Π a un profil de fuite* L1 *s'il révèle initialement au serveur seulement le nombre de documents partageant un même mot-clef puis les documents partageant un mot-clef qui a été recherché.*

Remarque 3.4. *Nous notons qu'un schéma* SSE *de profil de fuite* $\mathsf{L1}$ *révèle autant d'information qu'un schéma* SSE *de profil de fuite* $\mathsf{L2}$ *si le client a effectué toutes les recherches possibles.*

3.4.2 Exemple d'un schéma de profil de fuite L1

Soit Π_{L1} un schéma SSE statique utilisant deux schémas de chiffrement sémantiquement sûr $\mathcal{E}_1 = (\mathsf{Gen}_1, \mathsf{Enc}_1, \mathsf{Dec}_1)$, $\mathcal{E}_2 = (\mathsf{Gen}_2, \mathsf{Enc}_2, \mathsf{Dec}_2)$ de paramètre de sécurité λ et $F.$ une fonction pseudo-aléatoire dont nous supposons que son espace d'arrivée est $\{0,1\}^\lambda$. Soit D un ensemble documentaire. Nous présentons l'algorithme $\Pi_{\mathsf{L1}}.\mathsf{Setup}$ dans la figure 3.9.

Algorithme : $\Pi_{\mathsf{L1}}.\mathsf{Setup}$

Entrées : λ et D
Sortie : K_λ, EDB et D^*

$K_\lambda \leftarrow \mathsf{Gen}_1(1^)$;
$\mathsf{EDB} \leftarrow \emptyset$;
$\mathsf{D}^* \leftarrow \emptyset$;
pour $w \in \mathsf{W}$ **faire**
  $\mathsf{EDB}[F_{K_\lambda}(w)] \leftarrow (\mathsf{Enc}_{2_{F_{K\lambda}}}(i) : w \in d_i)$;
pour $d \in \mathsf{D}$ **faire**
  $\mathsf{D}^* \leftarrow \mathsf{D}^* \cup \{\mathsf{Enc}_{1_{K_\lambda}}(d)\}$;
retourner K_λ, EDB et D^* ;

FIGURE 3.9 – Algortihme $\Pi_{\mathsf{L1}}.\mathsf{Setup}$.

Cet algorithme produit une base de données chiffrée reposant sur un index inversé lui-même chiffré. Les entrées de la table correspondent aux mots-clefs de l'ensemble documentaire protégés par $F.$ aux quelles nous associons l'ensemble des identifiants des documents chiffrés dont les clairs contiennent le mot-clef correspondant. Ces identifiants sont ensuite chiffrés par Enc_2 dont la clef de chiffrement est la valeur du mot-clef protégé associé. Ainsi, cette construction ne permet que de savoir le nombre de documents partageant un même mot-clef.

Exemple 3.9. *Soit* $\mathsf{D} = (d_1, d_2)$ *un ensemble de deux documents avec* $d_1 = (w_3, w_2, w_3)$ *et* $d_1 = (w_1, w_2, w_1, w_3)$. *Nous obtenons par l'algorithme* $\Pi_{\mathsf{L1}}.\mathsf{Setup}$ *la base de données chiffrée suivante*

EDB
$F_{K_\lambda}(w_1) \rightarrow \{\mathsf{Enc}_{F_{K_\lambda}(w_1)}(2)\}$
$F_{K_\lambda}(w_2) \rightarrow \{\mathsf{Enc}_{F_{K_\lambda}(w_2)}(1), \mathsf{Enc}_{F_{K_\lambda}(w_2)}(2)\}$
$F_{K_\lambda}(w_3) \rightarrow \{\mathsf{Enc}_{F_{K_\lambda}(w_3)}(1), \mathsf{Enc}_{F_{K_\lambda}(w_3)}(2)\}$

Nous remarquons que sans aucune recherche faite par le client, le serveur sait uniquement le nombre de documents partageant un même mot-clef. Il ne peut plus, lorsqu'aucune recherche n'est faite, savoir quels sont les mots-clefs partagés par les documents.

Nous nous intéressons maintenant à la fonctionnalité de recherche de ce schéma. Pour cela, nous présentons le protocole $\Pi_{\mathsf{L1}}.\mathsf{Search}$ dans la figure 3.10.

Algorithme : $\mathsf{Client}.\Pi_{\mathsf{L1}}.\mathsf{Search}$

Entrées : K_λ, w
Sortie : w^*

$w^* \leftarrow F_{K_\lambda}(w)$;
retourner w^* au serveur ;

Algorithme : $\mathsf{Serveur}.\Pi_{\mathsf{L1}}.\mathsf{Search}$

Entrées : w^*, EDB
Sortie : $\mathsf{D}^*(w)$

$D_w \leftarrow \emptyset$;
pour chaque $i^* \in \mathsf{EDB}[w^*]$ **faire**
  $D_w \leftarrow D_w \cup \mathsf{Dec}_{2_{w^*}}(i^*)$;
retourner $D_w = \mathsf{D}(w)$ au client ;

FIGURE 3.10 – Le protocole $\Pi_{\mathsf{L1}}.\mathsf{Search}$.

Ce protocole de recherche protège le mot-clef recherché par la fonction pseudo-aléatoire F.. Pour répondre à une recherche, le serveur retourne simplement l'ensemble des identifiants associés à l'entrée de valeur, le protégé du mot-clef recherché, qu'il déchiffré préalablement via Enc_2 et la clef de déchiffrement de valeur, le protégé du mot-clef recherché.

Exemple 3.10. *Nous considérons la base de données chiffrée présentée dans l'exemple précédent et nous supposons que le client fasse une recherche sur le mot-clef w_1. Pour effectuer cette recherche, le client utilise le protocole $\Pi_{\mathsf{L1}}.\mathsf{Search}$ prenant en entrée K_λ et w_1. Le protocole protège w_1 en calculant $F_{K_\lambda}(w_1)$. Cette évaluation de w_1 par la fonction pseudo-aléatoire est envoyée au serveur qui lui permet de déchiffrer les identifiants correspondant. Il lui suffit de retourner la liste présente dans $\mathsf{EDB}[F_{K_\lambda}(w_1)]$, dans notre exemple* 2.

Remarque 3.5. *En réalisant différentes recherches, le client permet ainsi au serveur de déchiffrer les identifiants des documents contenant les mots-clefs recherchés. Le serveur apprend ainsi progressivement les documents partageant en commun les mots-clefs recherchés.*

§ 3.5 Profil de fuite L0

3.5.1 Fonction de fuite associée

Sans aucune recherche préalable par le client, un schéma SSE de profil de fuite L1 révèle uniquement au serveur le nombre de documents contenant un même mot-clef. Nous définissons le profil de fuite L0 comme la classe des schémas ne révélant pas cette information. Ainsi, sans recherche préalable, le serveur ne connaît que la quantité N de l'ensemble documentaire qu'il héberge.

Définition 3.8 (Profil de fuite L1)**.** *Soit Π un schéma* SSE *et $\mathcal{L}$ sa fonction de fuite associée. Soit* EDB *la base de données chiffrée générée par le schéma Π à partir de l'ensemble documentaire* D*. Nous dirons que le schéma Π a un profil de fuite* L0 *s'il révèle initialement au serveur seulement la quantité N de l'ensemble documentaire et les documents partageant un même mot-clef qui a été préalablement recherché.*

Remarque 3.6. *Nous notons qu'un schéma* SSE *de profil de fuite* $\mathsf{L0}$ *révèle autant d'information qu'un schéma* SSE *de profil de fuite* $\mathsf{L2}$ *si le client a effectué toutes les recherches possibles.*

3.5.2 Exemple d'un schéma de profil de fuite L0

Nous présentons le schéma SSE Π_{bas} proposé par Cash *et al.* en 2014 dans [CJJ+14]. Ce schéma utilise deux schémas de chiffrement sémantiquement sûr $\mathcal{E}_1 = (\mathsf{Gen_1}, \mathsf{Enc_1}, \mathsf{Dec_1})$, $\mathcal{E}_2 = (\mathsf{Gen_2}, \mathsf{Enc_2}, \mathsf{Dec_2})$ de paramètre de sécurité λ et F. une fonction pseudo-aléatoire dont nous supposons que son espace d'arrivée est $\{0,1\}^\lambda$. Soit D un ensemble documentaire. Nous présentons l'algorithme $\Pi_{\mathsf{bas}}.\mathsf{Setup}$ dans la figure 3.11.

Algorithme : $\Pi_{\mathsf{bas}}.\mathsf{Setup}$

Entrées : λ et D
Sortie : K_λ, EDB et D^*

$K_\lambda \leftarrow \mathsf{Gen_1}(1^)$;
$\mathsf{EDB} \leftarrow \emptyset$;
$\mathsf{D}^* \leftarrow \emptyset$;
pour $w \in \mathsf{W}$ **faire**
  $K_1 \| K_2 \leftarrow F_{K_\lambda}(w)$;
  $c \leftarrow 0$;
  pour $w \in \mathsf{lex}(d_i)$ **faire**
    $\mathsf{EDB}[F_{K_1}(c)] \leftarrow \mathsf{Enc}_{2K_2}(i)$;
    $c \leftarrow c + 1$;
pour $d \in \mathsf{D}$ **faire**
  $\mathsf{D}^* \leftarrow \mathsf{D}^* \cup \{\mathsf{Enc}_{1K_\lambda}(d)\}$;
retourner K_λ, EDB et D^* ;

FIGURE 3.11 – Algortihme $\Pi_{\mathsf{bas}}.\mathsf{Setup}$.

Cet algorithme produit une base de données chiffrée reposant sur un index inversé lui-même chiffré. Chaque entrée de la table, correpondant au chiffré d'un mot-clef protégé obtenu par $\mathsf{E_2}$, est associé à un unique identifiant dont le clair du document chiffré associé contient ce mot-clef. Cet identifiant est également chiffré à l'aide de $\mathsf{E_2}$.

Exemple 3.11. *Soit* $\mathsf{D} = (d_1, d_2)$ *un ensemble de deux documents avec* $d_1 = (w_3, w_2, w_3)$ *et* $d_1 = (w_1, w_2, w_1, w_3)$. *Nous obtenons par l'algorithme* $\Pi_{\mathsf{L1}}.\mathsf{Setup}$ *la base de données chiffrée suivante où* $K_1(w_j)$ *et* $K_2(w_j)$ *sont des clefs dépendant du mot-clef* w_j.

EDB
$F_{K_1(w_1)}(0) \rightarrow \{\mathsf{Enc}_{K_2(w_1)}(2)\}$
$F_{K_1(w_2)}(0) \rightarrow \{\mathsf{Enc}_{K_2(w_2)}(1)\}$
$F_{K_1(w_2)}(1) \rightarrow \{\mathsf{Enc}_{K_2(w_2)}(2)\}$
$F_{K_1(w_3)}(0) \rightarrow \{\mathsf{Enc}_{K_2(w_3)}(1)\}$
$F_{K_1(w_3)}(1) \rightarrow \{\mathsf{Enc}_{K_2(w_3)}(2)\}$

Nous remarquons que sans aucune recherche faite par le client, le serveur connait uniquement la quantité N de l'ensemble documentaire. Il ne peut plus, lorsqu'aucune recherche n'est faite, savoir combien de documents possèdent un même mot-clef.

Nous nous intéressons maintenant à la fonctionnalité de recherche de ce schéma. Pour cela, nous présentons le protocole $\Pi_{\mathsf{bas}}.\mathsf{Search}$ dans la figure 3.12.

Algorithme : $\mathsf{Client}.\Pi_{\mathsf{bas}}.\mathsf{Search}$

Entrées : K_λ, w
Sortie : K_1 et K_2

$K_1 \| K_2 \leftarrow F_{K_\lambda}(w)$;
retourner K_1 et K_2 au serveur ;

Algorithme : $\mathsf{Serveur}.\Pi_{\mathsf{bas}}.\mathsf{Search}$

Entrées : K_1, K_2 et EDB
Sortie : $\mathsf{D}^*(w)$

$D_w \leftarrow \emptyset$;
$c \leftarrow 0$;
tant que $\mathsf{EDB}[F_{K_1}(c)] \neq \perp$ **faire**
  retourner $\mathsf{Dec}_{2K_2}(\mathsf{EDB}[F_{K_1}(c)])$ au client ;
  $c \leftarrow c + 1$;

FIGURE 3.12 – Le protocole $\Pi_{\mathsf{bas}}.\mathsf{Search}$.

Ce protocole de recherche protège le mot-clef recherché en générant à partir de celui-ci deux clefs de chiffrement à l'aide la fonction pseudo-aléatoire F.. Pour répondre à une recherche, le serveur utilise la première clef pour parcourir les entrées correspondant au mot-clef recherché et déchiffre chaque identifiant à l'aide de la seconde clef.

Exemple 3.12. *Nous considérons la base de données chiffrée présentée dans l'exemple précédent et nous supposons que le client fasse une recherche sur le mot-clef w_2. Pour effectuer cette recherche, le client utilise le protocole $\Pi_{\mathsf{bas}}.\mathsf{Search}$ prenant en entrée K_λ et w_2. Le protocole protège w_2 en calculant $F_{K_\lambda}(w_2)$. Cette évaluation de w_2 par la fonction pseudo-aléatoire donne deux clefs $K_1(w_2)$ et $K_2(w_2)$. Le serveur reçoit ces deux clefs lui permettant de déchiffrer les identifiants correspondant. Pour cela, il incrémente un compteur c jusqu'à ce que la table de donne plus de réponse. Pour chaque c, il lui suffit alors de retourner le clair de l'identifiant chiffré présent à l'entrée $F_{K_1(w_2)}(c)$. Il déchiffre cet identifiant via l'algorithme de déchiffremet Dec_2 en utilisant la clef $K_2(w_2)$. Dans cet exemple, le serveur retourne au client les identifiants* 1 *et* 2.

Remarque 3.7. *En réalisant différentes recherches, le client permet ainsi au serveur de déchiffrer les identifiants des documents contenant les mots-clefs recherchés. Le serveur connaît ainsi les documents partageant en commun les mots-clefs recherchés.*

Nous nous intéressons dans la suite de ce mémoire aux attaques possibles sur des base de données chiffrées par des schémas SSE de profil de fuite L4, L3 et L2.

Chapitre 4

Exploitation des fuites pour la cryptanalyse des schémas de recherche

Nous présentons dans ce chapitre les différentes cryptanalyses réalisées sur les profils de fuite définis précédemment. Nous commencerons par définir les différentes attaques possibles et les différents buts d'un attaquant. Nous présenterons ensuite les attaques réalisées et les résultats obtenus sur différents ensembles de documents.

§ 4.1 Modèles d'attaques

4.1.1 Attaque passive

Nous l'avons vu dans le chapitre 3 (Classification des fuites d'information des schémas de recherche), les schémas de profil de fuite L4 révèlent au serveur le nombre total de mots-clefs, leur ordre ainsi que leur nombre d'apparition dans chacun des documents qu'il héberge alors que les schémas de profil de fuite L2 révèlent uniquement l'ensemble des mots-clefs distincts de chacun des documents.

Définition 4.1 (Attaque passive)**.** *Une attaque sera dite passive si le serveur ne fait qu'exploiter les informations révélées par le schéma.*

4.1.2 Attaque active

Contrairement à une attaque passive où le serveur ne fait qu'exploiter les informations révélées par le schéma, le serveur qui réalise une attaque active envoit un document clair choisit au client afin qu'il puisse recevoir son chiffré et déduire des informations sur les autres documents.

Exemple 4.1. *Soit un schéma SSE de profil de fuite* L4 *utilisé entre un client et son serveur de messagerie électronique. Nous supposons que le serveur procède à une attaque active. Il envoie alors un email au client qui à son tour le sauvegardera de façon chiffrée sur le serveur. Le schéma ayant un profil de fuite* L4*, le serveur pourra obtenir les substitués de chacun des mots-clefs présents dans l'email clair qu'il a envoyé. Si d'autres emails chiffrés possèdent les mêmes substitués, il pourra connaître leur version claire.*

Définition 4.2 (Attaque active)**.** *Une attaque sera dite passive si le serveur, en plus qu'exploiter les informations révélées par le schéma, envoie des documents clairs choisis au client.*

4.1.3 Connaissances préalables du serveur

Nous pouvons avoir différentes hypothèses sur les connaissances dont le serveur dispose. Ces connaissances peuvent concerner les documents chiffrés que le serveur héberge ou bien les requêtes de recherches envoyées par le client.

En effet, selon le contexte où s'applique le schéma SSE, le serveur peut connaître la nature des documents chiffrés. Ainsi pour un serveur de livres numérisés, il y aura une forte probabilité que celui-ci héberge de grands classiques littéraires. Le serveur pourra alors supposer raisonnablement connaître certains clairs des documents chiffrés. Il lui restera alors à trouver le document chiffré correspondant pour en déduire des informations sur les autres documents.

Exemple 4.2. *Soit un schéma* SSE *de profil de fuite* L4 *utilisé entre un client et un serveur de livres numérisés. Le serveur suppose qu'il héberge "À la recherche du temps perdu" de M. Proust. S'il arrive à déterminer le chiffré correspondant, le serveur pourra alors déterminer le sens de tous les substitués des autres livres si les mots-clefs sont présents dans le livre clair connu.*

Outre les documents chiffrés, le serveur est en lien avec le client par les recherches que ce dernier lui envoie. Nous pouvons supposer que le serveur connaît un certain nombre d'entres elles. En effet, selon les informations qu'il possède sur le client du schéma SSE, le serveur peut connaître plus ou moins son comportement. Ainsi, en anticipant les recherches du client, le serveur pourra savoir que les documents qu'il retourne possèdent le mot-clef correspondant à la recherche anticipée.

4.1.4 Objectifs des attaques

Nous définissons ici les deux objectifs principaux pour le serveur lorsque celui-ci est vu comme un attaquant.

Définition 4.3 (*Query Recovery*)**.** *L'objectif de la récupération des requêtes ou Query Recovery, noté* QR*, est que le serveur puisse déterminer la signification des requêtes que le client réalise, c'est-à-dire à quel mot-clef correspond telle recherche.*

Définition 4.4 (*Partial Plaintext Recovery*)**.** *L'objectif de la récupération du contenu des documents chiffrés ou Partial Plaintext Recovery, noté* PR*, est que le serveur puisse reconstruire autant que possible l'ensemble documentaire du client.*

Il est à noter que ces deux objectifs sont liés. En effet, dès qu'une requête de recherche est déterminée nous pouvons savoir quels sont les documents contenant le mot-clef associé. Inversement, si nous avons le recouvrement total d'un document chiffré et qu'une requête de recherche retourne ce document alors nous saurons que l'un des mots-clefs présent dans le document correspond à cette requête de recherche.

Remarque 4.1. *D'autres objectifs plus faibles pour le serveur sont possibles. Il peut s'agir par exemple de connaître la présence d'un certain document clair parmis les documents chiffrés ou bien encore d'associer à un document clair connu sa version chiffrée.*

§ 4.2 Mise en œuvre des attaques

4.2.1 Ensembles documentaires utilisés

Les attaques que nous allons présenter dans la suite de ce chapitre ont été réalisées sur cinq ensembles documentaires différents : *Commons*, *Lucene*, *Enron*, *Gutenberg* et *Wikipedia*. Nous résumons les caractéristiques de ces différents ensembles dans la table 4.1.

Collections	Contenu	#D	#W	N
Commons	mailing list	28 997	230 893	3 910 562
Enron	emails	490 369	643 818	47 301 160
Gutenberg	livres	21 602	2 853 955	91 261 811
Lucene	mailing list	58 884	394 481	7 952 794
Wikipedia	encyclopédie	3 607 727	12 816 686	591 292 531

TABLE 4.1 – Caractéristiques des différents ensembles documentaires.

Les ensembles de documents *Commons* et *Lucene* proviennent de deux projets *Apache*, ce sont des listes de diffusion. *Enron* est un ensemble d'*emails* de 158 employés de l'entreprise éponyme révélés par la *Commission fédérale de régulation de l'énergie* lors de l'effondrement de la compagnie. L'ensemble documentaire *Gutenberg* regroupe des livres numérisés libres de droits du projet Gutenberg. Quant à l'ensemble *Wikipedia*, il rassemble tous les articles de la version anglaise de l'encyclopédie libre bien connue.

4.2.2 Implémentation

Les attaques ont été réalisées sur une machine utilisant le système d'exploitation 64 bits Debian GNU/Linux 7.8, équipée de 3,7Go de mémoire vive et d'un processeur Intel® Celeron® G1610 possedant deux cœurs cadencés à 2,60Ghz.

Le premier choix du système de gestion de base de données pour utiliser ces cinq collections a été REDIS. Malheureusement, les tailles des bases de données utilisées étant conséquentes, nous nous sommes orientés vers son alternative non-volatile SSDB.

Le langage de programmation choisi pour écrire les attaques et manipuler les bases de données fut PYTHON 2.7.3.

4.2.3 Objectif et moyen des attaques réalisées

Les attaques que nous avons réalisées ont toutes le même objectif : le récupération du contenu des documents chiffrés (PR). Les attaques sont toutes passives, nous exploitons donc les informations révélées par le profil de fuite considéré. De plus, nous supposons connaître un échantillon de documents clairs connus.

La première étape des attaques sera alors d'associer les documents clairs connus à leur chiffré. Nous réalisons cette association grâce à des propriétés statistiques que nous pouvons mesurer sur les documents clairs comme sur les documents chiffrés. Ces statistiques dépendent donc du profil de fuite du schéma qui a généré la base de données chiffrée.

De façon générale, plus une statistique est discriminante, plus elle est intéressante à utiliser pour l'association entre les documents clairs connus et les documents chiffrés. En effet, plus le nombre de résultats uniques obtenus par la statistique est grand, plus nous pouvons associer de documents clairs connus à leur chiffré.

La deuxième étape pour atteindre notre objectif consiste, lorsque le profil de fuite le permet, d'associer les mots-clefs des documents clairs connus aux mots-clefs des documents chiffrés. Cette association nous permet ensuite de récupérer partiellement ou entièrement le contenu des autres documents chiffrés.

Remarque 4.2. *En pratique, nous réalisons nos attaques sur un ensemble de documents textes. L'échantillon de nos clairs connus, noté $\mathcal{I}$, est alors un pourcentage de ces documents pris de façon aléatoire. Les autres documents seront alors vus au travers les informations révélées par le profil de fuite considéré.*

Nous verrons que les étapes décrites ci-dessus se font de plus en plus difficilement à mesure que le profil de fuite rétrécit.

§ 4.3 Cryptanalyse des schémas de recherche de profil $\mathsf{L4}$

4.3.1 Approche par la longueur $\mathsf{L4}$ des documents

La toute première étape de notre cryptanalyse sur le profil de fuite $\mathsf{L4}$ a été de considérer la longueur $\mathsf{L4}$ des documents afin d'associer les documents clairs connus à leur chiffré.

Définition 4.5 (Longueur $\mathsf{L4}$ d'un document)**.** *Soit Π est un schéma* SSE *de profil de fuite $\mathsf{L4}$. Soit d un document composé ℓ mots-clef et soit d^* le chiffré de d obtenu par Π. Nous définissons la longueur $\mathsf{L4}$ de d^* comme*

$$\mathsf{longueur}_{\mathsf{L4}}(d^*) = |\mathsf{profil}^{\mathsf{L4}}_{\mathsf{EDB}}(d^*)| = \ell$$

Par exemple, nous supposons que le serveur connaît un unique document clair et que ce document a une longueur $\mathsf{L4}$ égale à ℓ. Nous supposons également que la base de données chiffrée contient deux documents possèdant des longueurs $\mathsf{L4}$ différentes et dont l'une est égale à ℓ. Le serveur pourra alors associer le document clair au document chiffré qui possède une longueur $\mathsf{L4}$ égale à ℓ. Par contre, si les deux documents chiffrés ont tous les deux une longueur $\mathsf{L4}$ égale à ℓ, le serveur ne pourra pas déterminer le chiffré du document clair qu'il connaît.

Nous présentons dans la table 4.2 le nombre de documents possédant une longueur $\mathsf{L4}$ unique dans les différents ensembles documentaires étudiés. Comme nous pouvons le voir, les ensembles *Commons*, *Enron* et *Lucene* possèdent un faible nombre de documents à longeur $\mathsf{L4}$ unique. L'anomalie présentée par l'ensemble *Gutenberg* s'explique par la diversité de ses documents. En effet, un livre contenant bien plus de mots-clefs qu'un *email*, il y a une faible probabilité que deux livres possèdent un même nombre de mots-clefs et donc une même longueur $\mathsf{L4}$.

Ces résultats sur le nombre de longueurs $\mathsf{L4}$ uniques montrent que cette statistique n'est pas suffisemment discriminante pour pouvoir associer un maximum de documents clairs connus à leur chiffré.

Ensembles documentaires	#D	#Longueur L4 unique	%
Commons	28 997	378	0.013
Enron	490 369	8 749	0.018
Gutenberg	21 602	15 515	0.718
Lucene	58 884	441	0.007

TABLE 4.2 – Nombre de documents à longueur L4 unique.

4.3.2 Approche par le ratio L4 des documents

La statistique sur les longueurs L4 n'étant pas suffisemment discrimante, pour associer les documents clairs connus à leur chiffré, nous définissons ci-dessous le ratio L4 d'un document.

Définition 4.6 (Ratio L4 d'un document)**.** *Soit* Π *un schéma* SSE *ayant un profil de fuite* L4*. Soit* d *un document composé de* ℓ *mots-clefs dont* ℓ_0 *sont distincts. Soit* d^* *le chiffré de* d *obtenu par* Π*. Nous définissons le ratio* L4 *de* d^* *comme*

$$\mathsf{ratio}_{\mathsf{L4}}(d^*) = \frac{\#\{k : k \in \mathsf{profil}^{\mathsf{L4}}_{\mathsf{EDB}}(d^*)\}}{|\mathsf{profil}^{\mathsf{L4}}_{\mathsf{EDB}}(d^*)|} = \frac{\ell_0}{\ell}$$

Remarque 4.3. *Nous signalons que le ratio* L4 *correspond à la proportion de mots-clefs uniques présents dans le document.*

Par exemple, nous supposons que le serveur connaît un unique document clair et que ce document a un ratio L4 égale à r. Nous supposons également que la base de données chiffrée contient deux documents possèdant des ratios L4 différents et dont l'un est égale à r. Le serveur pourra alors associer le document clair au document chiffré qui possède un ratio L4 égale à r. Par contre, si les deux documents chiffrés ont tous les deux un ratio L4 égale à r, le serveur ne pourra pas déterminer le chiffré du document clair qu'il connaît.

Nous présentons dans la table 4.3 le nombre de documents possédant un ratio L4 unique dans les différents ensembles documentaires étudiés.

Ensembles documentaires	#D	#Ratio L4 unique	%
Commons	28 997	8 624	0.297
Enron	490 369	8 748	0.018
Gutenberg	21 602	21 371	0.989
Lucene	58 884	11 824	0.201

TABLE 4.3 – Nombre de documents à ratio L4 unique.

Nous constatons que cette statistique est davantage discriminante, ce qui conduit à une première tentative d'attaque dont nous présentons l'algorithme dans la figure 4.1.

Cette attaque consiste tout d'abord à déterminer les chiffrés des documents présents dans l'échantillon $\mathcal{I}$. En considérant un document connu de $\mathcal{I}$, nous déterminons les chiffrés possédant le même ratio L4. S'il existe un unique chiffré vérifiant cette statistique, nous pouvons alors l'associer avec certitude au document clair considéré. Comme

Algorithme : Attaque $\mathsf{L4}$

Entrées : EDB, D^* et $\mathcal{I} \subseteq \mathsf{D}$
Sortie : $\mathsf{W}_{\mathsf{rec}} \subseteq \mathsf{W}$

$\mathsf{W}_{\mathsf{rec}} \leftarrow \varnothing$;

pour chaque $d \in \mathcal{I}$ **faire**
  $\mathsf{A} = \{i : \mathsf{ratio}_{\mathsf{L4}}(d_i^*) = \mathsf{ratio}_{\mathsf{L4}}(d), d_i^* \in \mathsf{D}^*\}$;
  si $\#\mathsf{A} = 1$ **alors**
    $\mathsf{W}_{\mathsf{rec}} \leftarrow \mathsf{W}_{\mathsf{rec}} \cup \mathsf{W}_i$;
retourner $\mathsf{W}_{\mathsf{rec}}$

FIGURE 4.1 – Algorithme de l'attaque utilisant le ratio $\mathsf{L4}$.

le profil de fuite $\mathsf{L4}$ préserve l'ordre des mots-clefs dans les documents chiffrés, nous pouvons associer les mots-clefs du document clair aux mots-clefs du documents chiffré. Nous représentons cette connaissance dans l'algorithme de la figure 4.1 par l'ensemble $\mathsf{W}_{\mathsf{rec}}$ contenant l'ensemble des mots-clefs dont nous connaissons le chiffré. Grâce à l'ensemble $\mathsf{W}_{\mathsf{rec}}$, nous pouvons récupérer partiellement ou totalement le contenu des autres documents chiffrés.

Nous exposons dans le graphe de la figure 4.2, les résultats de l'attaque utilisant le ratio $\mathsf{L4}$ réalisée sur l'ensemble documentaire *Commons*. Comme nous le voyons sur ce graphe, la connaissance de 20% des documents clairs de l'ensemble documentaire permet de récupérer au moins 70% du contenu de plus de 25 000 documents (sur un total de 28 997 documents).

4.3.3 Approche par le calque $\mathsf{L4}$ des documents

Nous définissons ci-dessous le calque $\mathsf{L4}$ d'un document. Cette statistique rassemble l'information fournie par le ratio $\mathsf{L4}$ et l'ordre des mots-clefs dans les documents.

Définition 4.7 (Calque $\mathsf{L4}$ d'un document)**.** *Soit* Π *un schéma* SSE *de profil de fuite* $\mathsf{L4}$*. Soit* d *un document composé de* ℓ *mots-clefs et soit* d^* *le chiffré de* d *obtenu par* Π*. Nous définissons le calque* $\mathsf{L4}$ *d'un document comme*

$$\mathsf{calque}_{\mathsf{L4}}(d^*) = \left(k : \min_{1 \leqslant k \leqslant \ell} \mathsf{profil}^{\mathsf{L4}}_{\mathsf{EDB}}(d^*)[k] = \mathsf{profil}^{\mathsf{L4}}_{\mathsf{EDB}}(d^*)[j] \text{ pour } 1 \leqslant j \leqslant \ell\right)$$

Exemple 4.3. *Soit* d^* *le chiffré de* $d = (w_1, w_2, w_2, w_4, w_3, w_1, w_3)$*. Nous avons alors*

$$\mathsf{calque}_{\mathsf{L4}}(d^*) = (1, 2, 2, 4, 5, 1, 5)$$

où $\mathsf{profil}^{\mathsf{L4}}_{\mathsf{EDB}}(d^*) = (1, 2, 2, 4, 3, 1, 3)$

Nous présentons dans la table 4.4 le nombre de documents possédant un calque $\mathsf{L4}$ unique dans les différents ensembles documentaires étudiés.

Nous constatons que cette statistique est très discrimante puisqu'au moins 93% des documents de chacun des ensembles documentaires possèdent un calque $\mathsf{L4}$ unique. Nous réalisons alors la même attaque que celle utilisant le ratio $\mathsf{L4}$ (4.1) en remplaçant cette

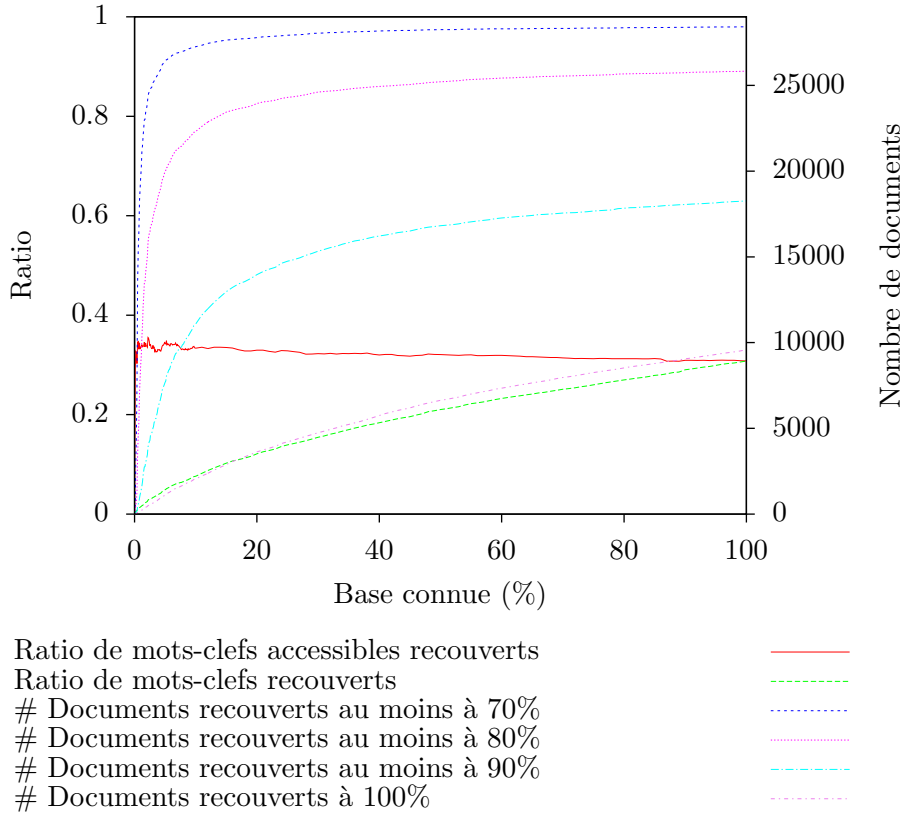

FIGURE 4.2 – Résultat de l'attaque par ratio unique sur la collection *Commons*.

Ensembles documentaires	#D	#Calque L4 unique	%
Commons	28 997	27 979	0.964
Enron	490 369	458 458	0.935
Gutenberg	21 602	21 526	0.996
Lucene	58 884	57 855	0.996

TABLE 4.4 – Nombre de documents à calque L4 unique.

statistique par celle du calque L4. Nous présentons l'algorithme de cette attaque dans la figure 4.3.

Cette attaque consiste tout d'abord à déterminer les chiffrés des documents clairs connus présents dans l'échantillon $\mathcal{I}$. En considérant $d \in \mathcal{I}$, nous déterminons les chiffrés possédant le même calque L4. S'il existe un unique chiffré d_i^* vérifiant cette statistique, nous pouvons alors l'associer avec certitude au document clair considéré. Comme le profil de fuite L4 préserve l'ordre des mots-clefs dans les documents chiffrés, nous pouvons associer les mots-clefs du document clair W_i aux mots-clefs du documents chiffré. Nous représentons cette connaissance dans l'algorithme de la figure 4.3 par l'ensemble $\mathsf{W}_{\mathsf{rec}}$ contenant l'ensemble des mots-clefs dont nous connaissons le chiffré. Grâce à l'ensemble $\mathsf{W}_{\mathsf{rec}}$, nous pouvons récupérer partiellement ou totalement le contenu des autres documents chiffrés.

Algorithme : Attaque $\mathsf{L4}$

Entrées : EDB, D^* et $\mathcal{I} \subseteq \mathsf{D}$
Sortie : $\mathsf{W_{rec}} \subseteq \mathsf{W}$

$\mathsf{W_{rec}} \leftarrow \varnothing$;

pour chaque $d \in \mathcal{I}$ **faire**
  $\mathsf{A} = \{i : \mathsf{calque_{L4}}(d_i^*) = \mathsf{calque_{L4}}(d), d_i^* \in \mathsf{D}^*\}$;
  si $\#\mathsf{A} = 1$ **alors**
    $\mathsf{W_{rec}} \leftarrow \mathsf{W_{rec}} \cup \mathsf{W}_i$;

retourner $\mathsf{W_{rec}}$

FIGURE 4.3 – Algorithme de l'attaque $\mathsf{L4}$ utilisant le calque $\mathsf{L4}$.

4.3.4 Résultats sur la cryptanalyse des schémas de profil $\mathsf{L4}$

Nous exposons dans le graphe de la figure 4.4, les résultats de l'attaque $\mathsf{L4}$ sur l'ensemble documentaire *Commons*.

Nous représentons sur ce graphe deux informations. La première concerne le taux de mots-clefs clairs dont nous avons déterminé la valeur protégée. Ce taux est d'une part calculé par rapport au nombre de mots-clefs présents dans l'échantillon des documents clairs connu (Ratio de mots-clefs accessibles recouverts). D'autre part, il est également calculé par rapport au nombre de mots-clefs total présents dans l'ensemble documentaire *Commons* (Ratio de mots-clefs recouverts).

La seconde information représentée est déduite de l'ensemble des mots-clefs clairs associés. Celle-ci représente le nombre de documents chiffrés dont nous avons reconstruit les clairs. Dans le graphes de la figure 4.4, nous représentons le nombre de documents chiffrés dont nous avons reconstruit les clairs au moins à 70%, 80%, 90% et 100% (# Documents recouverts au moins à 70%, 80%, 90% et 100%).

Nous présentons dans la table 4.5, le taux d'associations (Taux) que des mots-clefs clairs de l'échantillon connu que nous avons réussi à associer à leur valeur protégée. Nous représentons dans les autres colonnes le nombre de documents chiffrés, qui grâce à cet ensemble de mots-clefs associés, ont été reconstruit au moins à 70%, 80%, 90% et 100% (# 70%, 80%, 90%, 100%).

Comme nous le voyons, la connaissance de 5% des documents clairs de l'ensemble documentaire permet de récupérer au moins 80% du contenu de plus de 26 000 documents (sur un total de 28 997 documents).

Les résultats de cette attaque $\mathsf{L4}$ pour les ensembles documentaires *Enron* et *Lucene* sont quant à eux présentés dans l'annexe A.

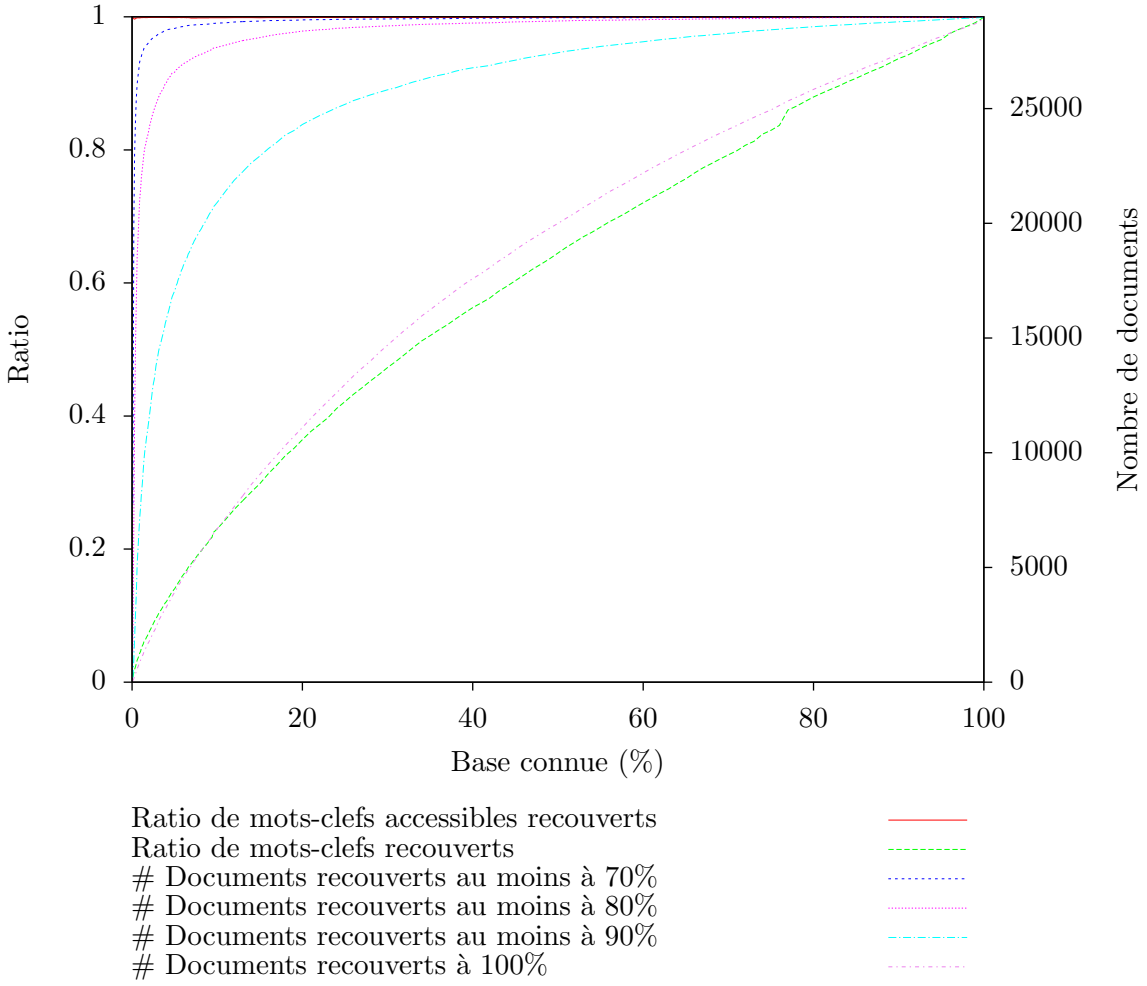

FIGURE 4.4 – Résultat de l'attaque L4 sur la collection *Commons*.

§ 4.4 Cryptanalyse sur les schémas de recherche de profil L3

4.4.1 Approche par la longueur L3 d'un document

Nous rappelons qu'un schéma SSE de profil de fuite L3 révèle au serveur, pour chaque document, le nombre de leurs mots-clefs distincts et leur ordre d'apparition.

La première étape de notre cryptanalyse sur le profil de fuite L3 a été de considérer la longueur L3 des documents afin d'associer les documents clairs connus à leur chiffré.

Définition 4.8 (Longueur L3 d'un document)**.** *Soit* Π *un schéma* SSE *de profil de fuite* L3*. Soit* d *un documents composé de* ℓ_0 *mots-clefs distincts et soit* d^* *le chiffré de* d *obtenu par* Π*. Nous définissons la longueur* L3 *d'un document chiffré comme*

$$\mathsf{longueur}_{\mathsf{L3}}(d^*) = |\mathsf{profil}^{\mathsf{L3}}_{\mathsf{EDB}}(d^*)| = \ell_0$$

Comme nous pouvons le constater dans la figure 4.5, le nombre de documents à longueur L3 unique est très faible dans les différents ensembles documentaires. Cette

%	Taux	# 70%	# 80%	# 90%	# 100%
1	0.99	27 136	21 488	7 631	961
5	0.99	28 489	26 587	17 053	3911
10	0.99	28 721	27 672	20 908	6 692
20	0.99	28 862	28 376	24 308	11 095
30	0.99	28 905	28 601	25 819	14 693
40	0.99	28 935	28 724	26 777	17 583
50	0.99	28 955	28 817	27 435	19 994

FIGURE 4.5 – Résultats de l'attaque L4 sur l'ensemble *Commons*.

statistique n'est donc pas efficace pour obtenir un maximum d'associasions entre les documents clairs connus et leur chiffré.

Ensembles	#D	#Longueur L3	%
Commons	28 997	222	
Enron	490 369	1 232	
Gutenberg	21 602	5 538	
Lucene	58 884	274	

TABLE 4.5 – Nombre de documents de longueur L3 unique.

4.4.2 Similarité de deux documents

Suite à l'observation sur les longueurs L3 uniques, nous nous sommes orientés vers la notion de similarité entre deux documents comme définie par dans []. L'idée est de considérer un couple de documents clairs connus et de calculer une mesure de similarité entre ces documents. Nous espérons que cette mesure soit discriminante afin de trouver un unique couple de documents chiffrés ayant la même similarité dans le but d'associer un ensemble de documents clairs à leur chiffré.

Remarque 4.4. *Nous signalons que les deux documents clairs choisis doivent être de longueur* L3 *différentes. En supposant que ce ne soit pas le cas et que nous trouvions un unique couple de documents chiffrés possédant la même similarité, il nous serait alors impossible de savoir quel chiffré correpond au clair.*

Nous présentons alors trois mesures de similarité : le simple match, la similarité de Jaccard et la similarité de Dice.

Définition 4.9 (Simple match)**.** *Soit* Π *un schéma* SSE *de profil de fuite* L3*. Soit* d_1 *et* d_2 *deux documents et soit* W_1 *et* W_2 *leur ensemble respectifs de leurs mots-clefs distincts. Nous définissons le simple match du couple* (d_1^*, d_2^*) *comme*

$$\mathsf{match}(d_1^*, d_2^*) = \#\left\{k : k \in \mathsf{profil}^{\mathsf{L3}}_{\mathsf{EDB}}(d_1^*), k \in \mathsf{profil}^{\mathsf{L3}}_{\mathsf{EDB}}(d_2^*)\right\} = \#(\mathsf{W}_1 \cap \mathsf{W}_2)$$

Définition 4.10 (Similarité de Jaccard)**.** *Soit* Π *un schéma* SSE *de profil de fuite* L3*. Soit* d_1 *et* d_2 *deux documents et soit* W_1 *et* W_2 *leur ensemble respectifs de leurs mots-clefs distincts. Nous définissons la similarité de Jaccard du couple* (d_1^*, d_2^*) *comme*

$$\mathsf{jaccard}(d_1^*, d_2^*) = \frac{\#\left\{k : k \in \mathsf{profil}^{\mathsf{L3}}_{\mathsf{EDB}}(d_1^*), k \in \mathsf{profil}^{\mathsf{L3}}_{\mathsf{EDB}}(d_2^*)\right\}}{\#\left(\{m : m \in \mathsf{profil}^{\mathsf{L3}}_{\mathsf{EDB}}(d_1^*)\} \cup \{n : n \in \mathsf{profil}^{\mathsf{L3}}_{\mathsf{EDB}}(d_2^*)\}\right)} = \frac{\#(\mathsf{W}_1 \cap \mathsf{W}_2)}{\#(\mathsf{W}_1 \cup \mathsf{W}_2)}$$

Définition 4.11 (Similarité de Dice)**.** *Soit* Π *un schéma* SSE *de profil de fuite* L3*. Soit* d_1 *et* d_2 *deux documents et soit* W_1 *et* W_2 *leur ensemble respectifs de leurs mots-clefs distincts. Nous définissons la similarité de Dice du couple* (d_1^*, d_2^*) *comme*

$$\mathsf{dice}(d_1^*, d_2^*) = \frac{\#\left\{k : k \in \mathsf{profil}^{\mathsf{L3}}_{\mathsf{EDB}}(d_1^*), k \in \mathsf{profil}^{\mathsf{L3}}_{\mathsf{EDB}}(d_2^*)\right\}}{|\mathsf{profil}^{\mathsf{L3}}_{\mathsf{EDB}}(d_1^*)| + |\mathsf{profil}^{\mathsf{L3}}_{\mathsf{EDB}}(d_2^*)|} = \frac{\#\left(\mathsf{W}_1 \cap \mathsf{W}_2\right)}{\#\mathsf{W}_1 + \#\mathsf{W}_2}$$

Afin de déterminer si l'une de ces similarités est discriminante, nous réalisons l'-expérience suivante. Pour commencer, nous choisissons deux documents clairs d_1 et d_2 dont le nombre de leur mots-clefs distincts respectif diffère. Puisqu'un schéma de profil de fuite L3 révèle les longueurs L3 de l'ensemble des documents chiffrés, nous déterminons l'ensemble des documents chiffrés candidats à chacun des documents clairs choisis. En effet, le document chiffré correspondant à un document clair possède nécessairement une longueur L3 égale au nombre de mots-clefs distincts du document clair. À l'aide de ces deux ensembles de candidats, nous pouvons calculer chacune des similarités présentées pour tous les couples candidats. Pour une mesure de similarité, plus il y a de couples de documents chiffrés possédant la même mesure que le coule (d_1, d_2), moins la mesure de similarité est discriminante.

La pratique nous a montré pour l'ensemble documentaire *Commons* que le nombre de couples chiffrés candidats ayant la même mesure qu'un couple de documents clairs est très élevé quelque soit la mesure de similarité utilisée parmis les trois. Ces trois mesures ne permettent donc pas d'obtenir d'associations entre les documents clairs et les documents chiffrés.

4.4.3 Similarité de deux documents en considérant l'ordre des mots-clefs

Les similarités que nous avons étudiées ne tiennent pas compte de l'information révélée sur l'ordre des mots-clefs dans les documents. Nous essayons de réintégrer cette notion pour construire une similarité discriminante.

Une telle similarité doit donc associer à un couple de documents une mesure considérant les mots-clefs partagés par les deux documents ainsi que leur ordre d'apparition dans chacun des deux documents. Nous pouvons voir cela un masque co-induit par les deux documents.

Définition 4.12 (Masque L3 co-induit)**.** *Soit* Π *un schéma* SSE *de profil de fuite* L3*. Soit* d_1 *et* d_2 *dont les ensembles de mots-clefs distincts respectifs sont* W_1 *et* W_2*. Nous notons* $S = \{k : k \in \mathsf{profil}^{\mathsf{L3}}_{\mathsf{EDB}}(d_1^*), k \in \mathsf{profil}^{\mathsf{L3}}_{\mathsf{EDB}}(d_2^*)\}$ *et* $\mathsf{W}_0 = \mathsf{W}_1 \cap \mathsf{W}_2$*. Nous définissons le masque* L3 *co-induit du* (d_1^*, d_2^*) *comme*

$$\begin{aligned}\mathsf{masque}_{\mathsf{L3}}(d_1^*, d_2^*) &= \left(\mathsf{bin}\left(\sum_{k \in S} 2^{\mathsf{index}(k, d_1^*)}\right), \mathsf{bin}\left(\sum_{k \in S} 2^{\mathsf{index}(k, d_2^*)}\right)\right) \\ &= \left(\mathsf{bin}\left(\sum_{w \in \mathsf{W}_0} 2^{\min_{1 \leqslant c \leqslant \ell_1} d_1[c]=w}\right), \mathsf{bin}\left(\sum_{w \in \mathsf{W}_0} 2^{\min_{1 \leqslant c \leqslant \ell_1} d_2[c]=w}\right)\right)\end{aligned}$$

où $\mathsf{bin}(m)$ *est la représentation binaire de* m *et* $\mathsf{index}(k, d^*) = j$ *si* $\mathsf{profil}^{\mathsf{L3}}_{\mathsf{EDB}}(d^*)[j] = k$*.*

Remarque 4.5. *Nous tenons à préciser que nous ne considérons pas le masque co-induit comme une mesure de similarité puisque les mots-clefs positionnés à la fin d'un document ont un poids plus important.*

Afin de déterminer si cette nouvelle similarité est discriminante, nous réalisons la même expérience que pour la similarité simple match, la similarité de Jaccard et la similarité de Dice.

La pratique nous a montré pour l'ensemble documentaire *Commons* que cette nouvelle similarité est discriminante puisqu'il y a de façon quasi systématique un unique couple chiffré candidat ayant la même mesure que le couple de documents clairs considéré. Nous utilisons alors la masque co-induit par un couple de documents clairs pour attaquer une base de données chiffrée qui a été générée par un schéma de profil de fuite $\mathsf{L3}$.

4.4.4 Algorithme de l'attaque sur le profil de fuite $\mathsf{L3}$

L'algorithme de cette attaque est présentée dans la figure 4.6. Nous en détaillons ici le fonctionnement.

En considérant deux documents d_1 et d_2 dans $\mathcal{I}$ dont les cardinaux de leur ensemble de mots-clefs distincts diffèrent, nous déterminons les chiffrés possédant le même masque co-induit. S'il existe un unique couple de chiffrés d_1^* et d_2^* vérifiant cette similarité, nous pouvons alors associer avec certitude chacun des chiffrés aux documents clairs considérés.

Comme le profil de fuite $\mathsf{L3}$ préserve l'ordre des mots-clefs dans les documents chiffrés, nous pouvons associer les mots-clefs des deux documents clairs aux mots-clefs des deux documents chiffrés.

Pour associer les documents clairs connus restant de l'échantillon $\mathcal{I}$ à leur chiffré, nous utilisons le couple de documents clairs que nous venons d'associer à leur chiffré. Soit d un document de $\mathcal{I}$ qui n'a pas encore été associer à son chiffré. Nous calculons alors les masques co-induits par les couples (d_1, d) et (d_2, d) et déterminons l'ensemble des chiffrés générant ces deux mêmes masques. Si un seul chiffré véréfie ces deux mesures, celui-ci correspond alors au chiffré de d.

Le profil de fuite $\mathsf{L3}$ préservant l'ordre des mots-clefs chiffrés, nous pouvons associer les mots-clefs de d à ceux de son chiffré. Nous représentons cette connaissance dans l'algorithme de la figure 4.6 par l'ensemble $\mathsf{W}_{\mathsf{rec}}$ contenant l'ensemble des mots-clefs dont nous connaissons le chiffré.

Grâce à l'ensemble $\mathsf{W}_{\mathsf{rec}}$, nous pouvons alors récupérer partiellement ou totalement le contenu des autres documents chiffrés.

4.4.5 Résultats sur la cryptanalyse des schémas de profil $\mathsf{L3}$

Nous exposons dans le graphe de la figure 4.7, les résultats de l'attaque $\mathsf{L3}$ sur l'ensemble documentaire *Commons*.

Nous représentons sur ce graphe deux informations. La première concerne le taux de mots-clefs clairs dont nous avons déterminé la valeur protégée. Ce taux est d'une part calculé par rapport au nombre de mots-clefs présents dans l'échantillon des documents clairs connu (Ratio de mots-clefs accessibles recouverts). D'autre part, il est également calculé par rapport au nombre de mots-clefs total présents dans l'ensemble documentaire

Algorithme : Attaque L3

Entrées : EDB, D^* et $\mathcal{I} \subseteq \mathsf{D}$
Sortie : $\mathsf{W}_{\mathsf{rec}} \subseteq \mathsf{W}$

$\mathsf{A} \leftarrow \emptyset$;

tant que $\#\mathsf{A} \neq 1$ **faire**
  $(d_1, d_2) \xleftarrow{\$} \mathcal{I}$, avec $\#\mathsf{W}_1 \neq \#\mathsf{W}_2$;
  $\mathsf{A} = \{(d_i^*, d_j^*) : \mathsf{masque}(d_i^*, d_j^*) = \mathsf{masque}(d_1, d_2), d_i^* \in \mathsf{D}^*, d_j^* \in \mathsf{D}^*\}$;

$\mathsf{W}_{\mathsf{rec}} \leftarrow \mathsf{W}_1 \cup \mathsf{W}_2$;

pour chaque $d \in \mathcal{I} \setminus \{d_1, d_2\}$ **faire**
  $\delta_1 \leftarrow \mathsf{masque}(d_1, d)$;
  $\delta_2 \leftarrow \mathsf{masque}(d_2, d)$;
  $\mathsf{B} = \{d^* : \mathsf{masque}(d_1^*, d^*) = \delta_1, \mathsf{masque}(d_2, d^*) = \delta_2, d^* \in \mathsf{D}^*\}$;
  si $\#\mathsf{B} = 1$ **alors**
    $\mathsf{W}_{\mathsf{rec}} \leftarrow \mathsf{W}_{\mathsf{rec}} \cup \mathsf{W}_{\mathsf{d}}$;

retourner $\mathsf{W}_{\mathsf{rec}}$

FIGURE 4.6 – Algorithme de l'attaque sur le profil de fuite L3.

Commons (Ratio de mots-clefs recouverts).

La seconde information représentée est déduite de l'ensemble des mots-clefs clairs associés. Celle-ci représente le nombre de documents chiffrés dont nous avons reconstruit les clairs. Dans le graphes de la figure 4.7, nous représentons le nombre de documents chiffrés dont nous avons reconstruit les clairs au moins à 70%, 80%, 90% et 100% (# Documents recouverts au moins à 70%, 80%, 90% et 100%).

Nous présentons dans la table 4.8, le taux d'associations (Taux) que des mots-clefs clairs de l'échantillon connu que nous avons réussi à associer à leur valeur protégée. Nous représentons dans les autres colonnes le nombre de documents chiffrés, qui grâce à cet ensemble de mots-clefs associés, ont été reconstruit au moins à 70%, 80%, 90% et 100% (# 70%, 80%, 90%, 100%).

Comme nous le voyons, la connaissance de 5% des documents clairs de l'ensemble documentaire permet de récupérer au moins 80% du contenu de plus de 26 000 documents (sur un total de 28 997 documents). Notre attaque L3 est tout aussi efficace que l'attaque L4 malgré la perte de l'information sur le nombre d'apparition des mots-clefs dans un document.

Les résultats de cette attaque L3 pour les ensembles documentaires *Gutenberg* et *Lucene* sont quant à eux présentés dans l'annexe A.

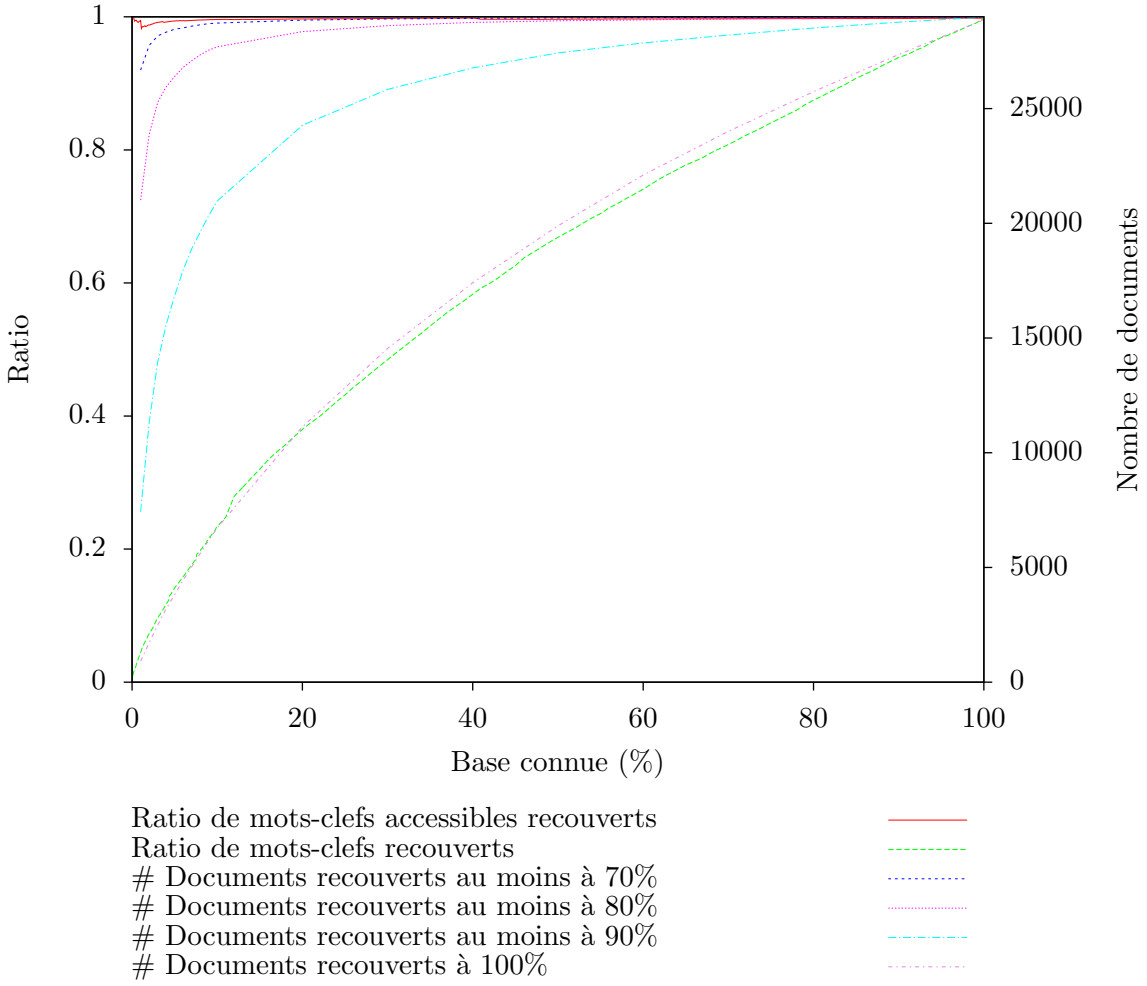

FIGURE 4.7 – Résultat de l'attaque L3 sur la collection *Commons*.

§ 4.5 Cryptanalyse sur les schémas de recherche de profil L2

4.5.1 Association entre documents clairs et documents chiffrés

Une base de données générée par un schéma SSE ayant un profil de fuite L2 ne révèle que les protégés des mots-clefs associés à chacun des documents référencés. L'idée est alors d'utiliser comme mesure discriminante pour associer les documents clairs connus à leur chiffré, le cardinal d'une intersection de mots-clefs protégés associés à deux documents, correspondant à la similarité du match L2.

Définition 4.13 (Match L2)**.** *Soit* Π *un schéma* SSE *de profil de fuite* L2*. Soit* d_1 *et* d_2 *deux documents et soit* W_1 *et* W_2 *leur ensemble respectif de leurs mots-clefs distincts. Nous définissons le match* L2 *du couple* (d_1^*, d_2^*) *comme*

$$\mathsf{match}_{\mathsf{L2}}(d_1^*, d_2^*) = \#\left\{k : k \in \mathsf{profil}^{\mathsf{L2}}_{\mathsf{EDB}}(d_1^*), k \in \mathsf{profil}^{\mathsf{L2}}_{\mathsf{EDB}}(d_2^*)\right\} = \#(\mathsf{W}_1 \cap \mathsf{W}_2)$$

Nous remarquons que le match L2 défini la même mesure que la similarité du simple match présentée dans la cryptanalyse sur le profil de fuite L3. Donnant trop de candidats

%	Taux	# 70%	# 80%	# 90%	# 100%
1	0.99	26 680	21 009	7 428	917
5	0.99	28 454	26 392	16 840	3 815
10	0.99	28 722	27 689	20 974	6 728
20	0.99	28 853	28 352	24 271	11 129
30	0.99	28 903	28 613	25 835	14 543
40	0.99	28 935	28 751	26 768	17 403
50	0.99	28 952	28 822	27 421	19 886

FIGURE 4.8 – Résultats de l'attaque L3 sur l'ensemble *Commons*.

pour permettre l'association entre les documents clairs connus et les documents chiffrés nous considérons un troisième document.

Un troisième candidat permet d'ajouter à la mesure du match L2 le cardinal de deux intersections de deux documents le cardinal d'une intersection de trois documents.

Exemple 4.4. *Soit trois documents* $d_1 = (w_1, w_2, w_3)$, $d_2 = (w_1, w_3)$ *et* $d_3 = (w_1, w_2)$. *Nous avons alors*

$$\begin{aligned}\mathsf{match}_{\mathsf{L2}}(d_1^*, d_2^*, d_3^*) &= (\#(\mathsf{W}_1 \cap \mathsf{W}_2), \#(\mathsf{W}_1 \cap \mathsf{W}_3), \#(\mathsf{W}_2 \cap \mathsf{W}_3), \#(\mathsf{W}_1 \cap \mathsf{W}_2 \cap \mathsf{W}_3)) \\ &= (2, 2, 1, 1)\end{aligned}$$

Dans la pratique, nous commençons par considérer la première intersection afin de réduire le nombre de candidats pour les trois documents. Nous continuons en considérant parmi ces candidats la deuxième intersection afin encore une fois de réduire le nombre de candidats pour les trois documents. De la même façon nous considérons ensuite la troisième puis la quatrième intersection. Bien que le nombre de candidats ait diminué, il reste en pratique toujours plusieurs candidats possibles pour le triplet considéré.

Nous ajoutons alors un quatrième candidat à la mesure du match L2 et nous nous attendons alors à ce que le nombre de candidats se réduise à chaque intersection. Nous définissons de façon générale, le match L2 d'ordre p.

Définition 4.14 (Match L2 d'ordre p)**.** *Le match* L2 *d'ordre* p*, noté* $\mathsf{match}_{\mathsf{L2}}{}^p$*, correspond à la liste de tous les cardinaux de toutes les intersections de toutes les parties de* p *documents.*

Grâce à l'information donnée par le match L2 d'ordre p, nous nous attendons heuristiquement à ce qu'il n'y ait plus qu'un p-uplet chiffré correspondant avec toutes les caractéristiques du p-uplet de clairs. Précisons que les p documents considérés doivent posséder des longueurs L2 deux-à-deux différentes afin de pouvoir associer les chiffrés aux clairs.

Définition 4.15 (Longueur L2 d'un document)**.** *Soit* Π *un schéma* SSE *de profil de fuite* L2*. Soit* d *un documents composé de* ℓ_0 *mots-clefs distincts et soit* d^* *le chiffré de* d *obtenu par* Π*. Nous définissons la longueur* L2 *d'un document chiffré comme*

$$\mathsf{longueur}_{\mathsf{L2}}(d^*) = |\mathsf{profil}^{\mathsf{L2}}_{\mathsf{EDB}}(d^*)| = \ell_0$$

Algorithme : M1

Entrées : EDB, D^* et $\mathcal{I} \subseteq \mathsf{D}$
Sortie : D_0

$\mathsf{A} \leftarrow \emptyset$;
tant que $\#\mathsf{A} \neq 1$ **faire**
  $p \leftarrow 2$;
  $\mathsf{D}_0 \leftarrow \mathcal{I}^p$ avec les p documents triés en fonction de leur nombre de candidats ;
  $\mathsf{A} = \{(i_1, \ldots, i_p) : \mathsf{match}_{\mathsf{L2}}{}^p(d^*_{i_1}, \ldots, d^*_{i_p}) = \mathsf{match}_{\mathsf{L2}}{}^p(\mathsf{D}_0), d_{i_j} \in \mathsf{D}^*\}$;
  $p \leftarrow p + 1$;
retourner D_0 ;

FIGURE 4.9 – Algorithme M1 d'associations de documents avec le match L2.

Nous présentons dans la figure 4.9 l'algorithme utilisant le match L2 d'ordre p pour associer p documents clairs à leur chiffré.

Les deux ensembles documentaires que nous avons considérés pour la cryptanalyse du profil de fuite L2 (*Commons* et Lucene) nous ont montré que nous avons besoin d'aller à l'ordre 4 afin d'associer un ensemble de docments clairs à leur chiffré. Cette première étape, l'amorce, domine le temps de calcul. Elle va nous permettre d'associer les autres documents clairs connus de l'échantillon plus efficacement. Nous présentons l'algorithme d'association dans la figure 4.10.

Algorithme : M2

Entrées : EDB, D^*, D_0 et $\mathcal{I} \subseteq \mathsf{D}$
Sortie : D_1

$\mathsf{D}_1 \leftarrow \mathsf{D}_0$;
pour chaque $d \in \mathcal{I} \setminus \mathsf{D}_0$;
faire
  $\mathsf{A} = \{i : \mathsf{match}_{\mathsf{L2}}{}^p(\mathsf{D}_0{}^* \cup \{d^*_i\}) = \mathsf{match}_{\mathsf{L2}}{}^p(\mathsf{D}_0 \cup \{d\}), d^*_i \in \mathsf{D}^*\}$;
si $\#\mathsf{A} \neq 1$ **alors**
  $\mathsf{D}_1 \leftarrow \mathsf{D}_1 \cup \{d\}$;
retourner D_1 ;

FIGURE 4.10 – Algorithme M2 pour associer les documents restant de $\mathcal{I}$.

Nous avons alors avec ces algorithmes le moyen de déterminer les chiffrés des documents clairs connus de l'échantillon.

4.5.2 Associer les mots-clefs avec un index inversé ordonné

Bien que nous pouvons associer un ensemble de documents clairs à leur chiffré, il reste à déterminer l'association entre les mots-clefs des documents clairs et les mots-clefs protégés qui référencent ces chiffrés associés.

L'information sur l'ordre des mots-clefs dans les documents étant perdue avec les schémas SSE ayant un profil de fuite L2, cette association ne peut plus se faire naturellement comme pour les schémas ayant un profil de fuite L3 et L4. En d'autres termes, nous cherchons la bonne bijection reliant les mots-clefs clairs et les mots-clefs protégés.

L'idée est la suivante. Nous considérons tout d'abord la partie D_1 de l'échantillon $\mathcal{I}$ dont les documents chiffrés respectifs ont été déterminés. Nous construisons son index inversé ordonné, noté $\mathsf{inv}_{\mathsf{ord}}(\mathsf{D}_1)$, correspondant à la construction suivante. Soit une table dont les entrées sont les mots-clefs des documents de D_1. La valeur de la table sous l'entrée d'un mot-clef est l'ensemble des identifiants des documents chiffrés tels que les clairs associés contiennent ce mot-clef. La dernière étape consiste à trier la table de telle sorte que la première entrée soit celle correspondant au mot-clef contenant le plus d'identifiants et que la dernière soit celle correspondant au mot-clef contenant le moins d'identifiants.

Exemple 4.5. *Soit* $\mathsf{D}_1 = (d_1, d_2, d_3$ *un ensemble de trois documents clairs où* $d_1 = (w_1, w_2, w_3)$*,* $d_2 = (w_1, w_2)$ *et* $d_3 = (w_1)$*. L'index inversé ordonné associé à* D_1 *est donc*

	$\mathsf{inv}_{\mathsf{ord}}(\mathsf{D}_1)$
w_1	$\{1, 2, 3\}$
w_2	$\{1, 2\}$
w_3	$\{1\}$

Suite à cette construction, nous pouvons construire l'algorithme M3 présenté dans la figure 4.11.

Algorithme : M3

Entrées : EDB et D_1
Sortie : $\mathsf{W}_{\mathsf{rec}} \subseteq \mathsf{W}$

$\mathsf{I} \leftarrow \mathsf{inv}_{\mathsf{ord}}(\mathsf{D}_1)$;
$\mathsf{W}_{\mathsf{rec}} \leftarrow \varnothing$;
$\mathsf{W}_{\mathsf{ign}} \leftarrow \varnothing$;
pour chaque $w \in \mathsf{I}$ **faire**
  si $\#\left(\cap_{i \in \mathsf{I}[w]} \mathsf{W}_i\right) \setminus (\mathsf{W}_{\mathsf{ign}} \cup \mathsf{W}_{\mathsf{rec}})$ **alors**
    $\mathsf{W}_{\mathsf{rec}} \leftarrow \mathsf{W}_{\mathsf{rec}} \cup \{w\}$;
  sinon
    $\mathsf{W}_{\mathsf{ign}} \leftarrow \mathsf{W}_{\mathsf{ign}} \cup \{w\}$;
retourner $\mathsf{W}_{\mathsf{rec}}$

FIGURE 4.11 – Algorithme M3 permettant d'associer les mots-clefs de D_1.

Considérons dans cet algorithme (4.11)un index inversé ordonné $\mathsf{inv}_{\mathsf{ord}}(\mathsf{D}_1)$ déterminant si possible les associations entre mots-clefs et mots-clefs protégés. Nous espérons tout d'abord obtenir un maximum de lignes uniques. En effet, considérons la première ligne de $\mathsf{inv}_{\mathsf{ord}}(\mathsf{D}_1)$ et supposons qu'elle soit unique. L'intersection des ensembles des mots-clefs protégés associés aux indices permettra de déterminer le protégé du mot-clef clair associé à la première ligne de $\mathsf{inv}_{\mathsf{ord}}(\mathsf{D}_1)$.

Si maintenant la seconde ligne de l'index inversé ordonné $\mathsf{inv}_{\mathsf{ord}}(\mathsf{D}_1)$ est aussi unique, deux cas sont possibles. Soit l'intersection des ensembles des mots-clefs protégés associés aux indices nous donne un unique mot-clef protégé correspondant au mot-clef clair considéré, soit nous obtenons deux protégés. Ce deuxième cas arrive lorsque l'ensemble des identifiants associés à la deuxième ligne sont inclus dans la première ligne. Comme nous avons déterminé précédemment le protégé du premier mot-clef, nous pouvons déduire le protégé du mot-clef de la deuxième entrée.

Malheureusement, il peut arriver que plusieurs mots-clefs possèdent le même ensemble d'identifiants. Cela arrive lorsque différents mots-clefs sont présents simultanément dans plusieurs documents. Dans ce cas, nous ne pouvons pas déterminer les associations entre les mots-clefs protégés et ces mots-clefs clairs. Nous ignorons alors ces mots-clefs protégés si ceux-là sont présents dans les intersections suivantes.

4.5.3 Algorithme de l'attaque L2

En utilisant l'algorithme M1 jusqu'à l'ordre 4 et les algorithmes M2 et M3, nous sommes dans la mesure de présenter (4.12) l'algorithme de l'attaque réalisée sur les schémas de profil de fuite L2.

Algorithme : Attaque L2

Entrées : EDB, D^* et $\mathcal{I} \subseteq \mathsf{D}$
Sortie : $\mathsf{W}_{\mathsf{rec}} \subseteq \mathsf{W}$

$\mathsf{D}_0 \leftarrow \mathsf{M1}(\mathsf{EDB}, \mathsf{D}^*, \mathcal{I})$;
$\mathsf{D}_1 \leftarrow \mathsf{M2}(\mathsf{EDB}, \mathsf{D}^*, \mathsf{D}_0, \mathcal{I})$;
$\mathsf{W}_{\mathsf{rec}} \leftarrow \mathsf{M3}(\mathsf{D}_1)$;

retourner $\mathsf{W}_{\mathsf{rec}}$

FIGURE 4.12 – Algorithme de l'attaque sur le profil de fuite L2.

4.5.4 Résultats sur la cryptanalyse des schémas le profil L2

Nous exposons dans le graphe de la figure 4.13, les résultats de l'attaque L2 sur l'ensemble documentaire *Commons*.

Nous représentons sur ce graphe deux informations. La première concerne le taux de mots-clefs clairs dont nous avons déterminé la valeur protégée. Ce taux est d'une part calculé par rapport au nombre de mots-clefs présents dans l'échantillon des documents clairs connu (Ratio de mots-clefs accessibles recouverts). D'autre part, il est également calculé par rapport au nombre de mots-clefs total présents dans l'ensemble documentaire *Commons* (Ratio de mots-clefs recouverts).

La seconde information représentée est déduite de l'ensemble des mots-clefs clairs associés. Celle-ci représente le nombre de documents chiffrés dont nous avons reconstruit les clairs. Dans le graphes de la figure 4.13, nous représentons le nombre de documents chiffrés dont nous avons reconstruit les clairs au moins à 70%, 80%, 90% et 100% (# Documents recouverts au moins à 70%, 80%, 90% et 100%).

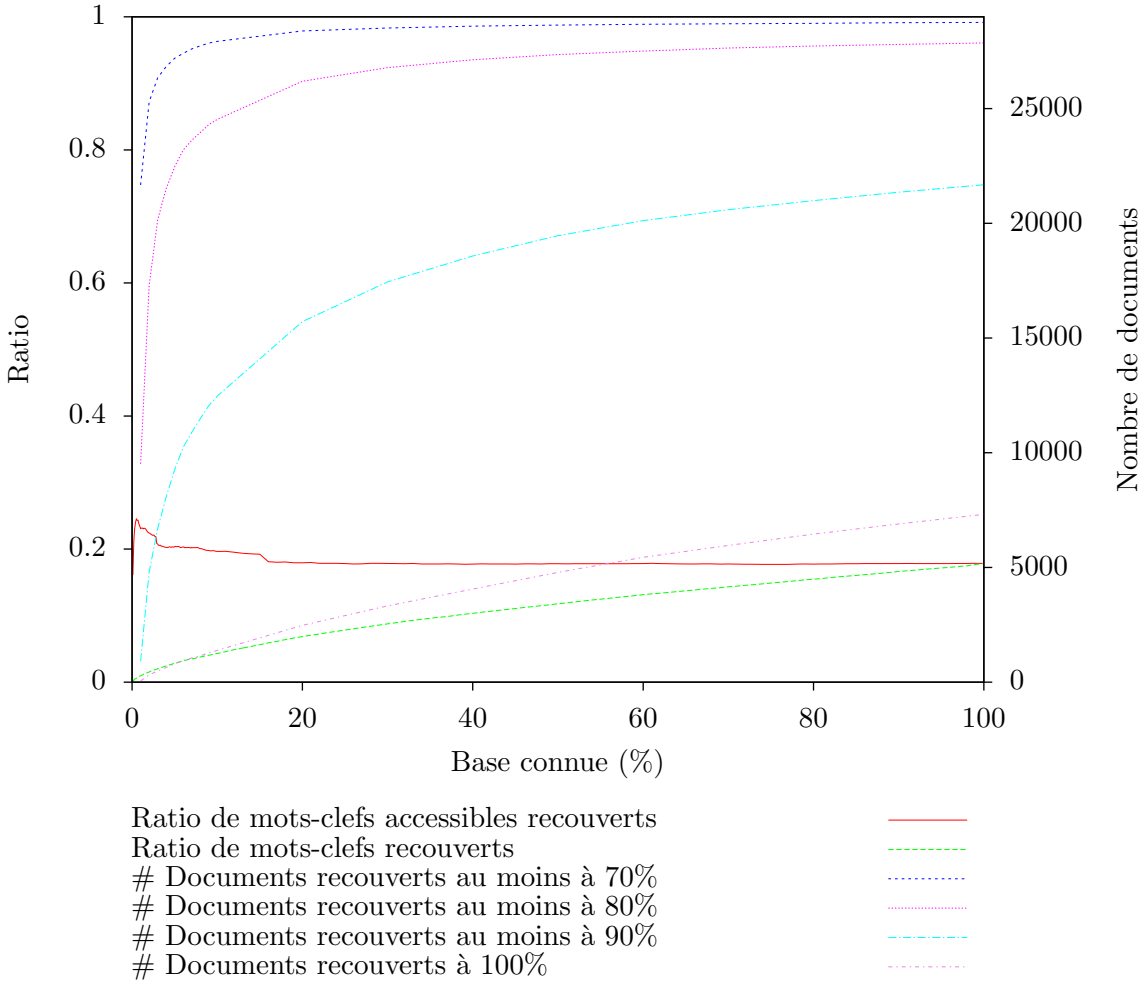

FIGURE 4.13 – Résultat de l'attaque L2 sur la collection *Commons*.

Nous présentons dans la table 4.14, le taux d'associations (Taux) réussies entre les mots-clefs clairs des documents de l'échantillon connu et leur valeur protégée en fonction du pourcentage de l'ensemble documentaire connu (%). Nous représentons dans les autres colonnes le nombre de documents chiffrés, qui grâce à cet ensemble de mots-clefs associés, ont été reconstruit au moins à 70%, 80%, 90% et 100% (# 70%, 80%, 90%, 100%).

%	Taux	# 70%	# 80%	# 90%	# 100%
1	0.23	21 664	9 516	909	51
5	0.20	27 187	22 460	9 249	794
10	0.19	27 929	24 529	12 472	1 385
20	0.18	28 383	26 187	15 715	2 475
30	0.18	28 508	26 780	17 447	3 326
40	0.18	28 588	27 126	18 573	4 059
50	0.18	28 634	27 354	19 460	4 784

FIGURE 4.14 – Résultats de l'attaque L2 sur l'ensemble *Commons*.

Comme nous le voyons, la connaissance de 5% des documents clairs de l'ensemble documentaire permet de récupérer au moins 80% du contenu de plus de 22 000 documents (sur un total de 28 997 documents).

Les résultats de cette attaque L2 pour l'ensemble documentaire *Lucene* sont quant à eux présentés dans l'annexe A.

Conclusion

Les résultats obtenus par les attaques réalisées nous montrent que la connaissance d'un faible échantillon de documents clairs est dangeureuse pour les documents chiffrés que le client héberge sur le serveur. En effet, pour les schémas SSE de profil de fuite L4, L3 ou L2, les résultats nous montrent qu'à partir d'un tel échantillon, un attaquant peut reconstruire un nombre important de documents clairs à partir de la base de données chiffrée.

Malgré ces bons résultats, il serait intéressant d'étudier le comportement de ces attaques sur d'autres ensembles documentaires afin de vérifier que celles-ci soient toujours aussi efficaces quelque soit la nature de l'ensemble documentaire considéré. Nous n'avons par exemple pas pu traiter l'ensemble documentaire *Wikipedia* à cause de contraintes matérielles.

Bien que l'attaque que nous avons réalisée sur un schéma de profil de fuite L2 nous donne une bonne connaissance du contenu des documents, une autre piste envisageable pour l'exploitation des fuites d'un tel schéma serait de considérer la matrice de co-occurence.

Enfin, les techniques d'attaque que nous avons utilisées sur les schémas de profil de fuite L4, L3 ou L2 ne sont pas applicables sur les schémas de profil de fuite L1 et L0. Il faudrait alors soit définir de nouvelles mesures, soit définir de nouvelles connaissances préalables pour l'attaquant.

Ce stage a été tout aussi enrichissant d'un point de vue professionnel, qu'humainement épanouissant. Il m'a permis d'approfondir des connaissances en cryptographique comme d'en apprendre de nouvelles, avec par exemple, l'utilisation de fonctions de fuites en preuve de sécurité, ou les différentes méthodes de manipulation des données chiffrées.

Je sors ravi de cette première expérience professionnelle et enthousiaste à l'idée de continuer à découvrir les joies que la cryptographie peut apporter.

Chapitre A
Résultats des attaques réalisées

Cette annexe rassemble les résultats des attaques réalisées sur les différents ensembles de documents considérés. Nous commençons par présenter les résultats sur la cryptanalyse des schémas de recherche ayant un profil de fuite L4 pour terminer avec ceux ayant un profil de fuite L2.

§ A.1 Lecture des résultats

A.1.1 Les graphes

Nous représentons sur chacun des graphes deux informations. La première concerne le taux de mots-clefs clairs dont nous avons déterminé la valeur protégée. Ce taux est d'une part calculé par rapport au nombre de mots-clefs présents dans l'échantillon des documents clairs connu (mots-clefs accessibles). D'autre part, il est également calculé par rapport au nombre de mots-clefs total présents dans l'ensemble documentaire considéré.

La seconde information représentée est déduite de l'ensemble des mots-clefs clairs associés. Celle-ci représente le nombre de documents dont nous avons récupéré une portion de leurs mots-clefs contenus. Dans les graphes à suivre, nous représentons le nombre de documents chiffrés dont nous avons reconstruit les clairs à 70%, 80%, 90% et 100%.

A.1.2 Les tableaux

Nous présentons dans les tableaux, le taux d'associations (Taux) réussies entre les mots-clefs clairs des documents de l'échantillon connu et leur valeur protégée en fonction du pourcentage de l'ensemble documentaire connu (%). Nous représentons dans les autres colonnes le nombre de documents chiffrés, qui grâce à cet ensemble de mots-clefs associés, ont été reconstruits au moins à 70%, 80%, 90% et 100% (# 70%, 80%, 90%, 100%).

§ A.2 Résultats sur la cryptanalyse des schémas de profil L4

A.2.1 Résultats sur l'ensemble documentaire *Lucene*

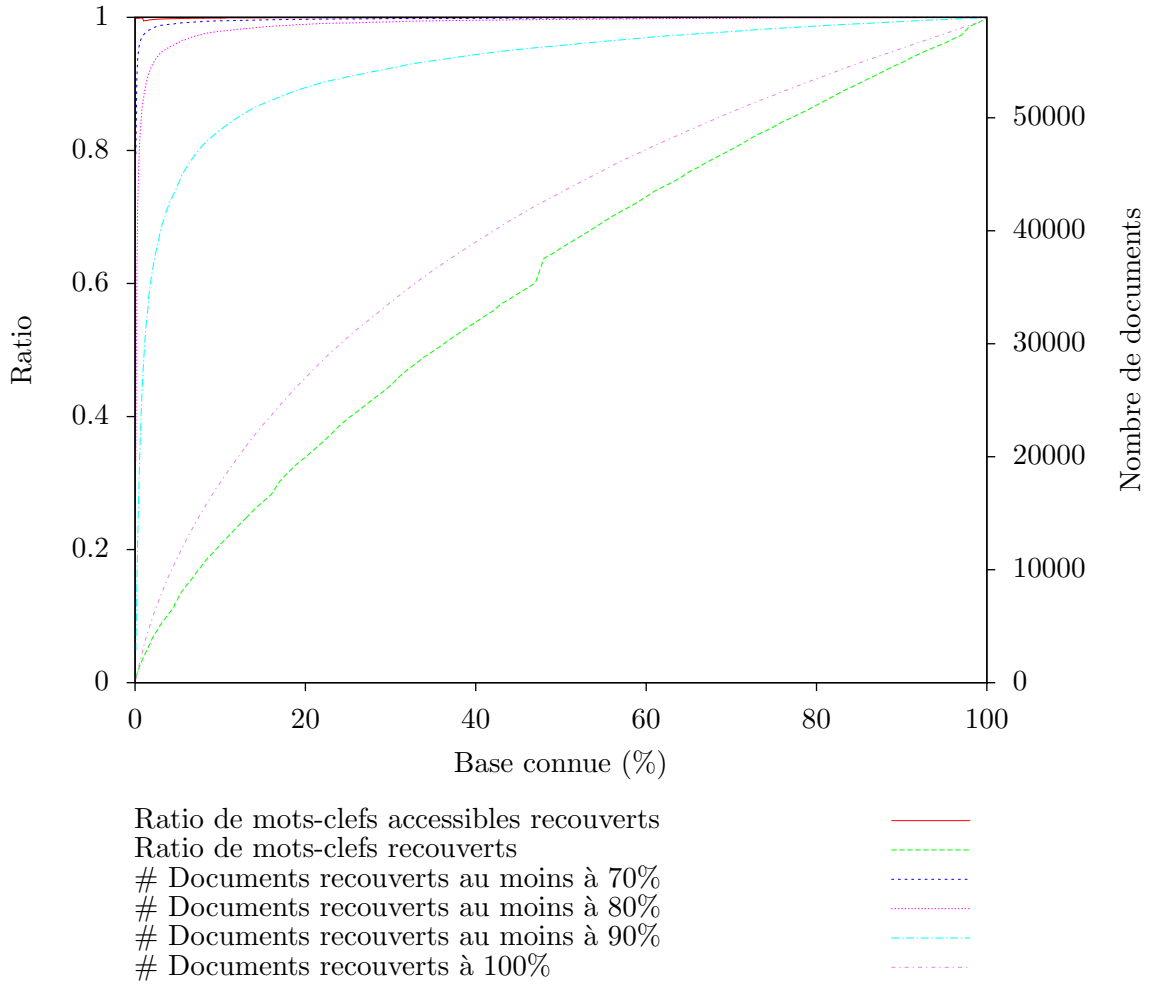

FIGURE A.1 – Résultats de l'attaque L4 sur l'ensemble documentaire *Lucene*.

%	Taux	# 70%	# 80%	# 90%	# 100%
1	0.99	57 335	51 752	28 374	3146
5	0.99	58 348	56 630	44 031	11 120
10	0.99	58 582	57 653	48 922	17 704
20	0.99	58 706	58 261	52 660	26 989
30	0.99	58 764	58 481	54 384	33 670
40	0.99	58 798	58 630	55 586	39 001
50	0.99	58 823	58 704	56 404	43 393

FIGURE A.2 – Résultats de l'attaque L4 sur l'ensemble *Lucene*.

A.2.2 Résultats sur l'ensemble documentaire *Enron*

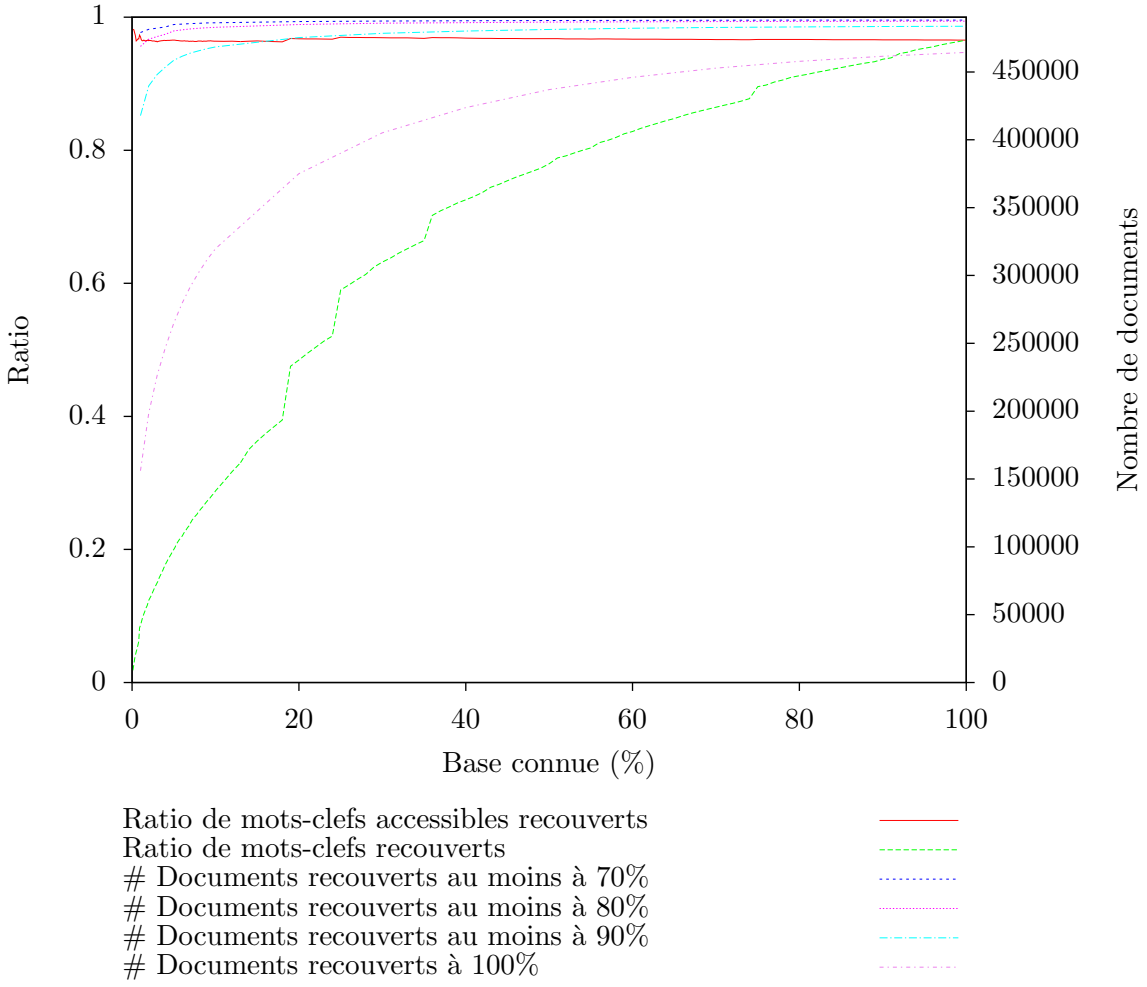

FIGURE A.3 – Résultats de l'attaque L4 sur l'ensemble documentaire *Enron*.

%	Taux	# 70%	# 80%	# 90%	# 100%
1	0.97	479 064	468 840	417 832	156 084
5	0.96	484 947	480 232	458 607	264 975
10	0.96	486 237	482 937	468 423	319 751
20	0.96	487 092	484 983	475 371	375 053
30	0.96	487 535	485 904	478 460	405 158
40	0.96	487 744	486 387	480 150	423 732
50	0.96	487 939	486 730	481 363	437 024

FIGURE A.4 – Résultats de l'attaque L4 sur l'ensemble *Enron*.

§ A.3 Résultats sur la cryptanalyse des schémas de profil L3

A.3.1 Résultats sur l'ensemble documentaire *Lucene*

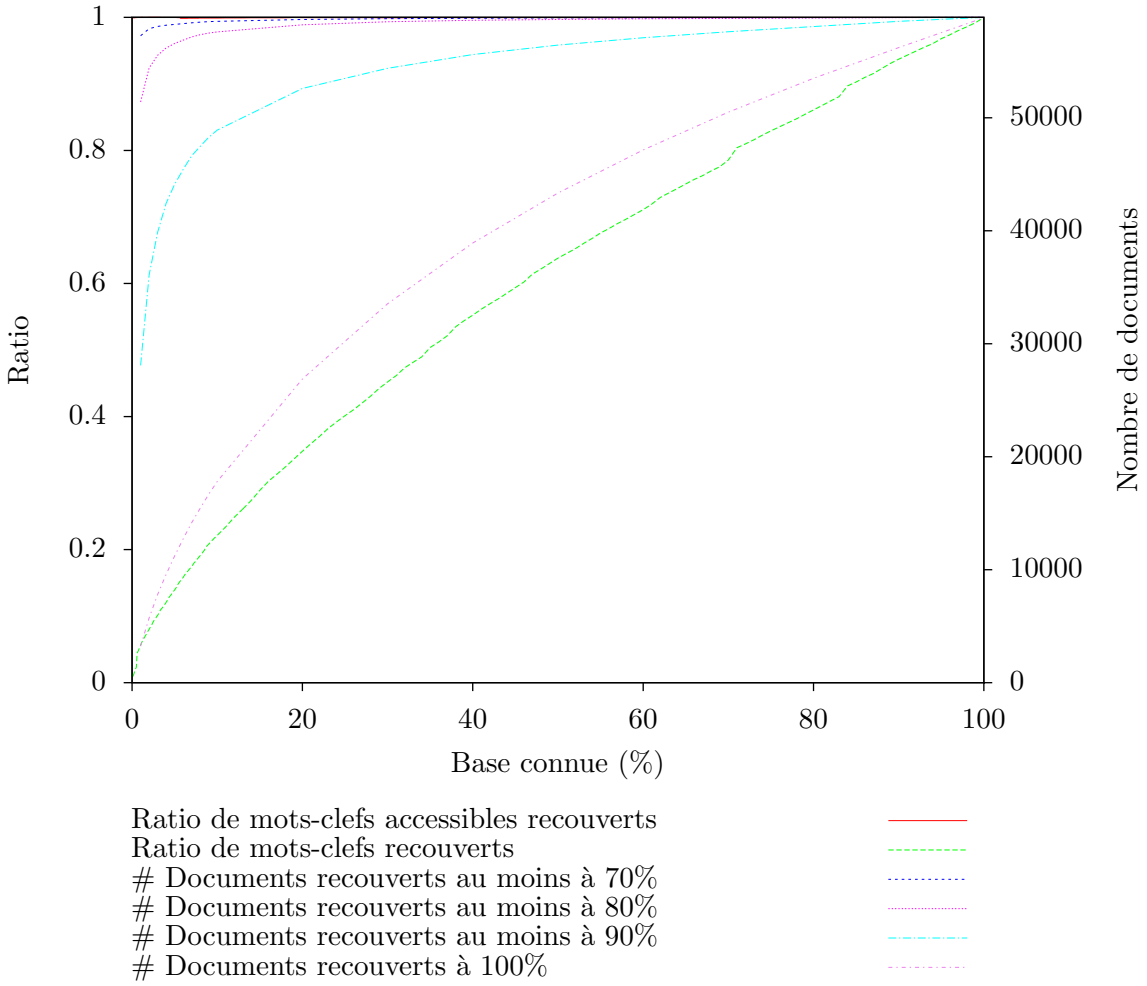

FIGURE A.5 – Résultats de l'attaque L3 sur l'ensemble documentaire *Lucene*.

%	Taux	# 70%	# 80%	# 90%	# 100%
1	0.99	57 258	51 394	28 086	3 240
5	0.99	58 264	56 567	44 106	11 212
10	0.99	58 524	57 598	48 905	17 811
20	0.99	58 701	58 222	52 586	26 880
30	0.99	58 771	58 489	54 371	33 542
40	0.99	58 806	58 620	55 589	38 913
50	0.99	58 832	58 701	56 430	43 333

FIGURE A.6 – Résultats de l'attaque L3 sur l'ensemble *Lucene*.

A.3.2 Résultats sur l'ensemble documentaire *Gutenberg*

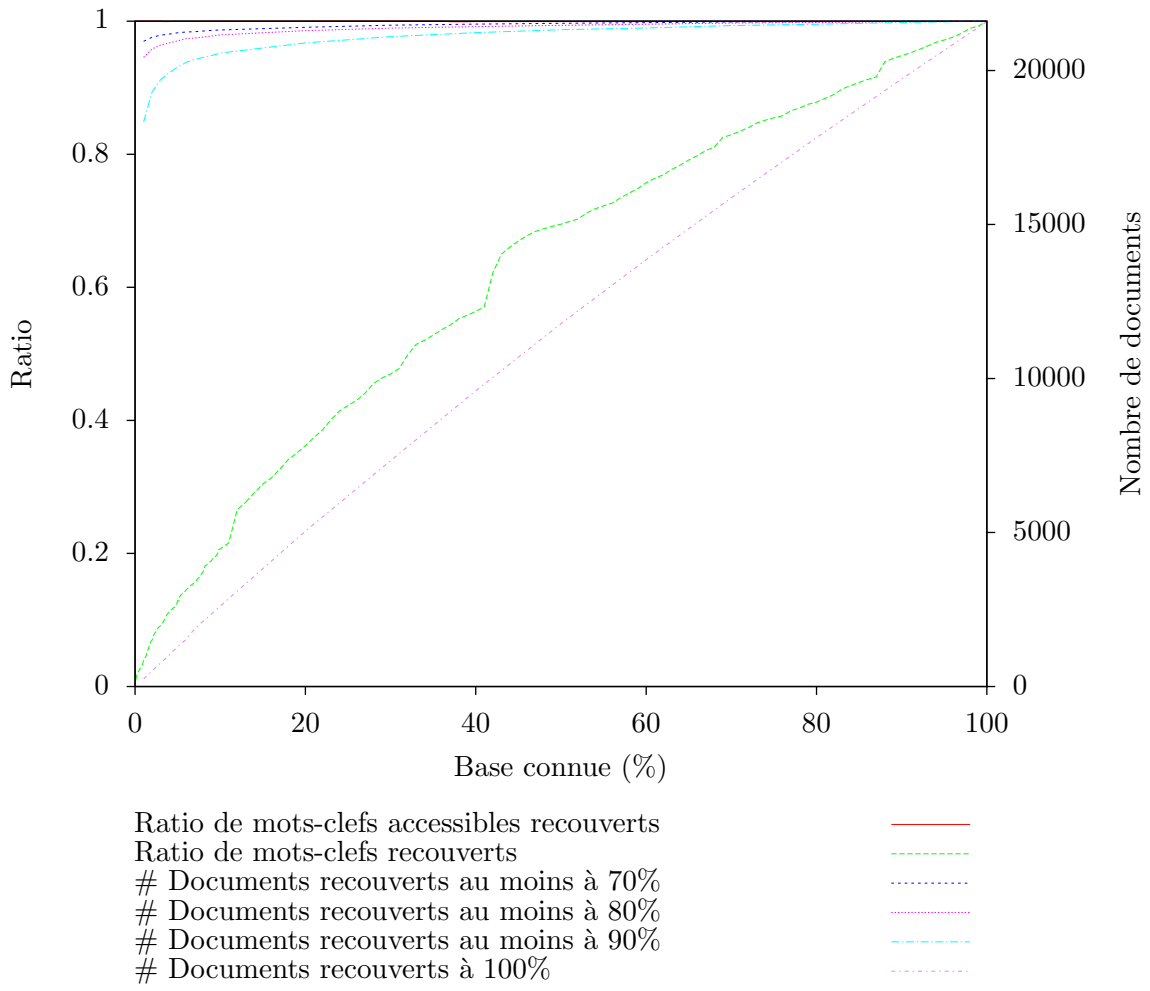

FIGURE A.7 – Résultats de l'attaque L3 sur l'ensemble documentaire *Gutenberg*.

%	Taux	# 70%	# 80%	# 90%	# 100%
1	1	20 948	20 430	18 328	244
5	0.99	21 225	20 959	20 109	1 288
10	0.99	21 317	21 154	20 568	2 613
20	0.99	21 401	21 295	20 894	5 044
30	0.99	21 470	21 375	21 099	7 332
40	0.99	21 505	21 424	21 229	9 603
50	0.99	21 532	21 468	21 323	11 778

FIGURE A.8 – Résultats de l'attaque L3 sur l'ensemble *Gutenberg*.

§ A.4 Résultats sur la cryptanalyse des schémas de profil L3

A.4.1 Résultats sur l'ensemble documentaire *Lucene*

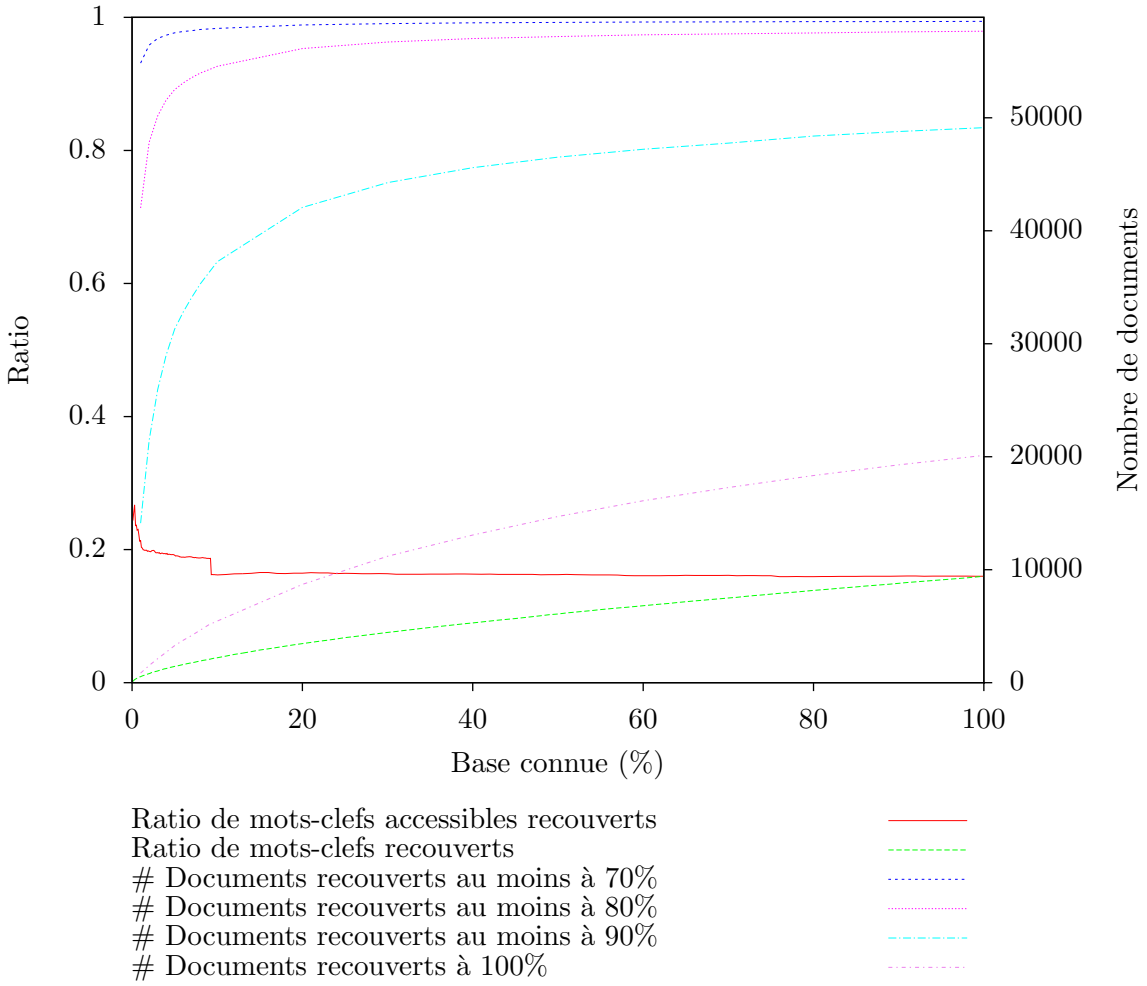

FIGURE A.9 – Résultats de l'attaque L2 sur l'ensemble *Lucene*.

%	Taux	# 70%	# 80%	# 90%	# 100%
1	0.21	54 839	42 016	14 117	855
5	0.19	57 517	52 483	31 285	3 285
10	0.16	57 899	54 556	37 260	5 458
20	0.16	58 217	56 124	42 062	8 704
30	0.16	58 325	56 703	44 257	11 187
40	0.16	58 396	57 008	45 579	13 064
50	0.16	58 438	57 188	46 513	14 713

FIGURE A.10 – Résultats de l'attaque L2 sur l'ensemble *Lucene*.

Bibliographie

[CGKO06] Reza Curtmola, Juan Garay, Seny Kamara, and Rafail Ostrovsky. Searchable symmetric encryption : Improved definitions and efficient constructions. 2006. http://eprint.iacr.org/2006/210.

[CGPR16] David Cash, Paul Grubbs, Jason Perry, and Thomas Ristenpart. Leakage-abuse attacks against searchable encryption. 2016. http://eprint.iacr.org/2016/718.

[CJJ+13] David Cash, Stanislaw Jacrecki, Charanjit Jutla, Hugo Krawczyk, Marcel-Cătălin Roşu, and Michael Steiner. Highly-scalable searchable symmetric encryption with support for boolean queries. 2013. http://eprint.iacr.org/2013/169.

[CJJ+14] David Cash, Joseph Jaeger, Stanislaw Jarecki, Charanjit Jutla, Hugo Krawczyk, Marcel-Cătălin Roşu, and Michael Steiner. Dynamic searchable encryption in very-large databases : Data structures and implementation. 2014. http://eprint.iacr.org/2014/853.

[Gen] Craig Gentry. Computing arbitrary functions of encrypted data.

[Goh03] Eu-Jin Goh. Secure indexes. 2003. http://eprint.iacr.org/2003/216.

[KPR12] Seny Kamara, Charalampos Papamanthou, and Tom Roeder. Dynamic searchable symmetric encryption. 2012. http://eprint.iacr.org/2012/530.